

Совместная программа СМОЛ
ГУ и ФКН НИУ ВШЭ

2026/27 учебный год

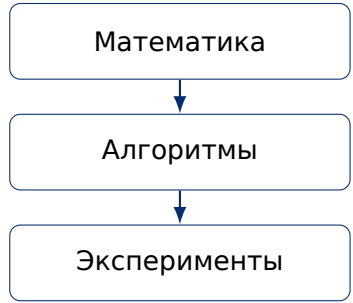
Методы оптимизации в машинном обучении

Лекция 1. Оптимизация как язык машинного обучения

Никита Лукьяненко

О преподавателе

- Никита Лукьяненко
- старший преподаватель ФКН НИУ ВШЭ
- преподавательский опыт: теория вероятностей, математическая статистика, статистическая теория обучения
- интересы курса: математическая сторона обучения моделей и вычислительное поведение алгоритмов

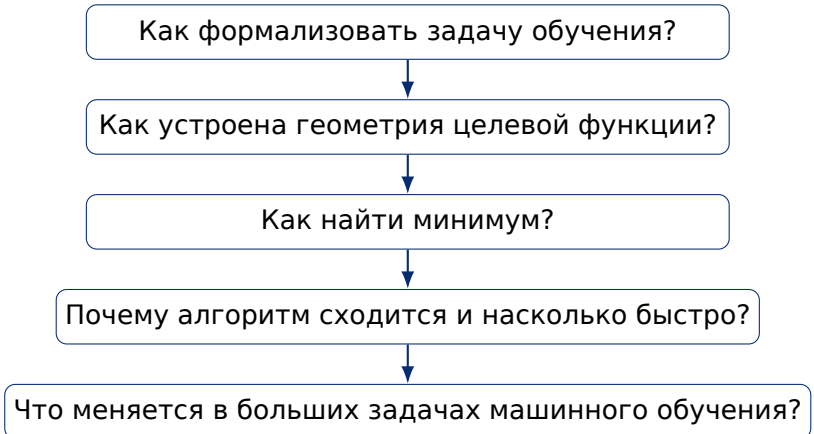


Как будем работать

Моя цель — не перечислить как можно больше методов, а научить вас понимать, **что именно оптимизируется, почему алгоритм устроен так и когда он может работать плохо**.

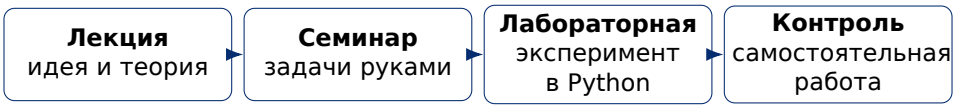
Что будет в курсе

Пять вопросов, к которым мы будем возвращаться весь год



Главный герой первого семестра — градиентный спуск.

Как устроен курс



На лекциях

Определения, геометрическая интуиция, ключевые утверждения и небольшое число доказательств.

На практике

Сначала маленькие задачи, где алгоритм можно увидеть целиком; затем — модели и реальные данные.

В течение семестра: 4 домашние лабораторные работы.

Система оценивания

Активность	Обозначение	Вес
Домашние задания / 4 лабораторные работы	H	0.20
Контрольная работа	C	0.25
Коллоквиум	K	0.25
Экзамен	E	0.50

Каждая активность оценивается целым числом от 0 до 10.

Расчёт

$$S = 0.20H + 0.25C + 0.25K + 0.50E.$$

Итоговая оценка получается арифметическим округлением рассчитанного результата.

Ориентировочные сроки: контрольная работа — первая половина ноября; коллоквиум — вторая половина ноября.

Домашние работы: 4 лабораторные работы в течение семестра; точные дедлайны объявляются заранее.

Начнём с самой простой задачи

Рассмотрим функцию

$$f(x) = (x - 3)^2 + 1.$$

Вопрос

Какое значение x нужно выбрать,
чтобы сделать $f(x)$ как можно меньше?

Начнём с самой простой задачи

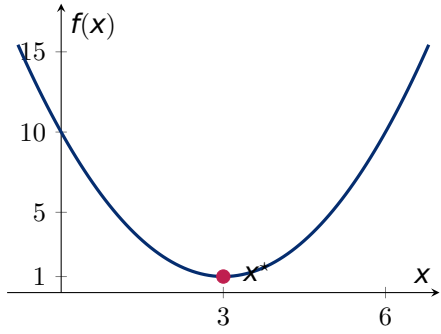
Рассмотрим функцию

$$f(x) = (x-3)^2 + 1.$$

Вопрос

Какое значение x нужно выбрать, чтобы сделать $f(x)$ как можно меньше?

$$x^\star = 3, \qquad f(x^\star) = 1.$$



Общая задача оптимизации

Что означает запись?

$$\min_{x \in X} f(x)$$

Нужно выбрать **допустимое** значение $x \in X$, при котором значение $f(x)$ как можно меньше.

x	$f(x)$	X
что выбираем	**что минимизируем**	**где можем выбирать**
переменная оптимизации	целевая функция	допустимое множество

Типичная интерпретация в машинном обучении

x — параметры модели, $f(x)$ — мера ошибки модели.

Минимум и минимизатор — разные объекты

Минимизатор

Точка (или множество точек), где достигается наименьшее значение:

$$x^\star \in \arg\min_x f(x).$$

Минимальное значение

Число — значение функции в оптимальной точке:

$$f^\star = \min_x f(x).$$

Для $f(x) = (x-3)^2 + 1$:

$$\arg\min_x f(x) = \{3\}, \qquad \min_x f(x) = 1.$$

$\arg\min$ **= где?** $\min$ **= сколько?**

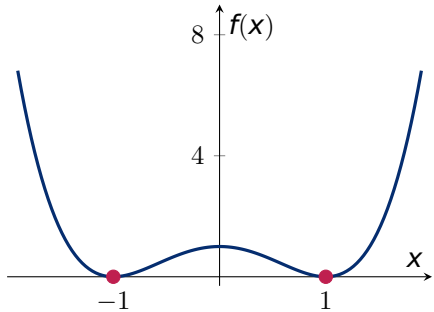
Минимизатор может быть не единственным

$$f(x) = (x^2 - 1)^2.$$

$$\arg\min_x f(x) = \{-1, 1\}.$$

Важно

$\arg\min$ в общем случае — **множество**, а не одна точка.



А минимум вообще всегда существует?

$f(x) = x^2$

Минимум существует:

$$\min f = 0.$$

$$x^\star = 0$$

$f(x) = e^x$

$$\inf f = 0,$$

но $e^x > 0$ при любом конечном x.

Минимума нет.

$f(x) = -x^2$

$$f(x) \to -\infty$$

при $|x| \to \infty$.

Функция не ограничена снизу.

Три фундаментальных вопроса курса

Существует ли решение? Единственно ли оно? Как его найти?

Добавление константы не меняет минимизаторы

Теорема

Пусть $g(x) = f(x) + C$, где C не зависит от x. Тогда

$$\arg\min_x g(x) = \arg\min_x f(x).$$

Добавление константы не меняет минимизаторы

Теорема

Пусть $g(x) = f(x) + C$, где C не зависит от x. Тогда

$$\arg\min_x g(x) = \arg\min_x f(x).$$

Доказательство.

Для любых x_1, x_2:

$$f(x_1) \le f(x_2) \quad \Longleftrightarrow \quad f(x_1) + C \le f(x_2) + C.$$

Следовательно, добавление C не меняет порядок значений функции и не меняет точки, в которых значение минимально. □



Положительное масштабирование тоже не меняет минимизаторы

Теорема

Если $g(x) = Cf(x)$ *и* $C > 0$, *то*

$$\arg\min_x g(x) = \arg\min_x f(x).$$

Положительное масштабирование тоже не меняет минимизаторы

Теорема

Если $g(x) = Cf(x)$ и $C > 0$, то

$$\arg\min_x g(x) = \arg\min_x f(x).$$

Поскольку при $C > 0$

$$f(x_1) \leq f(x_2) \quad \Longleftrightarrow \quad Cf(x_1) \leq Cf(x_2).$$

А если $C < 0$?

$$\arg\min_x Cf(x) = \arg\max_x f(x).$$

Отрицательное масштабирование переворачивает порядок.

Почему это понадобится в машинном обучении

Если $\ell_i(w)$ — ошибка модели на объекте i, то часто встречаются две записи:

$$F_1(w) = \sum_{i=1}^{n} \ell_i(w), \qquad F_2(w) = \frac{1}{n} \sum_{i=1}^{n} \ell_i(w).$$

Поскольку $1/n > 0$,

$$\boxed{\arg\min_w F_1(w) = \arg\min_w F_2(w).}$$

То есть

Для положения минимума сумма и среднее эквивалентны. Но их производные и численные масштабы отличаются — позже это станет важным для выбора шага алгоритма.

Не все преобразования безобидны

Исходная задача

Рассмотрим $x \in [-1, 1]$ и

$$f(x) = x.$$

Тогда

$$\arg\min_{x \in [-1,1]} f(x) = \{-1\}.$$

После преобразования

Возведём целевую функцию в квадрат:

$$g(x) = f(x)^2 = x^2.$$

Теперь

$$\arg\min_{x \in [-1,1]} g(x) = \{0\}.$$

Вывод

Даже простое преобразование целевой функции может изменить решение задачи оптимизации.

Небольшая задача

Пусть

$$f(x) = (x - 2)^2.$$

Найдите минимизаторы следующих функций:

$$f(x),$$
$$3f(x),$$
$$f(x) + 100,$$
$$-f(x).$$

На обсуждение: 2 минуты.

Что делает модель машинного обучения?

Пусть есть обучающая выборка

$$(x_i, y_i), \qquad i = 1, \ldots, n.$$

Модель с параметрами w строит предсказание

$$\widehat{y}_i = h_w(x_i).$$

Что мы можем менять?

Данные x_i, y_i уже зафиксированы. Во время обучения мы подбираем **параметры модели** w.

обучение = выбор хорошего значения w

Функция потерь: насколько плохо одно предсказание?

Определение

Функция потерь $\ell(\widehat{y}, y)$ сопоставляет предсказанию и правильному ответу число, измеряющее ошибку.

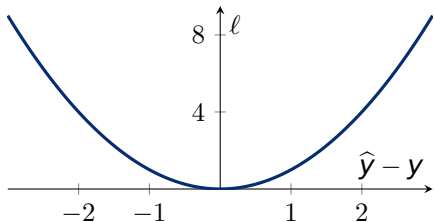
Для регрессии естественный пример:

$$\ell(\widehat{y}, y) = (\widehat{y} - y)^2.$$

Если $\widehat{y} = y$, то

$$\ell = 0.$$

Чем дальше предсказание от ответа, тем больше штраф.



От одного объекта ко всей выборке

Ошибка на объекте i:

$$\ell_i(w) = \ell\big(h_w(x_i), y_i\big).$$

Средняя ошибка на обучающей выборке:

$$\boxed{F(w) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(w)}$$

называется **эмпирическим риском**.



От одного объекта ко всей выборке

Ошибка на объекте i:

$$\ell_i(w) = \ell\big(h_w(x_i), y_i\big).$$

Средняя ошибка на обучающей выборке:

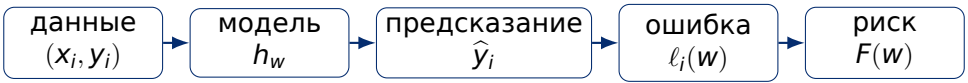
$$\boxed{F(w) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(w)}$$

называется **эмпирическим риском**.

Обучение модели превращается в задачу

$$\boxed{w^\star \in \arg\min_w F(w)}$$

Универсальная схема обучения



$$\min_w F(w)$$

Где начинается наш курс

Архитектура модели и выбор функции потерь задают F. Дальше возникает вопрос: **как эффективно минимизировать эту функцию по параметрам w?**



Разные модели — одна оптимизационная структура

Линейная регрессия

$$\widehat{y} = w^\top x + b$$

$$\min_{w,b} F(w, b)$$

Логистическая регрессия

$$p = \sigma(w^\top x + b)$$

$$\min_{w,b} F(w, b)$$

Нейронная сеть

$$\widehat{y} = h_w(x)$$

$$\min_{w} F(w)$$

Меняются модель и функция потерь, но остаётся вопрос

как найти хорошие параметры?

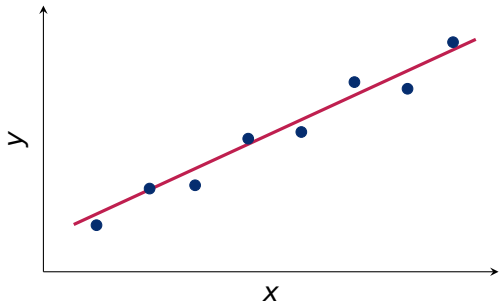
Пример 1: линейная регрессия

В одномерном случае модель имеет вид

$$\widehat{y} = wx + b.$$

Нужно подобрать два параметра:

$$w \quad \text{и} \quad b.$$



Интерпретация

w отвечает за наклон прямой, b — за вертикальный сдвиг.

Среднеквадратичная ошибка

Для наблюдений (x_i, y_i) и модели $\widehat{y}_i = wx_i + b$ определим

$$F(w, b) = \frac{1}{n}\sum_{i=1}^{n}(wx_i + b - y_i)^2.$$

Тогда обучение линейной регрессии — это

$$\boxed{\min_{w,b} \frac{1}{n}\sum_{i=1}^{n}(wx_i + b - y_i)^2}$$

Переменные оптимизации

w, b

Целевая функция

$F(w, b)$

Сегодня мы только ставим задачу. Градиент этой функции появится позже.

Два пространства, которые важно не путать

Пространство данных
Каждая пара (w, b) задаёт прямую

$$y = wx + b.$$

Мы видим, насколько хорошо она проходит через наблюдения.

Пространство параметров
Каждой паре (w, b) соответствует число

$$F(w, b).$$

Оптимизация происходит именно здесь:

$$(w, b) \longmapsto F(w, b).$$

Ключевая мысль

Модель живёт в пространстве данных, а алгоритм оптимизации двигается в пространстве параметров.

Пример 2: бинарная классификация

Пусть

$$y \in \{0, 1\}.$$

Линейное выражение $w^\top x + b$ может принимать любые вещественные значения, поэтому само по себе не является вероятностью.
Используем логистическую функцию:

$$\boxed{\sigma(z) = \frac{1}{1 + e^{-z}}}$$

$$p(y = 1 \mid x) = \sigma(w^\top x + b).$$

$\sigma(z) \in (0, 1)$ для любого $z \in \mathbb{R}$.

Логистическая функция потерь

Обозначим

$$p_i = \sigma(w^\top x_i + b).$$

Одна из стандартных функций потерь для бинарной классификации:

$$F(w, b) = -\frac{1}{n} \sum_{i=1}^{n} \Big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big].$$

И снова обучение имеет вид

$$\boxed{\min_{w,b} F(w, b).}$$

Пока принимаем формулу как данность

Её вывод из принципа максимального правдоподобия не нужен для сегодняшней цели. Нам важно увидеть оптимизационную структуру.

Всегда ли нужно минимизировать только ошибку?

Представьте две модели:

- первая почти идеально подстраивается под обучающие данные, но очень сложна;
- вторая ошибается немного сильнее, зато устроена заметно проще.

В машинном обучении часто нужен **компромисс** между качеством подгонки и сложностью модели.

Идея регуляризации

Добавим к ошибке штраф за нежелательные значения параметров.

Регуляризованная задача

$$\min_w \left[\underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell_i(w)}_{\text{ошибка на данных}} + \lambda \underbrace{R(w)}_{\text{штраф}} \right]$$

w

параметры модели
то, что мы подбираем

$R(w)$

регуляризатор
штраф за нежелательные параметры

$\lambda \geq 0$

сила штрафа
задаёт баланс двух частей

Пример: $R(w) = \|w\|_2^2$.

Чем больше λ, тем сильнее целевая функция штрафует большие значения параметров.

Оптимизация как компромисс

$$\underbrace{\text{ошибка на данных}}_{\text{хочется уменьшить}} + \lambda \underbrace{\text{сложность модели}}_{\text{хочется контролировать}}$$

Важно

Оптимизация не обязательно означает «минимизировать ошибку любой ценой». Мы сначала **конструируем целевую функцию**, которая отражает нужный нам компромисс, а уже потом ищем её минимум.



Вся первая лекция — в одной формуле

$$w^\star \in \arg\min_w \left[\frac{1}{n} \sum_{i=1}^{n} \ell\big(h_w(x_i), y_i\big) + \lambda R(w) \right]$$

- w — параметры модели;
- h_w — модель;
- ℓ — ошибка на одном объекте;
- R — регуляризатор;
- λ — сила регуляризации.

Но как найти $w^\star$?

Если параметров два, поверхность функции можно хотя бы нарисовать.

А если параметров — миллион?

Следующий вопрос курса

Как использовать геометрию функции, чтобы понять, **куда двигаться из текущей точки**?

Следующая лекция: **линейная алгебра для оптимизации**.



Что нужно унести с собой

1. Задача оптимизации имеет вид $\min_{x \in X} f(x)$.
2. $\arg\min$ обозначает точки-минимизаторы, $\min$ — минимальное значение.
3. Обучение модели часто сводится к минимизации среднего значения функции потерь.
4. Регуляризация добавляет в целевую функцию штраф и меняет компромисс, который мы оптимизируем.
5. Следующая задача — научиться находить минимум алгоритмически.

К следующему занятию: повторить векторы, матрицы, скалярное произведение и собственные значения.