



Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 2. Геометрия оптимизации: производная, градиент и
гессиан

Никита Лукьяненко



От первой лекции — к следующему вопросу

На первой лекции мы научились записывать обучение модели как задачу


$$x^* \in \arg \min_x f(x).$$

Теперь представим, что мы находимся в некоторой текущей точке x .

Главный вопрос сегодня

Как понять, **куда двигаться из x** , чтобы значение f стало меньше?

Какое направление выбрать?



пространство параметров



Любой итерационный метод: одна простая схема

Во многих алгоритмах новая точка получается из старой по правилу

$$x_{k+1} = x_k + h_k.$$

Направление

Куда должен смотреть вектор h_k ?

Длина шага


Насколько большим должен быть $\|h_k\|$?

Сегодня почти полностью занимаемся **направлением**. Выбор длины шага будет отдельной темой курса.



Основная идея лекции

Сложную функцию трудно анализировать целиком. Поэтому около текущей точки x мы заменяем её простой моделью.



Одна история на всю лекцию

Как поведение f в маленькой окрестности точки x подсказывает нам направление движения?



Изменение параметров — это вектор

Пусть $x \in \mathbb{R}^d$ — текущие параметры, а $h \in \mathbb{R}^d$ — их изменение. Тогда

$$x_{\text{new}} = x + h.$$

Например,


$$x = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad h = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

и поэтому

$$x + h = \begin{pmatrix} 1 \\ 3 \end{pmatrix}.$$

Что кодирует h ?

Его направление отвечает на вопрос «куда двигаться?», а длина $\|h\|$ — «насколько далеко?».





Длина изменения

Для евклидовой нормы

$$\|h\|_2 = \sqrt{h_1^2 + \dots + h_d^2}.$$

Геометрический смысл

$\|h\|_2$ — обычная длина вектора: насколько далеко мы ушли в пространстве параметров.

Например, для

$$h = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

имеем

$$\|h\|_2 = \sqrt{5}.$$

Дальше индекс 2 будем часто опускать и писать просто $\|h\|$.



Как сравнивать два направления?

В $\mathbb{R}^d$ привычное евклидово скалярное произведение имеет вид


$$x^\top v = \sum_{i=1}^d x_i v_i.$$

Его знак уже несёт геометрическую информацию:

- $x^\top v_+ > 0$ — острый угол,
- $x^\top v_0 = 0$ — прямой угол,
- $x^\top v_- < 0$ — тупой угол.

Геометрическая идея

Скалярное произведение позволяет числом измерить, насколько два направления согласованы друг с другом.





Самопроверка: что такое скалярное произведение?

Вопрос

Пусть V — вещественное векторное пространство. Каким свойствам должно удовлетворять отображение

$$\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R},$$

чтобы называться **скалярным произведением**?

Попробуйте вспомнить свойства до следующего слайда.

Подсказка: нужны свойства, связывающие скалярное произведение с линейной структурой пространства и с понятием длины.



Самопроверка: определение скалярного произведения

Вопрос

Каким свойствам должно удовлетворять $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$?

Определение

Отображение $\langle \cdot, \cdot \rangle$ называется **скалярным произведением**, если для любых $u, v, w \in V$ и $\alpha, \beta \in \mathbb{R}$ выполнены:

$$\begin{aligned}\text{билинейность: } \langle \alpha u + \beta w, v \rangle &= \alpha \langle u, v \rangle + \beta \langle w, v \rangle, \\ \langle u, \alpha v + \beta w \rangle &= \alpha \langle u, v \rangle + \beta \langle u, w \rangle;\end{aligned}$$

$$\text{симметрия: } \langle u, v \rangle = \langle v, u \rangle;$$

$$\text{положительная определённость: } \langle u, u \rangle \geq 0, \quad \langle u, u \rangle = 0 \iff u = 0.$$

Для стандартного скалярного произведения в $\mathbb{R}^d$:

$$\langle u, v \rangle = u^\top v = \sum_{i=1}^d u_i v_i.$$



Скалярное произведение и угол


Для ненулевых векторов

$$u^T v = \|u\| \|v\| \cos \theta,$$

где $\theta \in [0, \pi]$ — меньший угол между направлениями u и v .

- $\theta < 90^\circ: u^T v > 0$;
- $\theta = 90^\circ: u^T v = 0$;
- $\theta > 90^\circ: u^T v < 0$.

Именно зависимость от угла позже позволит понять, почему движение против градиента уменьшает функцию.





Пусть

Матрица как преобразование пространства

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}.$$


Тогда для любого $x = (x_1, x_2)^T$

$$Ax = \begin{pmatrix} 2x_1 \\ x_2/2 \end{pmatrix}.$$

Что происходит геометрически?

Первая координата каждой точки удваивается, а вторая уменьшается вдвое. Поэтому единичная окружность превращается в эллипс.

Матрица действует не только на один нарисованный вектор: она одновременно преобразует **всё пространство**.





Квадратичная форма: матрица превращается в число

Если $x \in \mathbb{R}^d$ и $A \in \mathbb{R}^{d \times d}$, то

$$x^T A x \in \mathbb{R}.$$

Следите за размерностями

$$x \in \mathbb{R}^d, \quad Ax \in \mathbb{R}^d, \quad x^T (Ax) \in \mathbb{R}.$$

Например,

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix} \implies x^T A x = 2x_1^2 + 5x_2^2.$$

Позже именно такие выражения будут описывать кривизну функции.



Мини-проверка: нулевое скалярное произведение

Пусть

$$u = (1, 2), \quad v = (2, -1).$$

Тогда


$$u^T v = 1 \cdot 2 + 2 \cdot (-1) = 0.$$

По формуле

$$u^T v = \|u\| \|v\| \cos \theta$$

для ненулевых u, v получаем $\cos \theta = 0$, то есть

$$\theta = 90^\circ.$$





Производная: не формула, а локальная модель

Определение производной

Если существует предел

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$


то функция называется дифференцируемой в точке x .

Для оптимизации важнее всего эквивалентная локальная запись

$$f(x+h) = f(x) + f'(x)h + o(|h|).$$

То есть около x функция отличается от своей касательной лишь на величину, малую по сравнению с $|h|$.

Около точки функция почти совпадает с касательной





Линейная модель функции

Зафиксируем точку x и рассмотрим функцию от малого смещения h :

$$m_x(h) = f(x) + f'(x)h.$$

Интерпретация

$m_x(h)$ — простая модель того, чему примерно равно $f(x + h)$.

При $h = 0$ она точна:

$$m_x(0) = f(x).$$

А коэффициент при h равен локальному наклону $f'(x)$.



Знак производной подсказывает направление

Если $f'(x) > 0$, то для малого $h > 0$

$$f(x + h) - f(x) \approx f'(x)h > 0,$$

то есть движение вправо увеличивает функцию.

Если $f'(x) < 0$, ситуация обратная.

В одном измерении

Чтобы локально уменьшить функцию, разумно двигаться **против знака производной**.



Из локального направления уже видна знакомая формула

В одном измерении естественный шаг имеет вид

$$x_{\text{new}} = x - \alpha f'(x), \quad \alpha > 0.$$

Пока не алгоритм

Сегодня нас интересует только происхождение направления $-f'(x)$. Вопрос «какое брать α ?» мы сознательно откладываем.

$$f'(x) > 0$$

 $\Rightarrow$

двигаемся влево

$$f'(x) < 0$$

 $\Rightarrow$

двигаемся вправо



Стационарная точка ещё не обязательно минимум

Определение

В одномерном случае точка x^* называется **стационарной**, если

$$f'(x^*) = 0.$$

Рассмотрим три функции:

$$f_1(x) = x^2, \quad f_2(x) = -x^2, \quad f_3(x) = x^3.$$

Во всех трёх случаях $x^* = 0$ стационарна, но тип точки различен:

x^2	$-x^2$	x^3
минимум	максимум	ни минимум, ни максимум

Вывод

Первый порядок фиксирует нулевой наклон, но не определяет тип стационарной точки. Нужна информация второго порядка.



Что будем называть локальной кривизной?

В одной переменной $f'(x)$ описывает локальный наклон, а $f''(x)$ — скорость изменения этого наклона.

Определение для этой лекции

Локальной кривизной одномерной функции в точке x будем называть величину

$$f''(x).$$

Для функции многих переменных кривизну будем измерять **в выбранном направлении** через вторую производную соответствующего одномерного сечения.

Например,

$$f_1(x) = x^2, \quad f_2(x) = -x^2,$$

и в точке 0 обе функции имеют нулевой наклон, но

$$f_1''(0) = 2 > 0, \quad f_2''(0) = -2 < 0.$$



Квадратичная модель видит изгиб функции

При малом h


$$f(x+h) \approx f(x) + f'(x)h + \frac{1}{2}f''(x)h^2.$$

Два уровня информации

$f'(x)h$ задаёт касательную — локальный наклон.


$\frac{1}{2}f''(x)h^2$ позволяет модели изгибаться и учитывать изменение наклона.

На рисунке линейная и квадратичная модели совпадают с e^t в точке 0, но второй порядок заметно лучше повторяет изгиб функции рядом с ней.





Что заменит f' и f'' в нескольких измерениях?



Сначала разберём первый порядок. Ответом будет **градиент**.



Поверхность и линии уровня — два взгляда на одну функцию

Рассмотрим

$$f(x_1, x_2) = x_1^2 + 2x_2^2.$$


Поверхность

Высота над точкой (x_1, x_2) равна значению $f(x_1, x_2)$.

Линия уровня

Контур $f(x_1, x_2) = c$ соединяет точки одной высоты. Для этой функции такие контуры — эллипсы.

По линиям уровня удобно видеть геометрию оптимизации сверху, не рисуя третью координату.





Частная производная: меняем одну координату

Для

$$f(x_1, \dots, x_d)$$

частная производная

$$\frac{\partial f}{\partial x_i}(x)$$

показывает локальное изменение функции, если мы двигаем только координату x_i .

Пример

Для

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

получаем

$$\frac{\partial f}{\partial x_1} = 2x_1, \quad \frac{\partial f}{\partial x_2} = 4x_2.$$



Градиент собирает все частные производные вместе

Определение

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_d}(x) \end{pmatrix}$$

То есть

$$\nabla f(x) \in \mathbb{R}^d.$$

Градиент — не число, а вектор той же размерности, что и параметры x .



Первый пример градиента

Для

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

имеем

$$\nabla f(x_1, x_2) = \begin{pmatrix} 2x_1 \\ 4x_2 \end{pmatrix}.$$

В точке $(1, 1)$:

$$\nabla f(1, 1) = \begin{pmatrix} 2 \\ 4 \end{pmatrix}.$$

Через несколько слайдов мы поймём, что именно геометрически означает эта стрелка $(2, 4)$.



Градиент зависит от точки

Для функции

$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

имеем

$$\nabla f(x_1, x_2) = (2x_1, 4x_2).$$

Поэтому


$$\nabla f(1, 1) = (2, 4),$$

$$\nabla f(-1, 1) = (-2, 4).$$

Важно

Градиент зависит от точки: это **поле направлений**, а не один фиксированный вектор.

Одна функция, разные точки — разные градиенты





Дифференцируемость в $\mathbb{R}^d$: формальная локальная модель

Определение

Функция $f : \mathbb{R}^d \rightarrow \mathbb{R}$ называется **дифференцируемой в точке** x , если существует вектор $g \in \mathbb{R}^d$ такой, что

$$f(x + h) = f(x) + g^\top h + o(\|h\|), \quad h \rightarrow 0.$$

Такой вектор g единственен и равен градиенту:

$$g = \nabla f(x).$$

Почему его компоненты — частные производные?

Подставим $h = te_i$. Тогда

$$\frac{f(x + te_i) - f(x)}{t} = g_i + o(1),$$

и при $t \rightarrow 0$ получаем $g_i = \frac{\partial f}{\partial x_i}(x)$.



Главная формула первого порядка

Для малого вектора h :

$$f(x + h) \approx f(x) + \nabla f(x)^\top h.$$

Как читать эту формулу

- h говорит, куда мы собираемся двигаться;
- $\nabla f(x)$ описывает локальный наклон функции;
- $\nabla f(x)^\top h$ предсказывает изменение f .

Это многомерный аналог $f(x + h) \approx f(x) + f'(x)h$.



Почему возникает скалярное произведение?

При малом движении h изменение функции примерно равно

$$\Delta f \approx \nabla f(x)^\top h.$$

Вспомним:

$$\nabla f(x)^\top h = \|\nabla f(x)\| \|h\| \cos \theta.$$

Следствие

Не только длина шага, но и **угол между h и градиентом** определяет, растёт функция или убывает.



Направленная производная

Пусть v — направление. Рассмотрим движение по прямой

$$x(t) = x + tv.$$

Определение

Направленная производная — обычная производная функции вдоль этой прямой:

$$D_v f(x) = \lim_{t \rightarrow 0} \frac{f(x + tv) - f(x)}{t}.$$

Если $\|v\| = 1$, то $D_v f(x)$ можно интерпретировать как скорость изменения функции на единицу пройденного расстояния.



Направленная производная через градиент

Утверждение

Если f дифференцируема в точке x , то для любого направления v

$$D_v f(x) = \nabla f(x)^\top v.$$

Доказательство

Из дифференцируемости при $h = tv$:

$$f(x + tv) = f(x) + t \nabla f(x)^\top v + o(|t|).$$

Следовательно,

$$\frac{f(x + tv) - f(x)}{t} = \nabla f(x)^\top v + o(1).$$

Переходя к пределу при $t \rightarrow 0$, получаем требуемую формулу. $\square$



Небольшая задача: изменение в двух направлениях

Пусть в некоторой точке

$$\nabla f(x) = (3, 4).$$

Что происходит при движении в направлениях

$$v_1 = (1, 0), \quad v_2 = (0, -1)?$$

$$D_{v_1}f(x) = 3, \quad D_{v_2}f(x) = -4.$$

Вывод

В направлении v_1 функция локально растёт, а в направлении v_2 — убывает.



В каком направлении функция растёт быстрее всего?

Теорема о направлении наискорейшего роста

Пусть f дифференцируема в точке x и $\nabla f(x) \neq 0$. Среди всех единичных направлений $\|v\| = 1$

$$\max_{\|v\|=1} D_v f(x) = \|\nabla f(x)\|,$$

причём максимум достигается при

$$v_+ = \frac{\nabla f(x)}{\|\nabla f(x)\|}.$$

А минимум равен $-\|\nabla f(x)\|$ и достигается при $v_- = -v_+$.

То есть градиент и антиградиент решают две маленькие оптимизационные задачи по выбору направления.



Доказательство теоремы о наискорейшем росте

Доказательство теоремы

По формуле направленной производной и неравенству Коши–Буняковского

$$D_v f(x) = \nabla f(x)^\top v \leq \|\nabla f(x)\| \|v\| = \|\nabla f(x)\|.$$

При

$$v = v_+ = \frac{\nabla f(x)}{\|\nabla f(x)\|}$$

получаем равенство:

$$D_{v_+} f(x) = \|\nabla f(x)\|.$$

Для $v_- = -v_+$ аналогично

$$D_{v_-} f(x) = -\|\nabla f(x)\|.$$

Следовательно, v_+ и v_- действительно дают максимальный рост и максимальное убывание. $\square$

Само неравенство Коши–Буняковского используем без доказательства.



Градиент — направление максимального локального роста

Из доказанной теоремы следует

$\nabla f(x)$ задаёт направление максимального локального роста,

а

$-\nabla f(x)$ задаёт направление максимального локального убывания.

Важно про слово «локального»

Теорема сравнивает только мгновенные скорости изменения функции в текущей точке x . Она ничего не утверждает о положении глобального минимума.

Если $\nabla f(x) = 0$, то все направленные производные первого порядка равны нулю, и первого порядка уже недостаточно.



Для уменьшения функции идём против градиента

Если градиент указывает направление самого быстрого роста, то

$$-\nabla f(x)$$

указывает направление самого быстрого локального убывания.

Отсюда естественным образом появляется формула

$$x_{k+1} = x_k - \alpha \nabla f(x_k).$$

Но сегодня этого недостаточно

Мы поняли, **откуда берётся направление**. Позже отдельно разберём, при каких α функция действительно убывает и когда последовательность сходится.



Градиент не «показывает на минимум»

Правильное утверждение:

$$-\nabla f(x)$$


даёт направление наибольшего **локального** убывания среди направлений одинаковой длины.

Глобальный минимум может находиться совсем в другом направлении: поверхность может иметь изогнутую долину.

Ключевое слово

локально

Локально лучший шаг не обязан вести прямо к минимуму





Линии уровня и градиент

Линия уровня — множество точек, в которых функция принимает одно значение:

$$\{x : f(x) = c\}.$$

Для


$$f(x_1, x_2) = x_1^2 + 2x_2^2$$

получаем семейство эллипсов.

На рисунке отмечены:

- несколько уровней $f(x) = c$;
- точка x ;
- градиент $\nabla f(x)$;
- касательное направление к линии уровня.

Следующий слайд объяснит, почему эти два направления перпендикулярны.





Почему градиент перпендикулярен линии уровня?

Утверждение

Пусть $f : \mathbb{R}^d \rightarrow \mathbb{R}$ дифференцируема, а гладкая кривая $\gamma(t)$ лежит на линии уровня $f = c$ и проходит через точку x :

$$\gamma(0) = x, \quad f(\gamma(t)) \equiv c.$$

Тогда касательный вектор $v = \gamma'(0)$ ортогонален градиенту:

$$\nabla f(x)^\top v = 0.$$

Доказательство

Так как $f(\gamma(t))$ постоянно, его производная равна нулю. По правилу цепочки

$$0 = \left. \frac{d}{dt} f(\gamma(t)) \right|_{t=0} = \nabla f(\gamma(0))^\top \gamma'(0) = \nabla f(x)^\top v.$$

Значит, $\nabla f(x) \perp v$. $\square$





Одинаковый минимум — разная геометрия

Сравним

$$f_1(x) = x_1^2 + x_2^2, \quad f_2(x) = x_1^2 + 10x_2^2.$$

Обе функции минимальны в $(0, 0)$, но их линии уровня имеют совершенно разную форму.



Вопрос на будущее

Почему по узкой вытянутой долине градиентному методу обычно двигаться труднее? Ответ дадут спектр и обусловленность.



От наклона к кривизне в разных направлениях

В $\mathbb{R}^d$ направлений бесконечно много, поэтому одного числа $f''(x)$ уже нет.

Определение направленной кривизны

Выберем направление v и одномерное сечение

$$\varphi(t) = f(x + tv).$$

Если $\varphi''(0)$ существует, будем называть

$$\kappa_v(x) := \varphi''(0)$$

кривизной функции f в точке x вдоль направления v .

Следующий вопрос: как вычислить $\kappa_v(x)$ сразу по многомерной функции, не выписывая каждое сечение отдельно?



Определение

Матрица вторых производных функции $f : \mathbb{R}^d \rightarrow \mathbb{R}$ называется гессианом:

$$\nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{pmatrix}.$$

Гессиан имеет размер $d \times d$.



Откуда берётся симметрия гессиана?

В позиции (i, j) гессиана стоит смешанная производная

$$\frac{\partial^2 f}{\partial x_i \partial x_j},$$

а в симметричной позиции (j, i) —

$$\frac{\partial^2 f}{\partial x_j \partial x_i}.$$

Если эти величины совпадают для всех пар i, j , то автоматически

$$\nabla^2 f(x) = \nabla^2 f(x)^\top.$$

Но совпадают ли они всегда?

Нет без дополнительных предположений. На следующем слайде сформулируем стандартное достаточное условие, которым будем пользоваться в курсе.



Теорема о равенстве смешанных производных

Теорема Шварца–Клеро

Пусть функция f имеет вторые частные производные в некоторой окрестности точки x , и смешанные производные непрерывны в этой окрестности. Тогда для любых i, j

$$\frac{\partial^2 f}{\partial x_i \partial x_j}(x) = \frac{\partial^2 f}{\partial x_j \partial x_i}(x).$$

Удобное следствие

Если $f \in C^2$ (все частные производные до второго порядка существуют и непрерывны), то её гессиан симметричен во всех точках:

$$\nabla^2 f(x) = \nabla^2 f(x)^\top.$$

Доказательство теоремы в этом курсе не требуется. Для нас важен вывод: у достаточно гладкой целевой функции гессиан — симметричная матрица, поэтому к нему применима спектральная геометрия.



Пример вычисления гессиана

Пусть

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2.$$

Сначала

$$\nabla f(x) = \begin{pmatrix} 2x_1 + 3x_2 \\ 3x_1 + 4x_2 \end{pmatrix}.$$

Теперь дифференцируем компоненты градиента:

$$\nabla^2 f(x) = \begin{pmatrix} 2 & 3 \\ 3 & 4 \end{pmatrix}.$$

Для квадратичной функции гессиан не зависит от точки.



Кривизна вдоль направления = вторая производная сечения

Утверждение

Пусть $f \in C^2$. Для

$$\varphi(t) = f(x + tv)$$


выполнено

$$\varphi''(0) = v^T \nabla^2 f(x) v.$$

Именно поэтому квадратичная форма

$$v^T \nabla^2 f(x) v$$

интерпретируется как локальная кривизна вдоль v .





Доказательство формулы направленной кривизны

Пусть $v = (v_1, \dots, v_d)^\top$ и $\varphi(t) = f(x + tv)$. По правилу цепочки

$$\varphi'(t) = \sum_{i=1}^d \frac{\partial f}{\partial x_i}(x + tv) v_i.$$

Дифференцируем ещё раз:

$$\varphi''(t) = \sum_{i=1}^d \sum_{j=1}^d \frac{\partial^2 f}{\partial x_j \partial x_i}(x + tv) v_j v_i.$$

Это ровно матричная запись

$$\varphi''(t) = v^\top \nabla^2 f(x + tv) v.$$

Подставляя $t = 0$, получаем

$$\boxed{\varphi''(0) = v^\top \nabla^2 f(x) v.} \quad \square$$



Главная формула второго порядка

Формула Тейлора второго порядка

Если $f \in C^2$ в окрестности точки x , то при $h \rightarrow 0$

$$f(x + h) = f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h + o(\|h\|^2).$$

Первый порядок

$\nabla f(x)^\top h$ описывает локальный наклон.

Доказательство многомерной формулы Тейлора в этом курсе используем без вывода.

Второй порядок

$\frac{1}{2} h^\top \nabla^2 f(x) h$ описывает изменение наклона, то есть локальную кривизну.



Положительная кривизна: локальная «чаша»

Определение

Симметричная матрица H называется **положительно определённой**, если

$$v^T H v > 0 \quad \text{для любого } v \neq 0.$$

Обозначение:

$$H \succ 0.$$

Если $H = \nabla^2 f(x) \succ 0$, то кривизна функции положительна во всех направлениях: каждое одномерное сечение локально изгибается вверх.


Геометрический образ

Второй порядок вокруг точки имеет форму локальной «чаши».




Три типа локальной кривизны

$$H \succ 0$$




Кривизна положительна во всех направлениях: локальная чаша.

$$H \prec 0$$



Кривизна отрицательна во всех направлениях: локальный купол.

H неопределён



Есть направления обоих знаков: седловая геометрия.

Знак $v^T H v$ отвечает на вопрос, вверх или вниз изгибается одномерное сечение поверхности вдоль конкретного направления v .



Что происходит в стационарной точке?

Пусть

$$\nabla f(x^*) = 0.$$

Тогда линейная часть исчезает, и локально

$$f(x^* + h) \approx f(x^*) + \frac{1}{2}h^\top Hh, \quad H = \nabla^2 f(x^*).$$

Значит

Чтобы понять тип стационарной точки, надо понять знак квадратичной формы $h^\top Hh$.

Следующий инструмент — собственные значения симметричной матрицы H .



Квадратичная форма на самом простом примере

Пусть

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}.$$

Тогда

$$q(x) = x^T A x = 2x_1^2 + 5x_2^2.$$

Что видно сразу?

- вдоль оси x_1 коэффициент кривизны равен 2;
- вдоль оси x_2 коэффициент кривизны равен 5;
- во второй координате функция растёт быстрее.



Собственный вектор: направление, которое матрица не поворачивает


Определение

Ненулевой вектор v называется **собственным вектором** матрицы A , если существует число λ такое, что

$$Av = \lambda v.$$

Число λ называется соответствующим **собственным значением**.

Матрица не уводит такой вектор с его прямой: меняется только масштаб, а при $\lambda < 0$ ещё и ориентация.





Диагональная матрица: собственные направления уже видны

Для

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}$$

имеем

$$A \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 2 \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad A \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 5 \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Поэтому собственные значения равны

$$\lambda_1 = 2, \quad \lambda_2 = 5.$$

Интерпретация для квадратичной формы

Собственные значения измеряют кривизну в главных направлениях.



Почему симметричные матрицы особенно удобны

Для любой вещественной симметричной матрицы $A = A^T$ существует ортонормированный базис собственных векторов

$$v_1, \dots, v_d.$$

То есть

$$v_i^T v_j = 0 \quad (i \neq j), \quad \|v_i\| = 1.$$

Спектральная теорема — геометрически

У симметричной матрицы есть взаимно перпендикулярные **главные направления**, вдоль которых она действует просто как растяжение на λ_j .

Доказательство спектральной теоремы в этом курсе нам не понадобится.



Квадратичная форма в собственных координатах

Разложим вектор по ортонормированным собственным векторам:

$$x = \sum_{i=1}^d z_i v_i.$$

Тогда

$$x^{\top} A x = \sum_{i=1}^d \lambda_i z_i^2.$$

Почему это удобно?

Сложная квадратичная форма после поворота координат превращается в сумму независимых квадратов.

Именно поэтому знаки собственных значений полностью определяют знак квадратичной формы.



Знаки собственных значений и тип кривизны

Для симметричной матрицы A :

$\lambda_i > 0$ для всех i

$$x^T A x > 0$$

для $x \neq 0$.

$A \succ 0$.

$\lambda_i < 0$ для всех i

$$x^T A x < 0$$

для $x \neq 0$.

$A \prec 0$.

Есть разные знаки

В одних направлениях форма
положительна, в других
отрицательна.

Седловая геометрия.



Критерий второго порядка для стационарной точки

Теорема: достаточное условие строгого локального минимума

Пусть $f \in C^2$ в окрестности x^* , $\nabla f(x^*) = 0$ и

$$H := \nabla^2 f(x^*) \succ 0.$$

Тогда x^* — строгий локальный минимум функции f .

Другие знаки гессиана

Если $H \prec 0$, то x^* — строгий локальный максимум. Если у H есть собственные значения разных знаков, то x^* — седловая точка.

Нулевые собственные значения

Если H лишь полуопределён, критерий второго порядка может не дать ответа.



Доказательство достаточного условия минимума

Пусть $\lambda_{\min} > 0$ — наименьшее собственное значение H . Тогда для любого h

$$h^T H h \geq \lambda_{\min} \|h\|^2.$$

По формуле Тейлора и условию $\nabla f(x^*) = 0$

$$f(x^* + h) - f(x^*) = \frac{1}{2} h^T H h + o(\|h\|^2).$$

По определению $o(\|h\|^2)$ для достаточно малых h имеем

$$|o(\|h\|^2)| \leq \frac{1}{4} \lambda_{\min} \|h\|^2.$$

Поэтому при $h \neq 0$

$$f(x^* + h) - f(x^*) \geq \frac{1}{2} \lambda_{\min} \|h\|^2 - \frac{1}{4} \lambda_{\min} \|h\|^2 = \frac{1}{4} \lambda_{\min} \|h\|^2 > 0.$$

Следовательно, x^* — строгий локальный минимум. $\square$



Почему две похожие задачи могут быть очень разными

Сравним

$$f_1(x) = x_1^2 + x_2^2, \quad f_2(x) = x_1^2 + 100x_2^2.$$

У обеих функций

$$\arg \min f = \{(0, 0)\}.$$

Но спектры гессианов различаются:

$$\nabla^2 f_1 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \quad \nabla^2 f_2 = \begin{pmatrix} 2 & 0 \\ 0 & 200 \end{pmatrix}.$$

Вопрос следующей лекции

Почему разница между маленькой и большой кривизной влияет на трудность оптимизации?



Две локальные модели, которые надо унести с собой

Первый порядок

$$f(x + h) \approx f(x) + \nabla f(x)^\top h.$$

Градиент говорит, как функция меняется при малом движении.

Второй порядок

$$f(x + h) \approx f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h.$$

Гессиан добавляет информацию о кривизне.



Что нужно уметь после сегодняшней лекции

1. Вычислить градиент и гессиан простой функции нескольких переменных.
2. Интерпретировать $\nabla f(x)^\top v$ как скорость изменения функции в направлении v .
3. Объяснить, почему $-\nabla f(x)$ — направление максимального локального убывания.
4. Интерпретировать $v^\top \nabla^2 f(x) v$ как кривизну вдоль направления.
5. По знакам собственных значений гессиана понять локальную геометрию стационарной точки.

Следующая лекция

Квадратичные задачи оптимизации и их геометрия: спектр, обусловленность и почему некоторые долины намного труднее других.