


Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

# Методы оптимизации в машинном обучении

## Лекция 3. Квадратичная оптимизация: геометрия, спектр и точное решение

Никита Лукьяненко

# От локальной геометрии — к точному классу задач

На прошлой лекции мы получили локальную квадратичную модель

$$f(x+h) \approx f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h.$$

### Первый порядок

$$\nabla f(x)$$

описывает локальный наклон.

### Второй порядок

$$\nabla^2 f(x)$$

описывает локальную кривизну.

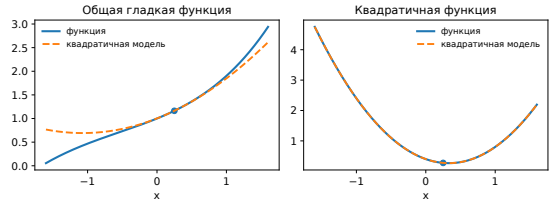
Сегодня рассмотрим класс функций, для которых квадратичная модель описывает функцию **точно**.

# Когда квадратичное приближение становится точным?

Для общей гладкой функции формула второго порядка лишь приближает поведение около выбранной точки.

Для квадратичной функции остатка нет:

$$f(x+h) = f(x) + \nabla f(x)^\top h + \frac{1}{2} h^\top \nabla^2 f(x) h.$$




## Почему это удобно?

Мы можем полностью понять геометрию задачи, а затем использовать её как модель для более общих функций.

# Почему квадратичные задачи важны?

### 1. Их можно исследовать полностью

Условия существования и единственности решения выражаются через спектр одной матрицы.

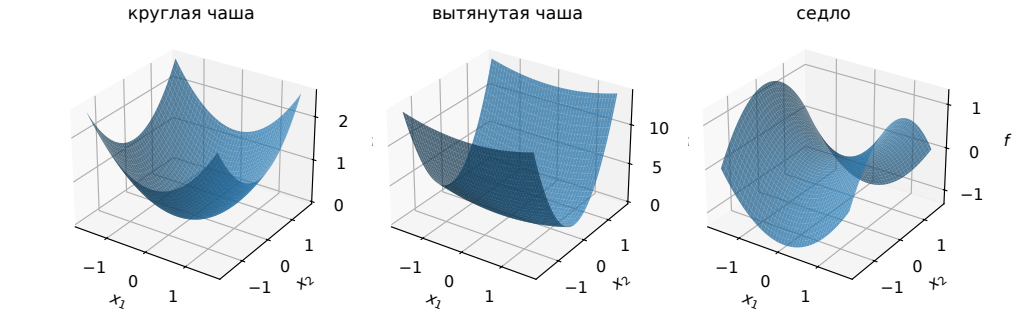
### 2. Они описывают локальную геометрию

Около точки минимума гладкая функция во втором порядке выглядит квадратично.

### 3. Они возникают непосредственно в машинном обучении

Метод наименьших квадратов — классический пример квадратичной оптимизации.

# Одна формула — очень разная геометрия




## Главный вопрос лекции

Как по матрице квадратичной функции заранее понять, какая геометрия перед нами?

# Квадратичная функция

## Определение

Функция

$$\boxed{f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \qquad x \in \mathbb{R}^d}$$

называется квадратичной, где

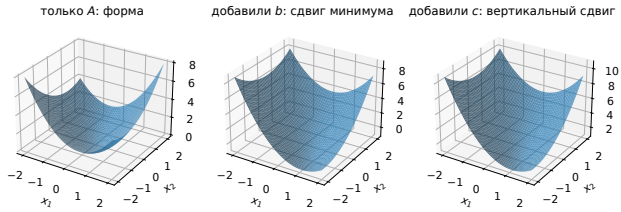
$$A \in \mathbb{R}^{d \times d}, \qquad b \in \mathbb{R}^d, \qquad c \in \mathbb{R}.$$

Матрица $A$ будет отвечать за кривизну и форму поверхности; $b$ — за положение её центра; $c$ — за вертикальный сдвиг.

# Что делает каждый член?

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c.$$

- $A$ задаёт **форму**;
- $b$ сдвигает оптимум;
- $c$ не меняет оптимум вообще.




## Важно

Изменяя $b$ и $c$, мы не меняем гессиан квадратичной функции.

# Зачем перед квадратичной формой ставят $1/2$?

Множитель $1/2$ не меняет сути задачи. Он выбран ради удобства производных.

В одном измерении:

$$\frac{d}{dx}\left(\frac{1}{2}ax^2\right) = ax.$$

В нескольких измерениях при симметричной $A$ аналогично:

$$\nabla\left(\frac{1}{2}x^\top Ax\right) = Ax.$$

Соглашение

В оптимизации запись $\frac{1}{2}x^\top Ax$ используется очень часто именно потому, что она убирает лишнюю двойку из градиента.

# Обязательно ли считать $A$ симметричной?

Любую квадратную матрицу можно разложить как

$$A = \underbrace{\frac{A + A^\top}{2}}_{S} + \underbrace{\frac{A - A^\top}{2}}_{K},$$

где

$$S^\top = S, \qquad K^\top = -K.$$

## Вопрос

Может ли кососимметричная часть $K$ влиять на величину $x^\top Ax$?

На следующем слайде ответим на этот вопрос формально.

# Кососимметричная часть не влияет на квадратичную форму

## Утверждение

Если $K^\top = -K$, то для любого $x \in \mathbb{R}^d$

$$\boxed{x^\top K x = 0.}$$

## Доказательство

Величина $x^\top K x$ — число, поэтому она совпадает со своим транспонированием:

$$x^\top K x = (x^\top K x)^\top = x^\top K^\top x.$$

Но $K^\top = -K$, следовательно,

$$x^\top K x = -x^\top K x.$$

Значит,

$$2x^\top K x = 0,$$

что и требовалось доказать.

# Поэтому можно считать $A$ симметричной

Из разложения $A = S + K$ и предыдущего утверждения получаем

$$x^\top Ax = x^\top Sx + x^\top Kx = x^\top Sx.$$

Следовательно,

$$\boxed{x^\top Ax = x^\top \frac{A + A^\top}{2} x.}$$

## Вывод

Для квадратичной оптимизации несимметричная часть матрицы не видна вообще. Поэтому дальше без ограничения общности считаем

$$\boxed{A = A^\top.}$$

# Пример в $\mathbb{R}^2$

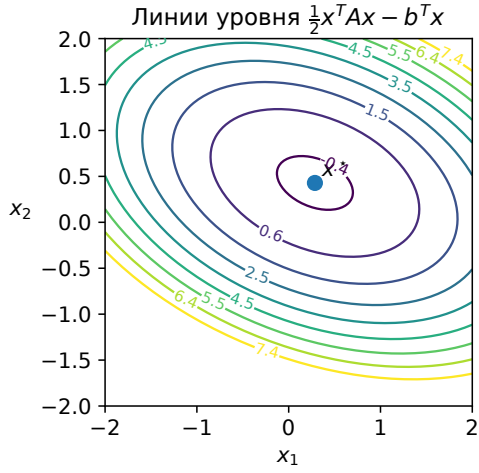
Пусть

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 4 \end{pmatrix}, \qquad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

Тогда при $c = 0$

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2} x^\top A x - b^\top x \\ &= x_1^2 + x_1 x_2 + 2x_2^2 - x_1 - 2x_2. \end{aligned}$$

Линии уровня уже дают важную информацию о форме задачи.



# Самопроверка: восстановите матричную запись

Рассмотрим

$$f(x, y) = 3x^2 - 2xy + y^2 + 4x - 6y + 7.$$

Представьте её в форме

$$f(z) = \frac{1}{2} z^\top A z - b^\top z + c, \qquad z = \begin{pmatrix} x \\ y \end{pmatrix}.$$

## Вопросы

Каковы $A$, $b$ и $c$? Почему коэффициент перед $xy$ нужно особенно внимательно сопоставлять с матрицей?

**На обсуждение: около минуты.**

# Градиент квадратичной формы

## Утверждение

Пусть $A = A^\top$. Тогда

$$\boxed{\nabla \left( \frac{1}{2} x^\top A x \right) = Ax.}$$

Это многомерный аналог знакомой формулы

$$\frac{d}{dx} \left( \frac{1}{2} a x^2 \right) = ax.$$

## Почему доказательство полезно?

Оно показывает, как аккуратно работать с индексами и где именно используется симметрия $A$.

# Доказательство формулы для градиента

Запишем

$$\frac{1}{2}x^\top Ax = \frac{1}{2}\sum_{i=1}^{d}\sum_{j=1}^{d} A_{ij}x_i x_j.$$

Для $k$-й координаты градиента

$$\frac{\partial}{\partial x_k}\left(\frac{1}{2}x^\top Ax\right) = \frac{1}{2}\sum_{j=1}^{d} A_{kj}x_j + \frac{1}{2}\sum_{i=1}^{d} A_{ik}x_i.$$

Так как $A_{ik} = A_{ki}$,

$$\frac{\partial}{\partial x_k}\left(\frac{1}{2}x^\top Ax\right) = \sum_{j=1}^{d} A_{kj}x_j = (Ax)_k.$$

Это верно для всех $k$, поэтому

$$\boxed{\nabla\left(\frac{1}{2}x^\top Ax\right) = Ax.}$$

# Линейный и постоянный члены

Для линейного члена

$$b^\top x = \sum_{i=1}^{d} b_i x_i,$$

поэтому

$$\nabla(b^\top x) = b.$$

Следовательно,

$$\nabla(-b^\top x) = -b.$$

А постоянный член не зависит от $x$:

$$\nabla c = 0.$$

## Итого

Для квадратичной функции остаётся только сложить три простых результата.

# Главная формула: градиент квадратичной функции

Для

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \qquad A = A^\top,$$

получаем

$$\boxed{\nabla f(x) = Ax - b.}$$

## Обратите внимание

Градиент линейно зависит от текущей точки $x$. Это сделает анализ градиентного спуска на следующей лекции почти полностью алгебраическим.

# Гессиан ещё проще

Поскольку

$$\nabla f(x) = Ax - b,$$

ещё одно дифференцирование даёт

$$\boxed{\nabla^2 f(x) = A.}$$

**Ключевая особенность**

Гессиан квадратичной функции не зависит от точки $x$. Кривизна поверхности одинакова везде.

# У общей функции кривизна меняется, у квадратичной — нет

В одном измерении кривизну отражает вторая производная.

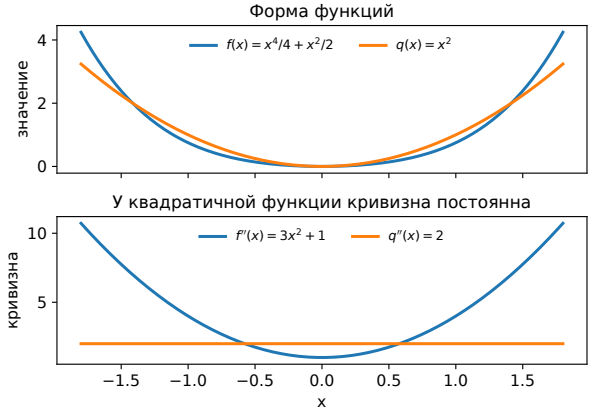
Для общей функции:

$$f''(x) \text{ зависит от } x.$$

Для квадратичной:

$$q''(x) = \text{const}.$$

В многомерном случае роль второй производной играет матрица $\nabla^2 f(x)$.



# Кривизна вдоль направления

С прошлой лекции мы знаем: для единичного направления $v$

$$\frac{d^2}{dt^2} f(x + tv)\Big|_{t=0} = v^\top \nabla^2 f(x) v.$$

Для квадратичной функции

$$\boxed{\kappa(v) = v^\top A v.}$$

## Что особенно удобно

Эта величина зависит от направления $v$, но **не зависит от точки** $x$.

Теперь вопрос о геометрии функции превращается в вопрос о квадратичной форме $v^\top A v$.

# Начнём с диагональной матрицы

Пусть

$$A = \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}.$$

Тогда

$$f(x) = \frac{1}{2} x^\top A x = \frac{1}{2} \left( \lambda_1 x_1^2 + \lambda_2 x_2^2 \right).$$

## Преимущество диагонального случая

Координаты не взаимодействуют: вклад каждого направления виден отдельно.

Именно к такой форме мы сведём произвольную симметричную матрицу с помощью собственных векторов.

# Если собственные значения одинаковы

При

$$A = I$$

имеем

$$f(x) = \frac{1}{2}(x_1^2 + x_2^2).$$

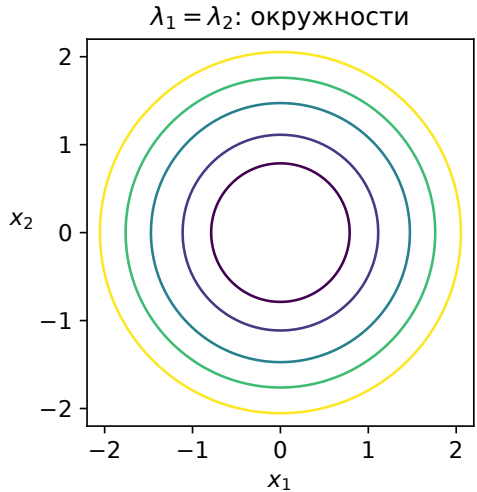
Линия уровня $f(x) = C$ задаётся условием

$$x_1^2 + x_2^2 = 2C,$$

то есть является окружностью.

## Геометрия

Кривизна одинакова во всех направлениях.



# Если собственные значения различаются

Для

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 10 \end{pmatrix}$$

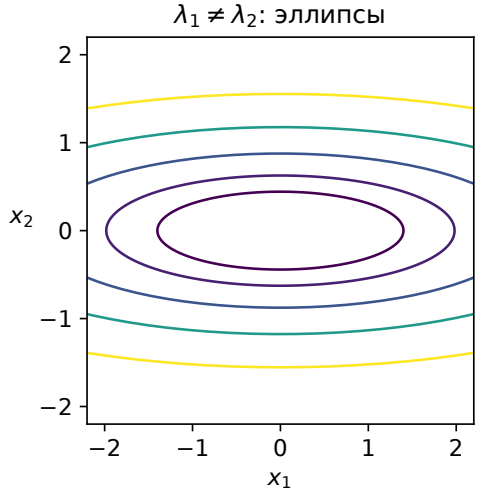
получаем

$$f(x) = \frac{1}{2}(x_1^2 + 10x_2^2).$$

Линии уровня становятся эллипсами.

## Интуиция

В направлении $x_2$ функция растёт значительно быстрее, поэтому допустимое отклонение по этой координате меньше.



# Что означает большое собственное значение?

Если $v_i$ — собственный вектор с собственным значением $\lambda_i$, то

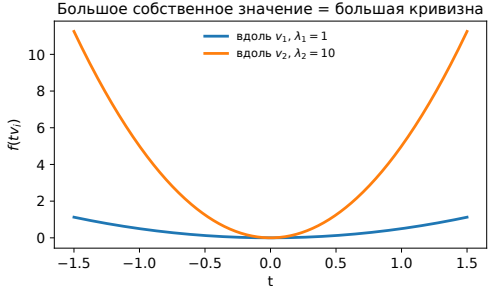
$$Av_i = \lambda_i v_i.$$

Рассмотрим движение только вдоль этого направления: $x = tv_i$. Для $\|v_i\| = 1$

$$f(tv_i) = \frac{1}{2} t^2 v_i^\top A v_i = \frac{1}{2} \lambda_i t^2.$$

## Вывод

Чем больше $\lambda_i$, тем сильнее функция изгибается и быстрее растёт вдоль направления $v_i$.



# Недиагональная матрица просто поворачивает главные оси

Например,

$$A = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}.$$

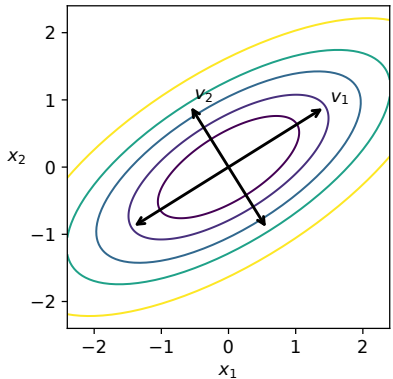
Линии уровня по-прежнему эллипсы, но их оси уже не совпадают с координатными осями.

## Новый вопрос

Как найти естественные направления, вдоль которых квадратичная функция снова выглядит как сумма независимых квадратов?

Ответ — собственные векторы $A$.

Главные оси эллипса = собственные направления



# Спектральная теорема для симметричной матрицы

## Теорема

Если $A = A^\top$, то существует ортогональная матрица $Q$ и диагональная матрица $\Lambda$, такие что

$$\boxed{A = Q\Lambda Q^\top,}$$

где столбцы $Q$ — ортонормированные собственные векторы $A$, а

$$\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_d).$$

## На этой лекции

Спектральную теорему используем без доказательства. Нас интересуют её последствия для оптимизации.

# Переходим в собственные координаты

Положим

$$z = Q^\top x, \qquad \text{то есть} \qquad x = Qz.$$

Тогда

$$x^\top A x = z^\top Q^\top (Q \Lambda Q^\top) Q z = z^\top \Lambda z.$$

Следовательно,

$$\boxed{x^\top A x = \sum_{i=1}^{d} \lambda_i z_i^2.}$$

## Смысл

После поворота координат любая симметричная квадратичная форма становится суммой независимых одномерных квадратичных функций.

# Почему преобразование действительно является только поворотом?

Матрица $Q$ ортогональна:

$$Q^\top Q = I.$$

Поэтому она сохраняет длины:

$$\|Qz\|^2 = z^\top Q^\top Qz = \|z\|^2.$$

И сохраняет скалярные произведения:

$$(Qz_1)^\top (Qz_2) = z_1^\top z_2.$$

## Геометрическая интерпретация

Переход $x = Qz$ не растягивает пространство. Он лишь меняет ортонормированный базис так, чтобы его оси совпали с собственными направлениями $A$.

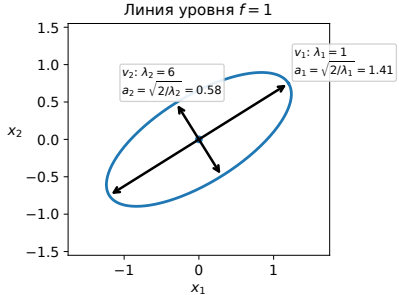
# Как из собственных значений увидеть форму линии уровня?

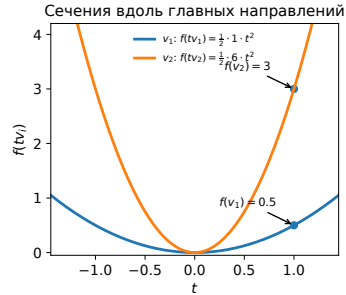
В собственных координатах возьмём

$$f(z) = \frac{1}{2}\left(z_1^2 + 6z_2^2\right), \qquad \lambda_1 = 1, \quad \lambda_2 = 6.$$

На линии уровня $f(z) = 1$

$$z_1^2 + 6z_2^2 = 2, \qquad a_1 = \sqrt{\frac{2}{\lambda_1}} = \sqrt{2}, \quad a_2 = \sqrt{\frac{2}{\lambda_2}} = \sqrt{\frac{1}{3}}.$$




**Вывод:** большее $\lambda_i$ означает более сильную кривизну вдоль $v_i$ и более короткую полуось линии уровня.

# Спектральные границы квадратичной формы

## Утверждение

Для симметричной $A$ и любого $x \in \mathbb{R}^d$

$$\boxed{\lambda_{\min}(A)\,\|x\|^2 \le x^\top A x \le \lambda_{\max}(A)\,\|x\|^2\,.}$$

## Доказательство

В собственных координатах $z = Q^\top x$:

$$x^\top A x = \sum_i \lambda_i z_i^2.$$

Так как $\lambda_{\min} \le \lambda_i \le \lambda_{\max}$,

$$\lambda_{\min} \sum_i z_i^2 \le \sum_i \lambda_i z_i^2 \le \lambda_{\max} \sum_i z_i^2.$$

Ортогональность $Q$ даёт $\|z\| = \|x\|$.

# Положительная определённость

## Определение

Симметричная матрица $A$ называется **положительно определённой**, если

$$\boxed{x^\top Ax > 0 \quad \text{для любого } x \neq 0.}$$

Обозначение:

$$A \succ 0.$$

Если допускается равенство нулю,

$$x^\top Ax \geq 0 \quad \forall x,$$

то $A$ называется положительно полуопределённой и пишут

$$A \succeq 0.$$

# Как проверить $A \succ 0$, не перебирая все направления?

Определение требует проверять знак $x^\top Ax$ для бесконечного множества векторов $x$. Для симметричной матрицы спектр превращает эту проверку в конечную.

## Спектральный критерий

Для симметричной матрицы $A$

$$\boxed{A \succ 0 \quad \Longleftrightarrow \quad \lambda_{\min}(A) > 0.}$$

То есть достаточно посмотреть на **наименьшее** собственное значение.

- $\lambda_{\min} > 0$ — положительно определённая чаша;
- $\lambda_{\min} = 0$ и отрицательных значений нет — есть плоские направления;
- $\lambda_{\min} < 0$ — существует направление отрицательной кривизны.

Следующий слайд — доказательство критерия.

# Доказательство спектрального критерия

Пусть сначала все $\lambda_i > 0$. В собственных координатах

$$x^\top A x = \sum_i \lambda_i z_i^2 .$$

Если $x \neq 0$, то и $z \neq 0$, поэтому хотя бы одно $z_i \neq 0$, а значит

$$x^\top A x > 0.$$

Следовательно, $A \succ 0$.

Теперь пусть $A \succ 0$. Возьмём собственный вектор $v_i \neq 0$:

$$A v_i = \lambda_i v_i .$$

Тогда

$$v_i^\top A v_i = \lambda_i \|v_i\|^2 .$$

Левая часть положительна, а $\|v_i\|^2 > 0$. Поэтому $\lambda_i > 0$.

$$\boxed{A \succ 0 \iff \lambda_i > 0 \ \forall i.}$$

# $A \succ 0$: единственная чашеобразная геометрия

Для

$$f(x) = \frac{1}{2} x^\top A x, \qquad A \succ 0,$$

имеем

$$f(x) > 0 \quad \text{при } x \neq 0, \qquad f(0) = 0.$$

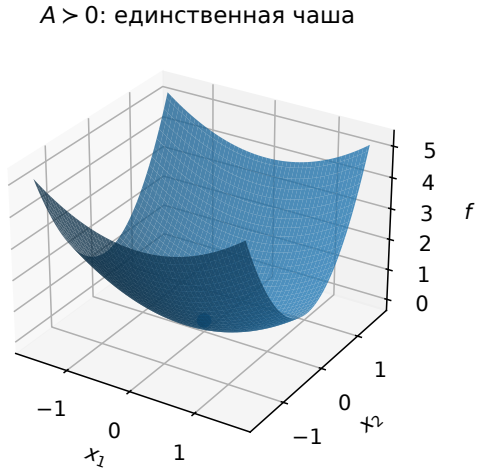
Поэтому

$$\boxed{x^\star = 0}$$

— единственный глобальный минимум.

## Геометрия

Во всех направлениях кривизна положительна: поверхность изгибается вверх.



# Отрицательное собственное значение разрушает ограниченность снизу

Пусть у $A$ есть собственный вектор $v$ с

$$Av = \lambda v, \qquad \lambda < 0.$$

Рассмотрим точки $x = tv$. Тогда

$$f(tv) = \frac{1}{2} t^2 v^\top Av = \frac{1}{2} \lambda t^2 \|v\|^2 .$$

Так как $\lambda < 0$,

$$f(tv) \longrightarrow -\infty \qquad \text{при } |t| \to \infty.$$

## Вывод

Если у квадратичной части есть отрицательное собственное значение, то чистая квадратичная функция $\frac{1}{2} x^\top Ax$ не ограничена снизу.

# Собственные значения разных знаков: седловая геометрия

Если существуют

$$\lambda_i > 0, \qquad \lambda_j < 0,$$

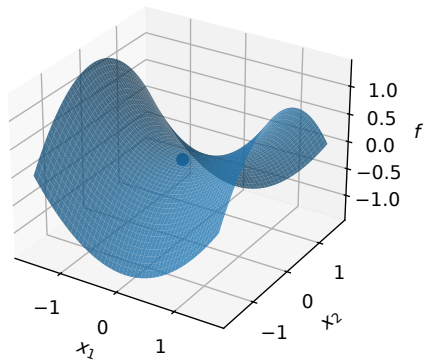
то в одном собственном направлении функция растёт вверх, а в другом — вниз.

## Следствие

Точка $x = 0$ стационарна для $\frac{1}{2} x^\top A x$, но не является ни минимумом, ни максимумом.

Такую точку называют седловой.

Собственные значения разных знаков: седло



# Полуопределённость: минимум может быть не единственным

Пусть

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}.$$

Тогда

$$f(x_1, x_2) = \frac{1}{2} x_1^2.$$

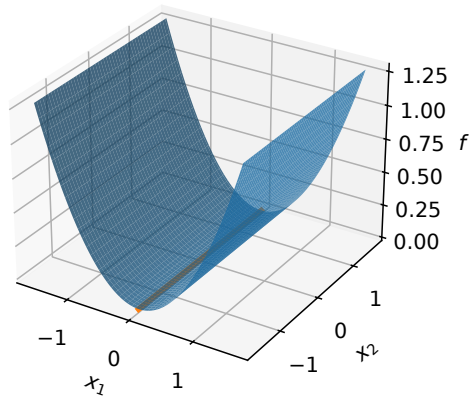
Минимальное значение равно нулю для всех точек

$$x_1 = 0.$$

## Важно

Нулевое собственное значение означает направление с нулевой кривизной. В этом направлении поверхность плоская.

$A \succcurlyeq 0$: минимум вдоль целой прямой



# Но при $A \succeq 0$ линейный член может всё изменить

Рассмотрим

$$f(x, y) = x^2 - y.$$

Её гессиан

$$\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \succeq 0.$$

Но при $y \to +\infty$

$$f(x, y) \to -\infty.$$

## Вывод

Положительная полуопределённость квадратичной части сама по себе ещё не гарантирует существование минимума, если присутствует линейный член.

Общий полуопределённый случай пока оставим за рамками курса. Для основной теории сосредоточимся на $A \succ 0$.



# Ищем минимум при $A \succ 0$

Для

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c$$

имеем

$$\nabla f(x) = Ax - b.$$

В точке внутреннего минимума необходимо

$$\nabla f(x^\star) = 0.$$

Следовательно,

$$\boxed{Ax^\star = b.}$$

То есть задача минимизации свелась к решению системы линейных уравнений.

# Точное решение

Если $A \succ 0$, то $A$ обратима. Поэтому из

$$Ax^\star = b$$

следует

$$\boxed{x^\star = A^{-1}b.}$$

Но есть важный практический нюанс

В вычислениях почти никогда не стоит явно находить $A^{-1}$. Обычно решают систему

$$Ax = b$$

специализированным численным методом.

Формула $A^{-1}b$ важна для теории, но не обязательно является хорошим алгоритмом.

# Почему положительно определённая матрица обратима?

## Утверждение

Если $A \succ 0$, то $A$ невырождена.

## Доказательство

Предположим, что

$$Ax = 0.$$

Тогда

$$x^\top Ax = x^\top 0 = 0.$$

Но положительная определённость требует

$$x^\top Ax > 0$$

для любого $x \neq 0$. Значит, равенство $Ax = 0$ возможно только при $x = 0$.
Следовательно,

$$\ker A = \{0\},$$

а значит $A$ обратима.

# Теорема о минимуме квадратичной функции

## Теорема

Пусть

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \qquad A = A^\top \succ 0.$$

Тогда $f$ имеет единственный глобальный минимум, причём

$$\boxed{x^\star = A^{-1} b.}$$

## Почему это сильнее условия $\nabla f = 0$?

Условие первого порядка само по себе говорит лишь о стационарности. Положительная определённость позволяет доказать и глобальность, и единственность минимума.

# Доказательство: дополняем до квадрата

Пусть $x^\star = A^{-1}b$, то есть $b = Ax^\star$. Рассмотрим разность

$$f(x) - f(x^\star).$$

Подставляя $b = Ax^\star$ и используя симметрию $A$, получаем

$$\begin{aligned} f(x) - f(x^\star) &= \frac{1}{2}x^\top Ax - (x^\star)^\top Ax + \frac{1}{2}(x^\star)^\top Ax^\star \\ &= \frac{1}{2}(x - x^\star)^\top A(x - x^\star). \end{aligned}$$

Так как $A \succ 0$,

$$(x - x^\star)^\top A(x - x^\star) > 0 \qquad \text{для } x \neq x^\star.$$

Следовательно,

$$f(x) > f(x^\star) \qquad \forall x \neq x^\star.$$

Значит, $x^\star$ — единственный глобальный минимум.

# Линейный член сдвигает минимум, но не меняет форму

При фиксированной $A \succ 0$

$$\nabla^2 f(x) = A$$

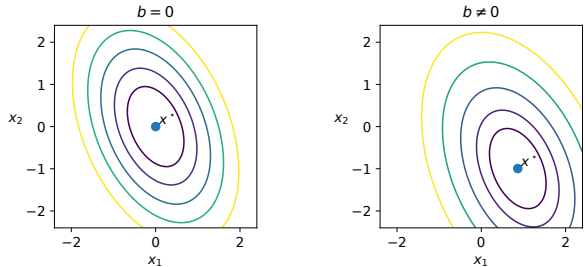
не зависит от $b$.
Но положение минимума

$$x^\star = A^{-1} b$$

зависит от $b$.

## Геометрически

$b$ передвигает центр эллиптической чаши, не меняя её главные направления и кривизну.



# Связь с линейной регрессией

В курсе машинного обучения вы уже работаете с задачей наименьших квадратов. Здесь посмотрим только на её **оптимизационную структуру**.

Пусть

$$X \in \mathbb{R}^{n \times d}, \qquad y \in \mathbb{R}^{n},$$

а предсказания имеют вид $Xw$.
Среднеквадратичная задача:

$$\boxed{\min_{w} \frac{1}{2} \|Xw - y\|^2 .}$$

Это квадратичная оптимизация по параметрам $w$.

# Разворачиваем квадрат нормы

Используем

$$\|Xw - y\|^2 = (Xw - y)^\top (Xw - y).$$

Тогда

$$\begin{aligned} f(w) &= \frac{1}{2}(Xw - y)^\top (Xw - y) \\ &= \frac{1}{2} w^\top X^\top X w - y^\top X w + \frac{1}{2} y^\top y. \end{aligned}$$

Сравним с общей формой

$$\frac{1}{2} w^\top A w - b^\top w + c.$$



# Матрица квадратичной задачи для линейной регрессии

Из предыдущего разложения:

$$\boxed{A = X^\top X,} \qquad \boxed{b = X^\top y,} \qquad \boxed{c = \frac{1}{2} y^\top y.}$$

Следовательно,

$$\boxed{\nabla f(w) = X^\top (Xw - y),}$$

$$\boxed{\nabla^2 f(w) = X^\top X.}$$

Оптимизационная геометрия линейной регрессии

Она полностью определяется спектром матрицы $X^\top X$.

# Почему $X^\top X$ всегда положительно полуопределена?

## Утверждение

Для любой матрицы $X$

$$X^\top X \succeq 0.$$

## Доказательство

Для любого $z \in \mathbb{R}^d$

$$z^\top X^\top X z = (Xz)^\top (Xz) = \|Xz\|^2 \geq 0.$$

Следовательно, по определению

$$\boxed{X^\top X \succeq 0.}$$

Это объясняет, почему функция наименьших квадратов никогда не имеет седловой квадратичной геометрии.

# Когда решение линейной регрессии единственно?

Для $X^\top X$ положительная определённость означает

$$z^\top X^\top X z = \|Xz\|^2 > 0 \qquad \forall z \neq 0.$$

Это эквивалентно условию

$$Xz \neq 0 \qquad \forall z \neq 0,$$

то есть

$$\ker X = \{0\}.$$

## Иными словами

Если столбцы $X$ линейно независимы, то $X^\top X \succ 0$ и решение единственно.

Тогда условие $\nabla f(w) = 0$ даёт нормальные уравнения

$$X^\top X w = X^\top y.$$

# Две задачи с одним минимумом могут быть очень разными

Рассмотрим

$$f_1(x) = \frac{1}{2}(x_1^2 + x_2^2),$$

$$f_2(x) = \frac{1}{2}(x_1^2 + 100x_2^2).$$

Обе функции:

- положительно определены;
- имеют единственный минимум в $x^\star = 0$;
- имеют очень простую явную формулу.

Но кривизна по разным направлениям во второй задаче отличается в 100 раз. Нужна численная характеристика этой неоднородности.

# Число обусловленности

## Определение

Для симметричной положительно определённой матрицы $A$ число

$$\boxed{\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}}$$

называется спектральным числом обусловленности.

Так как $0 < \lambda_{\min} \leq \lambda_{\max}$,

$$\kappa(A) \geq 1.$$

## Что именно измеряет $\kappa$?

Не общую “крутизну” функции, а **неравномерность кривизны по разным направлениям**.

Действительно, для любого $c > 0$

$$\kappa(cA) = \frac{c\lambda_{\max}(A)}{c\lambda_{\min}(A)} = \kappa(A).$$

# Число обусловленности — отношение экстремальных кривизн

## Утверждение

Если $A = A^\top \succ 0$, то

$$\max_{\|v\|=1} v^\top A v = \lambda_{\max}(A), \qquad \min_{\|v\|=1} v^\top A v = \lambda_{\min}(A).$$

Следовательно,

$$\boxed{\kappa(A) = \frac{\max\limits_{\|v\|=1} v^\top A v}{\min\limits_{\|v\|=1} v^\top A v}.}$$

## Доказательство

Из спектральных границ при $\|v\| = 1$:

$$\lambda_{\min} \le v^\top A v \le \lambda_{\max}.$$

Обе границы достигаются на собственных векторах $v_{\min}$ и $v_{\max}$.

# Число обусловленности точно задаёт вытянутость линии уровня

В собственных координатах

$$\frac{1}{2}\sum_i \lambda_i z_i^2 = c.$$

Полуось вдоль $v_i$ равна

$$a_i = \sqrt{\frac{2c}{\lambda_i}}.$$

Поэтому

$$\frac{a_{\max}}{a_{\min}} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \boxed{\sqrt{\kappa(A)}}.$$




## Точная геометрическая связь

Если $\kappa = 100$, то линия уровня вытянута по главным осям в $\sqrt{100} = 10$ раз.

# Большая кривизна сама по себе не означает плохую обусловленность

Сравним две матрицы:

$$A_1 = I, \qquad A_2 = 100I.$$

У второй функции кривизна во всех направлениях в 100 раз больше, но

$$\kappa(A_1) = 1, \qquad \kappa(A_2) = \frac{100}{100} = 1.$$

## Ключевой смысл

Хорошая обусловленность означает, что все главные направления имеют **сопоставимую** кривизну. Абсолютный масштаб собственных значений — другой вопрос.

## Самопроверка

Что хуже обусловлено: $A = 0.01I$ или $A = \mathrm{diag}(1, 100)$?

# Почему это называется “обусловленностью”?

Число $\kappa$ связано не только с формой линий уровня, но и с **чувствительностью решения** к небольшим изменениям задачи.
Пусть

$$x^\star = A^{-1} b,$$

а после возмущения $b \mapsto b + \delta b$ решение изменилось на

$$x^\star \mapsto x^\star + \delta x.$$

Тогда

$$A\,\delta x = \delta b.$$

## Оценка чувствительности

Для $b \neq 0$

$$\boxed{\frac{\|\delta x\|}{\|x^\star\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}.}$$

То есть большое $\kappa$ допускает сильное усиление относительной ошибки входных данных.

# Откуда берётся оценка чувствительности?

Из $A\delta x = \delta b$ получаем

$$\delta x = A^{-1}\delta b.$$

Собственные значения $A^{-1}$ равны $1/\lambda_i(A)$, поэтому

$$\|\delta x\| \leq \frac{1}{\lambda_{\min}(A)} \|\delta b\|.$$

С другой стороны,

$$\|b\| = \|Ax^\star\| \leq \lambda_{\max}(A) \|x^\star\|,$$

то есть

$$\frac{1}{\|x^\star\|} \leq \frac{\lambda_{\max}(A)}{\|b\|}.$$

Перемножая оценки,

$$\frac{\|\delta x\|}{\|x^\star\|} \leq \frac{\lambda_{\max}}{\lambda_{\min}} \frac{\|\delta b\|}{\|b\|} = \kappa(A) \frac{\|\delta b\|}{\|b\|}.$$

# Одинаковое возмущение может по-разному сдвинуть минимум

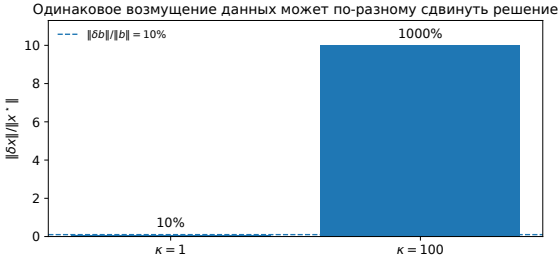
Возьмём в обоих случаях

$$b = (0, 1)^\top, \qquad \delta b = (0.1, 0)^\top.$$

Тогда относительное изменение $b$ равно 10%.

- при $A = I$ имеем $\kappa = 1$ и относительный сдвиг решения 10%;
- при $A = \mathrm{diag}(0.01, 1)$ имеем $\kappa = 100$ и относительный сдвиг решения 1000%.

Это пример, где оценка предыдущего слайда фактически достигается.



# Почему обусловленность станет важна уже на следующей лекции

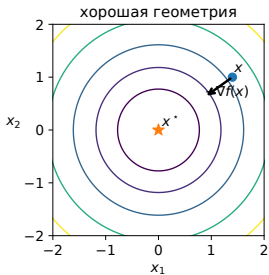
Градиент указывает локальное направление наискорейшего убывания:

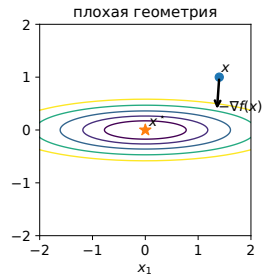
$$-\nabla f(x).$$

Но при большом $\kappa$ поверхность имеет очень разные кривизны по главным направлениям. Градиент оказывается сильно ориентирован поперёк узкой долины.

## Вопрос

Как число обусловленности повлияет на допустимый шаг и скорость градиентного спуска?



# Карта всей лекции

$$\boxed{f(x) = \frac{1}{2}x^\top Ax - b^\top x + c}$$

$$\Downarrow$$

$$\nabla f(x) = Ax - b, \qquad \nabla^2 f(x) = A$$

$$\Downarrow$$

$$A = Q\Lambda Q^\top$$

$$\Downarrow$$

$\lambda_i \iff$ кривизна по главным направлениям

$$\Downarrow$$

$$A \succ 0 \Longrightarrow x^\star = A^{-1}b, \qquad \kappa(A) = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

# Следующая лекция: почему работает градиентный спуск?

Теперь для квадратичной функции мы точно знаем

$$\nabla f(x) = Ax - b.$$

Градиентный шаг имеет вид

$$\boxed{x_{k+1} = x_k - \alpha(Ax_k - b).}$$

А точное решение удовлетворяет

$$Ax^\star = b.$$

## Главный вопрос следующей лекции

При каких значениях шага $\alpha$ последовательность $x_k$ действительно приходит к $x^\star$? И как скорость зависит от $\lambda_{\min}$, $\lambda_{\max}$ и $\kappa(A)$?

Именно здесь обусловленность начнёт непосредственно управлять поведением алгоритма.