



Совместная программа СМОЛ ГУ и  
ФКН НИУ ВШЭ

2026/27 учебный год

# Методы оптимизации в машинном обучении

Лекция 4. Обусловленность и градиентный спуск: почему алгоритм сходится?

Никита Лукьяненко



## С чего продолжаем

На прошлой лекции для квадратичной функции

$$f(x) = \frac{1}{2}x^T A x - b^T x + c, \quad A = A^T \succ 0,$$

мы ввели число обусловленности

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} \geq 1.$$

### Сегодня


Сначала разберёмся, что именно измеряет  $\kappa(A)$  и почему эта величина важна. Затем увидим, как тот же спектр определяет допустимый шаг и скорость градиентного спуска.




# Геометрический смысл числа обусловленности

Чем больше число обусловленности, тем сильнее различается кривизна по направлениям


$\kappa = 1$



$\kappa = 10$



$\kappa = 100$



$\kappa$  измеряет не общую “крутизну” функции, а **неравномерность кривизны по разным направлениям.**



## Экстремальные кривизны

Для симметричной положительно определённой матрицы

$$\min_{\|v\|=1} v^T A v = \lambda_{\min}(A), \quad \max_{\|v\|=1} v^T A v = \lambda_{\max}(A).$$

Поэтому

$$\kappa(A) = \frac{\max_{\|v\|=1} v^T A v}{\min_{\|v\|=1} v^T A v}.$$

### Интерпретация

Число обусловленности показывает, во сколько раз самая большая направленная кривизна превосходит самую маленькую.



## Почему вытянутость равна $\sqrt{\kappa}$ , а не $\kappa$ ?

В собственных координатах линия уровня квадратичной функции имеет вид

$$\frac{1}{2} \sum_i \lambda_i z_i^2 = c.$$

Вдоль собственного направления  $v_i$  остальные координаты равны нулю, поэтому

$$\frac{1}{2} \lambda_i z_i^2 = c \implies |z_i| = a_i = \sqrt{\frac{2c}{\lambda_i}}.$$

Значит,

$$\frac{a_{\max}}{a_{\min}} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \sqrt{\kappa(A)}.$$

### Пример

Если  $\kappa = 100$ , линия уровня вытянута по главным осям в 10 раз.



## Масштаб функции и обусловленность — разные вещи

Если умножить матрицу на  $c > 0$ , все собственные значения умножатся на  $c$ :

$$\lambda_i(cA) = c\lambda_i(A).$$

Следовательно,

$$\kappa(cA) = \frac{c\lambda_{\max}(A)}{c\lambda_{\min}(A)} = \kappa(A).$$

### Самопроверка

Что хуже обусловлено?

$$A_1 = 0.01I, \quad A_2 = \text{diag}(1, 100).$$

Ответ:  $\kappa(A_1) = 1$ , а  $\kappa(A_2) = 100$ .



## Почему это вообще называется “обусловленностью”?

Рассмотрим линейную систему

$$Ax = b, \quad A \succ 0.$$

Её решение

$$x = A^{-1}b$$

зависит от входных данных  $b$ .

### Вопрос

Если слегка изменить  $b$ , насколько сильно может измениться решение  $x$ ?

Именно эту **чувствительность задачи** контролирует число обусловленности.





## Одинаковое возмущение – разный сдвиг решения

Рассмотрим одно и то же относительное возмущение правой части:

$$b = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \Delta b = \begin{pmatrix} 0 \\ 0.1 \end{pmatrix}, \quad \frac{\|\Delta b\|}{\|b\|} = 10\%.$$

Одно и то же относительное возмущение правой части:  $\|\Delta b\|/\|b\| = 10\%$



Одинаковое изменение входных данных может почти не изменить решение хорошо обусловленной системы и сильно изменить решение плохо обусловленной.



## Оценка чувствительности решения

### Утверждение

Пусть  $A = A^T \succ 0$ ,  $Ax = b$ , а при фиксированной  $A$  правая часть получила возмущение  $\Delta b$ . Тогда при  $b \neq 0$

$$\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}.$$

### Смысл

$\kappa(A)$  — максимально возможный коэффициент усиления относительной ошибки правой части в этой оценке.



## Доказательство оценки чувствительности: первая половина

После возмущения имеем

$$A(x + \Delta x) = b + \Delta b.$$

Вычитая  $Ax = b$ , получаем

$$A\Delta x = \Delta b, \quad \Delta x = A^{-1}\Delta b.$$

Собственные значения  $A^{-1}$  равны  $1/\lambda_i(A)$ , поэтому

$$\|A^{-1}\|_2 = \frac{1}{\lambda_{\min}(A)}.$$

Следовательно,

$$\|\Delta x\| \leq \frac{1}{\lambda_{\min}(A)} \|\Delta b\|.$$



## Доказательство оценки чувствительности: завершаем

Так как  $b = Ax$ ,

$$\|b\| = \|Ax\| \leq \lambda_{\max}(A) \|x\|.$$

Отсюда

$$\frac{1}{\|x\|} \leq \frac{\lambda_{\max}(A)}{\|b\|}.$$

Комбинируем с предыдущей оценкой:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} \frac{\|\Delta b\|}{\|b\|}.$$

То есть

$$\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}.$$



## Обусловленность задачи и скорость алгоритма — не одно и то же

До сих пор мы говорили о **чувствительности самой задачи**: как решение реагирует на изменение входных данных.

Теперь переключимся на **алгоритм**: сколько шагов потребуется, чтобы добраться до решения?

### Интрига

Для квадратичных задач оказывается, что те же числа  $\lambda_{\min}$ ,  $\lambda_{\max}$  и  $\kappa$  управляют и поведением градиентного спуска.



## Напоминание: градиентный спуск

В курсе машинного обучения вы уже встречали алгоритм

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

где  $\alpha > 0$  — шаг.

Сегодня нас интересуют не вычислительные детали

Мы хотим математически ответить на два вопроса:

1. почему этот шаг вообще должен уменьшать функцию;
2. при каких  $\alpha$  последовательность действительно сходится.



## Откуда возникает направление $-\nabla f(x)$ ?

Из второй лекции:

$$f(x + h) \approx f(x) + \nabla f(x)^\top h.$$

Если выбрать направление единичной длины, максимально быстро уменьшает линейную модель направление

$$-\frac{\nabla f(x)}{\|\nabla f(x)\|}.$$

Но одной линейной модели недостаточно для выбора **длины** шага.



# Линейная модель сама не умеет выбирать длину шага

Локально мы заменяем исходную функцию линейной моделью



$$m_{\text{lin}}(h) = \nabla f(x)^\top h.$$

Если  $\nabla f(x) \neq 0$  и  $h = -t\nabla f(x)$ ,  $t > 0$ , то

$$m_{\text{lin}}(-t\nabla f(x)) = -t \|\nabla f(x)\|^2 \xrightarrow[t \rightarrow \infty]{} -\infty.$$

## Важно

Неограниченно уменьшается именно **линейная модель**, а не исходная функция  $f$ . Линейное приближение надёжно только для малых  $\|h\|$ , поэтому само по себе оно не может выбрать длину шага.





## Как найти минимум вспомогательной модели?

Рассмотрим функцию шага

$$m_x(h) = \nabla f(x)^\top h + \frac{1}{2\alpha} \|h\|^2, \quad \alpha > 0.$$

### 1. Необходимое условие

Если дифференцируемая функция имеет внутренний локальный минимум в  $h^*$ , то

$$\nabla_h m_x(h^*) = 0.$$

Здесь

$$\nabla_h m_x(h) = \nabla f(x) + \frac{1}{\alpha} h.$$

Следовательно, чтобы найти  $h^*$ , достаточно решить уравнение  $\nabla_h m_x(h) = 0$ .

### 2. Почему здесь этого достаточно?

Гессиан по переменной  $h$  равен

$$\nabla_h^2 m_x(h) = \frac{1}{\alpha} I \succ 0.$$

Поэтому  $m_x$  — строго выпуклая квадратичная функция: её стационарная точка единственна и является глобальным минимумом.



## Градиентный шаг как решение локальной задачи

Из предыдущего уравнения

$$h^* = -\alpha \nabla f(x).$$

Поэтому

$$x_{k+1} = x_k + h^* = x_k - \alpha \nabla f(x_k).$$

**Важно**

Мы вывели форму шага, но пока **не доказали**, что исходная функция  $f$  при этом уменьшается или что последовательность сходится.



## Главный вопрос: как выбрать $\alpha$ ?

Слишком маленький шаг может дать очень медленное движение.

Слишком большой — перескакивание через минимум и даже расходимость.

Какие значения  $\alpha$  гарантируют сходимость?

Начнём с квадратичной функции, где ответ можно получить полностью.



## Квадратичная задача: всё уже известно

Пусть

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c, \quad A = A^\top \succ 0.$$

Из третьей лекции:

$$\nabla f(x) = Ax - b, \quad x^* = A^{-1}b.$$

Градиентный шаг принимает вид

$$x_{k+1} = x_k - \alpha(Ax_k - b).$$



## Вместо самих точек будем изучать ошибку

Определим

$$e_k = x_k - x^*.$$

Тогда сходимость

$$x_k \rightarrow x^*$$

эквивалентна

$$e_k \rightarrow 0.$$

Почему это удобно?

Уравнение  $Ax^* = b$  позволит убрать из рекурсии линейный член  $b$ .



## Получаем линейную рекурсию для ошибки

$$\begin{aligned} e_{k+1} &= x_{k+1} - x^* \\ &= x_k - \alpha(Ax_k - b) - x^*. \end{aligned}$$

Так как  $b = Ax^*$ ,

$$e_{k+1} = x_k - x^* - \alpha A(x_k - x^*).$$

Следовательно,

$$e_{k+1} = (I - \alpha A)e_k.$$

Теперь задача сходимости свелась к анализу степеней одной матрицы.



## Переходим в собственный базис

Поскольку  $A$  симметрична, существует ортонормированный базис собственных векторов  $v_i$ :

$$Av_i = \lambda_i v_i.$$

Разложим ошибку:

$$e_k = \sum_i z_{k,i} v_i.$$

Тогда

$$(I - \alpha A)v_i = (1 - \alpha \lambda_i)v_i.$$

### Главная идея

В собственных координатах многомерный градиентный спуск распадается на независимые одномерные рекурсии.



## Рекурсия для каждой компоненты

Подставляя разложение в

$$e_{k+1} = (I - \alpha A)e_k,$$

получаем

$$z_{k+1,i} = (1 - \alpha \lambda_i) z_{k,i}.$$

Введём обозначение

$$q_i := 1 - \alpha \lambda_i.$$

Тогда




$$z_{k+1,i} = q_i z_{k,i}, \quad z_{k,i} = q_i^k z_{0,i}.$$

Смысл  $q_i$

$q_i$  — множитель, на который меняется  $i$ -я компонента ошибки за одну итерацию.



## Одна координата: три возможных режима



Знак  $q_i$  определяет наличие колебаний, а модуль  $|q_i|$  — затухает ошибка или растёт.



## Условие сходимости в одном собственном направлении

Для рекурсии

$$z_{k+1} = qz_k$$

имеем  $z_k \rightarrow 0$  при любом  $z_0$  тогда и только тогда, когда

$$|q| < 1.$$

Здесь


$$q = 1 - \alpha\lambda.$$

Поэтому требуется

$$|1 - \alpha\lambda| < 1.$$



## Что означает $|1 - \alpha\lambda| < 1$ ?



На рисунке взято  $\lambda = 3$ . Поэтому устойчивый интервал имеет вид

$$0 < \alpha < \frac{2}{3}.$$

В точке  $\alpha = 1/3$  получаем  $q = 0$ : эта компонента ошибки исчезает за один шаг.



## Решаем неравенство

Так как  $\lambda > 0$ ,

$$|1 - \alpha\lambda| < 1$$

равносильно

$$-1 < 1 - \alpha\lambda < 1.$$

Отсюда

$$0 < \alpha\lambda < 2,$$

то есть

$$0 < \alpha < \frac{2}{\lambda}.$$

Для многомерной задачи условие должно выполняться для **каждого** собственного значения.



## Теорема о сходимости на квадратичной функции

### Теорема

Пусть  $A = A^T \succ 0$ . Тогда метод

$$x_{k+1} = x_k - \alpha(Ax_k - b)$$

сходится к  $x^* = A^{-1}b$  при любом  $x_0$  тогда и только тогда, когда

$$0 < \alpha < \frac{2}{\lambda_{\max}(A)}.$$

Это первый полный ответ на вопрос о выборе шага.



## Доказательство теоремы

Мы получили

$$z_{k,i} = (1 - \alpha \lambda_i)^k z_{0,i}.$$

Поэтому  $e_k \rightarrow 0$  при любом начальном  $e_0$  тогда и только тогда, когда

$$|1 - \alpha \lambda_i| < 1 \quad \forall i.$$

Для каждого  $i$  это равносильно

$$0 < \alpha < \frac{2}{\lambda_i}.$$

Чтобы условие выполнялось одновременно для всех  $i$ , достаточно и необходимо взять самое строгое ограничение:

$$0 < \alpha < \min_i \frac{2}{\lambda_i} = \frac{2}{\lambda_{\max}(A)}.$$

Следовательно,  $e_k \rightarrow 0$  и  $x_k \rightarrow x^*$ .





# Не только сходимость: насколько быстро уменьшается ошибка?

Из собственных координат

$$|z_{k,i}| = |1 - \alpha \lambda_i|^k |z_{0,i}|.$$

Определим

$$q(\alpha) = \max_i |1 - \alpha \lambda_i|.$$

Тогда

$$\|e_k\| \leq q(\alpha)^k \|e_0\|.$$

## Интерпретация

Чем меньше  $q$ , тем быстрее геометрически убывает ошибка.



## Почему при $\alpha = 1/L$ худшее направление соответствует $\mu$ ?

Обозначим  $L = \lambda_{\max}(A)$  и  $\mu = \lambda_{\min}(A)$ . Для каждой собственной компоненты ошибки после одного шага остаётся доля

$$q_i = \left| 1 - \frac{\lambda_i}{L} \right| = 1 - \frac{\lambda_i}{L}, \quad \lambda_i \in [\mu, L].$$


### Что значит “худшее”?

Чем **больше**  $q_i$ , тем большая доля ошибки остаётся после шага и тем медленнее затухает эта компонента.

Поскольку  $q_i$  убывает с ростом  $\lambda_i$ , максимум достигается при  $\lambda_i = \mu$ :


$$q_{\max} = 1 - \frac{\mu}{L} = 1 - \frac{1}{\kappa}.$$

То есть  $\mu/L$  — доля, которая гарантированно “снимается” в самом медленном направлении;  $1 - \mu/L$  — доля ошибки, которая остаётся.





## Почему большое $\kappa$ означает медленную сходимость?







# Геометрия траектории при разной обусловленности

Один и тот же алгоритм ведёт себя всё медленнее при росте обусловленности


$\kappa = 1, \alpha = 1/L$



$\kappa = 10, \alpha = 1/L$



$\kappa = 100, \alpha = 1/L$






# Почему обусловленность замедляет градиентный спуск?

При шаге  $\alpha = 1/L$  мы получили оценку

$$\|e_k\| \leq \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|.$$



## Вывод

При большом  $\kappa$  множитель  $1 - 1/\kappa$  близок к единице, поэтому гарантированное сокращение ошибки может быть очень медленным.



## Но реальные функции не обязаны быть квадратичными

Для квадратичной функции

$$\nabla^2 f(x) = A$$

постоянен.


Для общей гладкой функции кривизна меняется от точки к точке.

### Новая задача

Нужна характеристика, которая позволит контролировать, насколько быстро может меняться градиент.



## Почему величины градиента в одной точке недостаточно





## Липшицевость: общее определение

### Определение

Отображение  $g : \mathbb{R}^d \rightarrow \mathbb{R}^m$  называется **липшицевым с константой**  $L \geq 0$ , если для любых  $x, y$

$$\|g(x) - g(y)\| \leq L \|x - y\| .$$

### Что означает это неравенство?

Изменение значения  $g$  не может быть больше, чем  $L$  раз изменение аргумента. Константа  $L$  задаёт глобальное ограничение на скорость изменения отображения.

Если условие выполняется с некоторым  $L$ , оно автоматически выполняется и с любой большей константой.



## Определение

Дифференцируемая функция  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  называется  $L$ -гладкой, если её градиент  $\nabla f$  является липшицевым с константой  $L$ :

$$\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\| .$$

## Смысл

$L$  ограничивает скорость изменения **градиента**, а не самой функции. Большое  $L$  означает, что направление и величина градиента могут быстро меняться даже на небольших расстояниях.





## Как понимать параметр $L$ в одном измерении?

Пусть  $g(t) = f'(t)$ . Липшицевость градиента означает, что для любых  $t_1 \neq t_2$

$$\frac{|g(t_2) - g(t_1)|}{|t_2 - t_1|} \leq L.$$

То есть  $L$  ограничивает **наклон любой секущей** графика производной  $g = f'$ .

Для  $L$ -липшицева градиента модуль наклона любой секущей графика  $g = f'$  не превосходит  $L$



Если  $f''$  непрерывна, локально это соответствует условию  $|f''(t)| \leq L$ : гладкость ограничивает величину кривизны.



## Квадратичная функция как проверка определения

Пусть

$$f(x) = \frac{1}{2}x^{\top}Ax - b^{\top}x, \quad A = A^{\top} \succeq 0.$$

Тогда

$$\nabla f(x) - \nabla f(y) = A(x - y).$$

Следовательно,

$$\|\nabla f(x) - \nabla f(y)\| \leq \|A\|_2 \|x - y\|.$$

Для симметричной положительно полуопределённой  $A$

$$\|A\|_2 = \lambda_{\max}(A).$$

Значит, квадратичная функция  $L$ -гладкая при

$$L = \lambda_{\max}(A).$$



## Гладкость даёт квадратичную верхнюю модель

### Лемма об убывании


Если  $f$  имеет  $L$ -липшицев градиент, то для любых  $x, h$

$$f(x + h) \leq f(x) + \nabla f(x)^\top h + \frac{L}{2} \|h\|^2.$$

Для квадратичной функции такая формула была точной. Для общей гладкой функции она становится **глобальной верхней оценкой**.



# Геометрия леммы об убывании





## Доказательство леммы: сводим всё к одной переменной

Рассмотрим путь

$$\varphi(t) = f(x + th), \quad t \in [0, 1].$$

По основной теореме анализа

$$f(x + h) - f(x) = \int_0^1 \varphi'(t) dt.$$

По правилу цепочки

$$\varphi'(t) = \nabla f(x + th)^\top h.$$

Следовательно,

$$f(x + h) - f(x) = \int_0^1 \nabla f(x + th)^\top h dt.$$



## Доказательство леммы: используем гладкость

Вычтем линейную часть:

$$\begin{aligned} f(x+h) - f(x) - \nabla f(x)^\top h \\ = \int_0^1 [\nabla f(x+th) - \nabla f(x)]^\top h \, dt. \end{aligned}$$

По неравенству Коши–Буняковского и  $L$ -гладкости

$$[\nabla f(x+th) - \nabla f(x)]^\top h \leq Lt \|h\|^2.$$

Интегрируя,

$$\int_0^1 Lt \|h\|^2 \, dt = \frac{L}{2} \|h\|^2.$$

Получаем требуемую оценку.





## Подставляем градиентный шаг

Положим

$$h = -\alpha \nabla f(x).$$

Тогда из леммы

$$\begin{aligned} f(x - \alpha \nabla f(x)) &\leq f(x) - \alpha \|\nabla f(x)\|^2 \\ &\quad + \frac{L}{2} \alpha^2 \|\nabla f(x)\|^2. \end{aligned}$$

То есть

$$f(x_{k+1}) \leq f(x_k) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x_k)\|^2.$$



## Теорема об убывании градиентного спуска

### Следствие

Если  $f$   $L$ -гладкая и

$$0 < \alpha < \frac{2}{L},$$

то при  $\nabla f(x_k) \neq 0$

$$f(x_{k+1}) < f(x_k).$$

Особенно удобно взять

$$\alpha = \frac{1}{L}.$$


Тогда

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2.$$



## Как выглядит гарантированное убывание

При  $\alpha = 1/L$  шаг уменьшает верхнюю модель и саму функцию





## Что мы доказали — и чего ещё не доказали

Из  $L$ -гладкости мы получили:

$$f(x_{k+1}) \leq f(x_k)$$

при подходящем шаге.

Но отсюда **не следует**, что

$$x_k \rightarrow x_{\text{global}}^*.$$

### Почему?

Невыпуклая функция может иметь локальные минимумы и седловые точки. Убывание функции — это ещё не глобальная оптимальность.


Для более сильных выводов нам понадобятся дополнительные свойства функции.




# Как влияет размер шага на траекторию?

Шаг управляет компромиссом: скорость, колебания и устойчивость


$\alpha = 0.2/L$




$\alpha = 1.0/L$



$\alpha = 1.8/L$



$\alpha = 2.2/L$





## Можно ли выбрать шаг лучше, чем $1/L$ ?

Для квадратичной функции мы знаем точный коэффициент сокращения

$$q(\alpha) = \max_i |1 - \alpha \lambda_i|.$$

При спектре

$$\lambda_i \in [\mu, L]$$

достаточно контролировать концы интервала:

$$q(\alpha) = \max\{|1 - \alpha\mu|, |1 - \alpha L|\}.$$

Теперь можно оптимизировать уже сам выбор шага.



## Оптимальный фиксированный шаг: идея

Чтобы минимизировать худший множитель, естественно уравнивать ошибки на двух концах спектра:

$$1 - \alpha\mu = -(1 - \alpha L).$$

Отсюда

$$2 = \alpha(L + \mu),$$

поэтому

$$\alpha^* = \frac{2}{L + \mu}.$$



## Коэффициент сокращения при оптимальном шаге

Подставим  $\alpha^*$ :

$$q^* = 1 - \alpha^* \mu = 1 - \frac{2\mu}{L + \mu}.$$

Следовательно,

$$q^* = \frac{L - \mu}{L + \mu}.$$

Через число обусловленности  $\kappa = L/\mu$ :


$$q^* = \frac{\kappa - 1}{\kappa + 1}.$$



## Где находится оптимальный шаг?

Для спектра  $\lambda \in [\mu, L]$  худший множитель равен

$$q(\alpha) = \max\{|1 - \alpha\mu|, |1 - \alpha L|\}.$$




Минимум достигается там, где два крайних направления одинаково плохи:

$$1 - \alpha\mu = -(1 - \alpha L) \implies \alpha^* = \frac{2}{L + \mu}.$$



## Сравним $1/L$ и оптимальный фиксированный шаг





$$\kappa = \frac{L}{\mu}$$

 $\implies$ 

вытянутость линий уровня  
чувствительность решения

 $\Downarrow$ 

$$e_{k+1} = (I - \alpha A)e_k$$

 $\implies$ 

$$z_{k+1,i} = (1 - \alpha \lambda_i) z_{k,i}$$

 $\Downarrow$ 

$$0 < \alpha < \frac{2}{L},$$

$$\|e_k\| \leq q^k \|e_0\|$$

 $\Downarrow$ 

$$L\text{-гладкость} \implies f(x+h) \leq f(x) + \nabla f(x)^\top h + \frac{L}{2} \|h\|^2.$$



## Что стоит уметь после лекции

1. Объяснять геометрический и численный смысл  $\kappa(A)$ .
2. Доказывать оценку чувствительности линейной системы через  $\kappa(A)$ .
3. Выводить рекурсию

$$e_{k+1} = (I - \alpha A)e_k$$

и условие

$$0 < \alpha < 2/L.$$

4. Формулировать определение  $L$ -гладкости.
5. Доказывать лемму об убывании и применять её к градиентному шагу.



## Куда движемся дальше?

Сегодня мы показали, что при гладкости подходящий градиентный шаг **уменьшает функцию**. Но остаётся вопрос:

когда локальное уменьшение приводит к глобальному минимуму?

Для этого нам понадобится геометрическое свойство функции — **выпуклость**.

Следующая лекция: **выпуклые функции и условия оптимальности**.