

Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 4. Обусловленность и градиентный спуск: почему алгоритм сходится?

Никита Лукьяненко

С чего продолжаем

На прошлой лекции для квадратичной функции

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c, \qquad A = A^\top \succ 0,$$

мы ввели число обусловленности

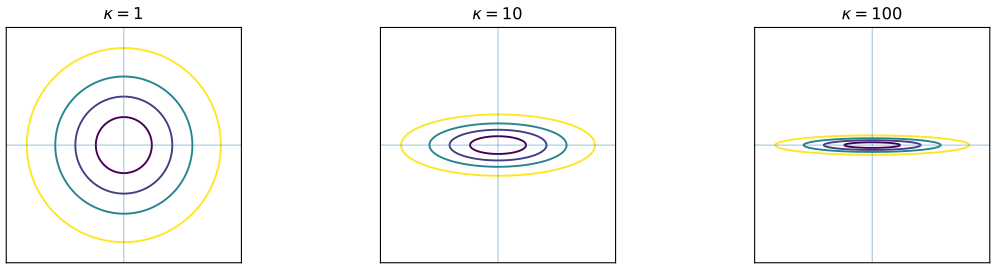
$$\boxed{\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)} \geq 1.}$$

Сегодня

Сначала разберёмся, что именно измеряет $\kappa(A)$ и почему эта величина важна. Затем увидим, как тот же спектр определяет допустимый шаг и скорость градиентного спуска.

Геометрический смысл числа обусловленности

Чем больше число обусловленности, тем сильнее различается кривизна по направлениям



κ измеряет не общую “крутизну” функции, а **неравномерность кривизны по разным направлениям**.

Экстремальные кривизны

Для симметричной положительно определённой матрицы

$$\min_{\|v\|=1} v^\top A v = \lambda_{\min}(A), \qquad \max_{\|v\|=1} v^\top A v = \lambda_{\max}(A).$$

Поэтому

$$\kappa(A) = \frac{\max\limits_{\|v\|=1} v^\top A v}{\min\limits_{\|v\|=1} v^\top A v}.$$

Интерпретация

Число обусловленности показывает, во сколько раз самая большая направленная кривизна превосходит самую маленькую.

Почему вытянутость равна $\sqrt{\kappa}$, а не κ?

В собственных координатах линия уровня квадратичной функции имеет вид

$$\frac{1}{2}\sum_i \lambda_i z_i^2 = c.$$

Вдоль собственного направления v_i остальные координаты равны нулю, поэтому

$$\frac{1}{2}\lambda_i z_i^2 = c \quad \Longrightarrow \quad |z_i| = a_i = \sqrt{\frac{2c}{\lambda_i}}.$$

Значит,

$$\boxed{\frac{a_{\max}}{a_{\min}} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} = \sqrt{\kappa(A)}.}$$

Пример

Если $\kappa = 100$, линия уровня вытянута по главным осям в 10 раз.

Масштаб функции и обусловленность — разные вещи

Если умножить матрицу на $c > 0$, все собственные значения умножатся на c:

$$\lambda_i(cA) = c\lambda_i(A).$$

Следовательно,

$$\boxed{\kappa(cA) = \frac{c\lambda_{\max}(A)}{c\lambda_{\min}(A)} = \kappa(A).}$$

Самопроверка

Что хуже обусловлено?

$$A_1 = 0.01I, \qquad A_2 = \mathrm{diag}(1, 100).$$

Ответ: $\kappa(A_1) = 1$, а $\kappa(A_2) = 100$.

Почему это вообще называется “обусловленностью”?

Рассмотрим линейную систему

$$Ax = b, \qquad A \succ 0.$$

Её решение

$$x = A^{-1}b$$

зависит от входных данных b.

Вопрос

Если слегка изменить b, насколько сильно может измениться решение x?

Именно эту **чувствительность задачи** контролирует число обусловленности.

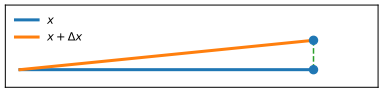
Одинаковое возмущение — разный сдвиг решения

Рассмотрим одно и то же относительное возмущение правой части:

$$b = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad \Delta b = \begin{pmatrix} 0 \\ 0.1 \end{pmatrix}, \qquad \frac{\|\Delta b\|}{\|b\|} = 10\%.$$

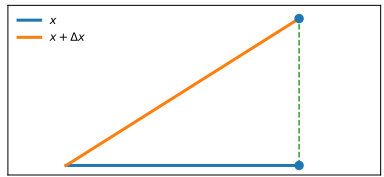
Одно и то же относительное возмущение правой части: $\|\Delta b\|/\|b\| = 10\%$

$A_1 = I$, $\kappa(A_1) = 1$



$\|\Delta x\|/\|x\| = 10\%$

$A_2 = \mathrm{diag}(1, 0.01)$, $\kappa(A_2) = 100$



$\|\Delta x\|/\|x\| = 1000\%$

Одинаковое изменение входных данных может почти не изменить решение хорошо обусловленной системы и сильно изменить решение плохо обусловленной.

Оценка чувствительности решения

Утверждение

Пусть $A = A^\top \succ 0$, $Ax = b$, а при фиксированной A правая часть получила возмущение Δb. Тогда при $b \neq 0$

$$\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A)\,\frac{\|\Delta b\|}{\|b\|}.}$$

Смысл

$\kappa(A)$ — максимально возможный коэффициент усиления относительной ошибки правой части в этой оценке.

Доказательство оценки чувствительности: первая половина

После возмущения имеем

$$A(x + \Delta x) = b + \Delta b.$$

Вычитая $Ax = b$, получаем

$$A\Delta x = \Delta b, \qquad \Delta x = A^{-1}\Delta b.$$

Собственные значения A^{-1} равны $1/\lambda_i(A)$, поэтому

$$\left\|A^{-1}\right\|_2 = \frac{1}{\lambda_{\min}(A)}.$$

Следовательно,

$$\boxed{\|\Delta x\| \leq \frac{1}{\lambda_{\min}(A)} \|\Delta b\|.}$$

Доказательство оценки чувствительности: завершаем

Так как $b = Ax$,

$$\|b\| = \|Ax\| \leq \lambda_{\max}(A)\,\|x\|\,.$$

Отсюда

$$\frac{1}{\|x\|} \leq \frac{\lambda_{\max}(A)}{\|b\|}.$$

Комбинируем с предыдущей оценкой:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}\frac{\|\Delta b\|}{\|b\|}.$$

То есть

$$\boxed{\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A)\frac{\|\Delta b\|}{\|b\|}.}$$

Обусловленность задачи и скорость алгоритма — не одно и то же

До сих пор мы говорили о **чувствительности самой задачи**: как решение реагирует на изменение входных данных.

Теперь переключимся на **алгоритм**: сколько шагов потребуется, чтобы добраться до решения?

Интрига

Для квадратичных задач оказывается, что те же числа $\lambda_{\min}$, $\lambda_{\max}$ и κ управляют и поведением градиентного спуска.

Напоминание: градиентный спуск

В курсе машинного обучения вы уже встречали алгоритм

$$\boxed{x_{k+1} = x_k - \alpha \nabla f(x_k),}$$

где $\alpha > 0$ — шаг.

Сегодня нас интересуют не вычислительные детали

Мы хотим математически ответить на два вопроса:

1. почему этот шаг вообще должен уменьшать функцию;
2. при каких α последовательность действительно сходится.



Откуда возникает направление $-\nabla f(x)$?

Из второй лекции:

$$f(x+h) \approx f(x) + \nabla f(x)^\top h.$$

Если выбирать направление единичной длины, максимально быстро уменьшает линейную модель направление

$$-\frac{\nabla f(x)}{\|\nabla f(x)\|}.$$

Но одной линейной модели недостаточно для выбора **длины** шага.

Линейная модель сама не умеет выбирать длину шага

Локально мы заменяем исходную функцию линейной моделью

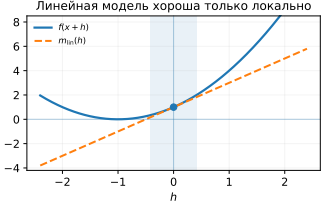
$$m_{\text{lin}}(h) = \nabla f(x)^\top h.$$

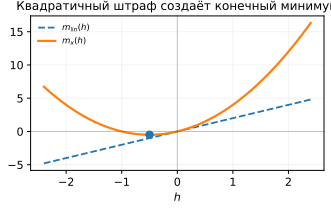
Если $\nabla f(x) \neq 0$ и $h = -t\nabla f(x)$, $t > 0$, то

$$m_{\text{lin}}(-t\nabla f(x)) = -t\,\|\nabla f(x)\|^2 \xrightarrow[t\to\infty]{} -\infty.$$

Важно

Неограниченно уменьшается именно **линейная модель**, а не исходная функция f. Линейное приближение надёжно только для малых $\|h\|$, поэтому само по себе оно не может выбрать длину шага.





Как найти минимум вспомогательной модели?

Рассмотрим функцию шага

$$m_x(h) = \nabla f(x)^\top h + \frac{1}{2\alpha}\|h\|^2, \qquad \alpha > 0.$$

1. Необходимое условие

Если дифференцируемая функция имеет внутренний локальный минимум в h^*, то

$$\nabla_h m_x(h^*) = 0.$$

Здесь

$$\nabla_h m_x(h) = \nabla f(x) + \frac{1}{\alpha} h.$$

2. Почему здесь этого достаточно?

Гессиан по переменной h равен

$$\nabla_h^2 m_x(h) = \frac{1}{\alpha} I \succ 0.$$

Поэтому m_x — строго выпуклая квадратичная функция: её стационарная точка единственна и является глобальным минимумом.

Следовательно, чтобы найти h^*, достаточно решить уравнение $\nabla_h m_x(h) = 0$.

Градиентный шаг как решение локальной задачи

Из предыдущего уравнения

$$\boxed{h^* = -\alpha \nabla f(x).}$$

Поэтому

$$x_{k+1} = x_k + h^* = \boxed{x_k - \alpha \nabla f(x_k)}.$$

Важно

Мы вывели форму шага, но пока **не доказали**, что исходная функция f при этом уменьшается или что последовательность сходится.



Главный вопрос: как выбрать α?

Слишком маленький шаг может дать очень медленное движение.
Слишком большой — перескакивание через минимум и даже расходимость.

Какие значения α гарантируют сходимость?

Начнём с квадратичной функции, где ответ можно получить полностью.



Квадратичная задача: всё уже известно

Пусть

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c, \qquad A = A^\top \succ 0.$$

Из третьей лекции:

$$\nabla f(x) = Ax - b, \qquad x^* = A^{-1}b.$$

Градиентный шаг принимает вид

$$\boxed{x_{k+1} = x_k - \alpha(Ax_k - b).}$$

Вместо самих точек будем изучать ошибку

Определим

$$\boxed{e_k = x_k - x^*.}$$

Тогда сходимость

$$x_k \to x^*$$

эквивалентна

$$e_k \to 0.$$

Почему это удобно?

Уравнение $Ax^* = b$ позволит убрать из рекурсии линейный член b.

Получаем линейную рекурсию для ошибки

$$\begin{aligned} e_{k+1} &= x_{k+1} - x^* \\ &= x_k - \alpha(Ax_k - b) - x^*. \end{aligned}$$

Так как $b = Ax^*$,

$$e_{k+1} = x_k - x^* - \alpha A(x_k - x^*).$$

Следовательно,

$$\boxed{e_{k+1} = (I - \alpha A)e_k.}$$

Теперь задача сходимости свелась к анализу степеней одной матрицы.

Переходим в собственный базис

Поскольку A симметрична, существует ортонормированный базис собственных векторов v_i:

$$Av_i = \lambda_i v_i.$$

Разложим ошибку:

$$e_k = \sum_i z_{k,i} v_i.$$

Тогда

$$(I - \alpha A)v_i = (1 - \alpha\lambda_i)v_i.$$

Главная идея

В собственных координатах многомерный градиентный спуск распадается на независимые одномерные рекурсии.

Рекурсия для каждой компоненты

Подставляя разложение в

$$e_{k+1} = (I - \alpha A)e_k,$$

получаем

$$\boxed{z_{k+1,i} = (1 - \alpha\lambda_i)z_{k,i}.}$$

Введём обозначение

$$\boxed{q_i := 1 - \alpha\lambda_i.}$$

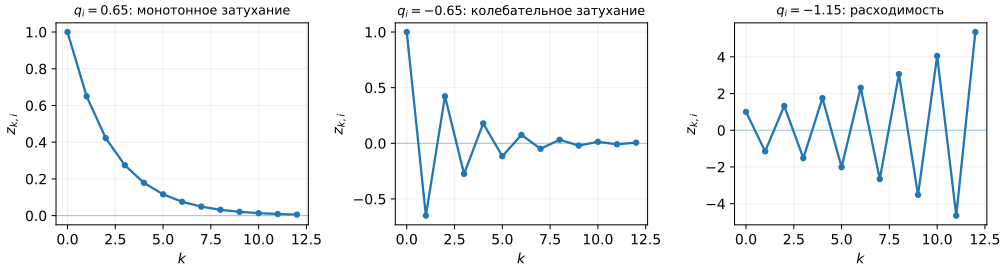
Тогда

$$z_{k+1,i} = q_i z_{k,i}, \qquad z_{k,i} = q_i^k z_{0,i}.$$

Смысл q_i

q_i — множитель, на который меняется i-я компонента ошибки за одну итерацию.

Одна координата: три возможных режима



Знак q_i определяет наличие колебаний, а модуль $|q_i|$ — затухает ошибка или растёт.

Условие сходимости в одном собственном направлении

Для рекурсии

$$z_{k+1} = qz_k$$

имеем $z_k \to 0$ при любом z_0 тогда и только тогда, когда

$$|q| < 1.$$

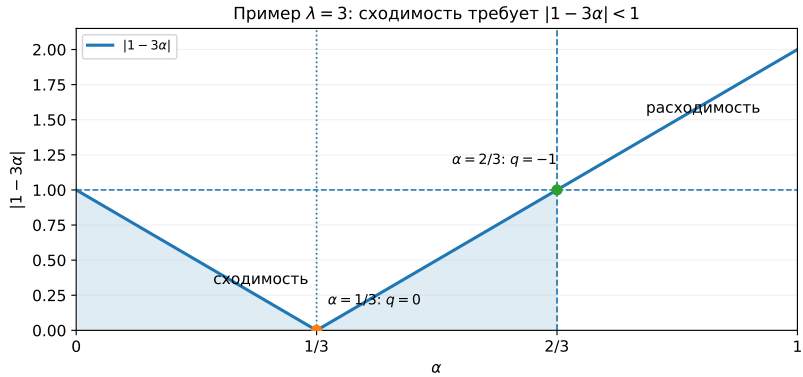
Здесь

$$q = 1 - \alpha\lambda.$$

Поэтому требуется

$$|1 - \alpha\lambda| < 1.$$

Что означает $|1 - \alpha\lambda| < 1$?



На рисунке взято $\lambda = 3$. Поэтому устойчивый интервал имеет вид

$$0 < \alpha < \frac{2}{3}.$$

В точке $\alpha = 1/3$ получаем $q = 0$: эта компонента ошибки исчезает за один шаг.

Решаем неравенство

Так как $\lambda > 0$,

$$|1 - \alpha\lambda| < 1$$

равносильно

$$-1 < 1 - \alpha\lambda < 1.$$

Отсюда

$$0 < \alpha\lambda < 2,$$

то есть

$$\boxed{0 < \alpha < \frac{2}{\lambda}.}$$

Для многомерной задачи условие должно выполняться для **каждого** собственного значения.

Теорема о сходимости на квадратичной функции

Теорема

Пусть $A = A^\top \succ 0$. Тогда метод

$$x_{k+1} = x_k - \alpha(Ax_k - b)$$

сходится к $x^* = A^{-1}b$ при любом x_0 тогда и только тогда, когда

$$\boxed{0 < \alpha < \frac{2}{\lambda_{\max}(A)}.}$$

Это первый полный ответ на вопрос о выборе шага.

Доказательство теоремы

Мы получили

$$z_{k,i} = (1 - \alpha\lambda_i)^k z_{0,i}.$$

Поэтому $e_k \to 0$ при любом начальном e_0 тогда и только тогда, когда

$$|1 - \alpha\lambda_i| < 1 \qquad \forall i.$$

Для каждого i это равносильно

$$0 < \alpha < \frac{2}{\lambda_i}.$$

Чтобы условие выполнялось одновременно для всех i, достаточно и необходимо взять самое строгое ограничение:

$$0 < \alpha < \min_i \frac{2}{\lambda_i} = \frac{2}{\lambda_{\max}(A)}.$$

Следовательно, $e_k \to 0$ и $x_k \to x^*$. □

Не только сходимость: насколько быстро уменьшается ошибка?

Из собственных координат

$$|z_{k,i}| = |1 - \alpha\lambda_i|^k |z_{0,i}|.$$

Определим

$$\boxed{q(\alpha) = \max_i |1 - \alpha\lambda_i|.}$$

Тогда

$$\boxed{\|e_k\| \leq q(\alpha)^k \|e_0\|.}$$

Интерпретация

Чем меньше q, тем быстрее геометрически убывает ошибка.

Почему при $\alpha = 1/L$ худшее направление соответствует μ?

Обозначим $L = \lambda_{\max}(A)$ и $\mu = \lambda_{\min}(A)$. Для каждой собственной компоненты ошибки после одного шага остаётся доля

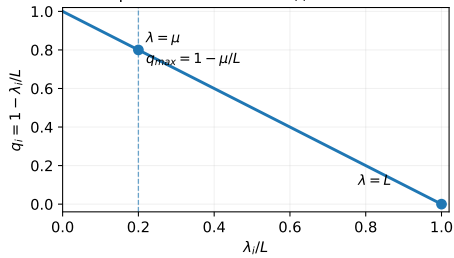
$$q_i = \left|1 - \frac{\lambda_i}{L}\right| = 1 - \frac{\lambda_i}{L}, \qquad \lambda_i \in [\mu, L].$$

Что значит “худшее”?

Чем **больше** q_i, тем большая доля ошибки остаётся после шага и тем медленнее затухает эта компонента.
Поскольку q_i убывает с ростом λ_i, максимум достигается при $\lambda_i = \mu$:

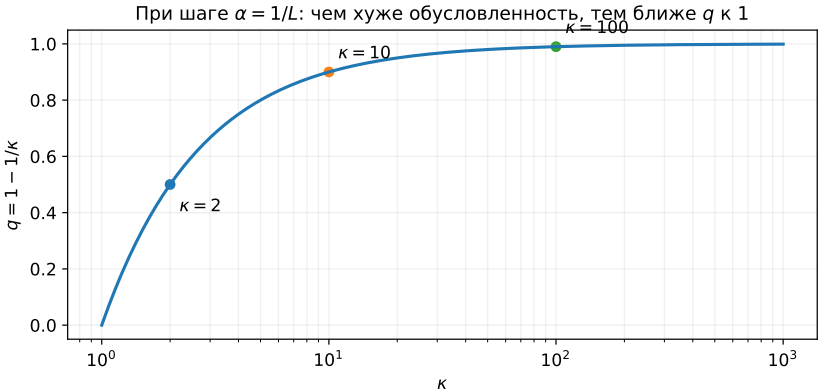
$$q_{\max} = 1 - \frac{\mu}{L} = 1 - \frac{1}{\kappa}.$$

Меньшая кривизна ⇒ большая доля ошибки остаётся



То есть μ/L — доля, которая гарантированно “снимается” в самом медленном направлении; $1 - \mu/L$ — доля ошибки, которая остаётся.

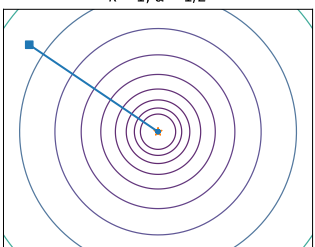
Почему большое κ означает медленную сходимость?



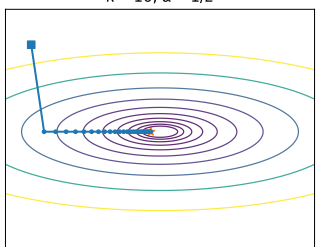
Геометрия траектории при разной обусловленности

Один и тот же алгоритм ведёт себя всё медленнее при росте обусловленности

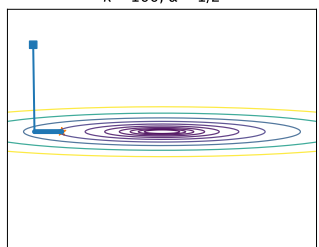
$\kappa = 1$, $\alpha = 1/L$



$\kappa = 10$, $\alpha = 1/L$



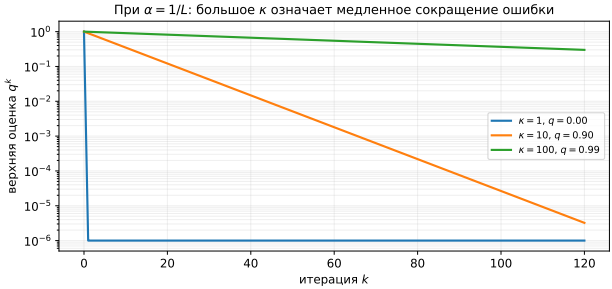
$\kappa = 100$, $\alpha = 1/L$



Почему обусловленность замедляет градиентный спуск?

При шаге $\alpha = 1/L$ мы получили оценку

$$\boxed{\|e_k\| \le \left(1 - \frac{1}{\kappa}\right)^k \|e_0\|.}$$



Вывод

При большом κ множитель $1 - 1/\kappa$ близок к единице, поэтому гарантированное сокращение ошибки может быть очень медленным.



Но реальные функции не обязаны быть квадратичными

Для квадратичной функции

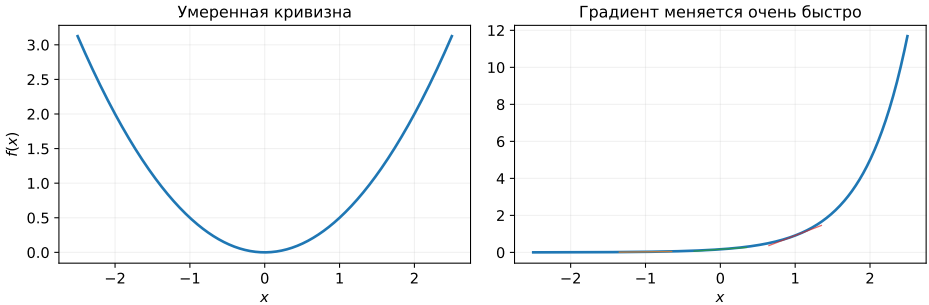
$$\nabla^2 f(x) = A$$

постоянен.
Для общей гладкой функции кривизна меняется от точки к точке.

Новая задача

Нужна характеристика, которая позволит контролировать, насколько быстро может меняться градиент.

Почему величины градиента в одной точке недостаточно



Липшицевость: общее определение

Определение

Отображение $g : \mathbb{R}^d \to \mathbb{R}^m$ называется **липшицевым с константой** $L \geq 0$, если для любых x, y

$$\boxed{\|g(x) - g(y)\| \leq L \|x - y\|.}$$

Что означает это неравенство?

Изменение значения g не может быть больше, чем L раз изменение аргумента. Константа L задаёт глобальное ограничение на скорость изменения отображения.

Если условие выполняется с некоторым L, оно автоматически выполняется и с любой большей константой.

L-гладкость

Определение

Дифференцируемая функция $f : \mathbb{R}^d \to \mathbb{R}$ называется L-гладкой, если её градиент ∇f является липшицевым с константой L:

$$\boxed{\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|.}$$

Смысл

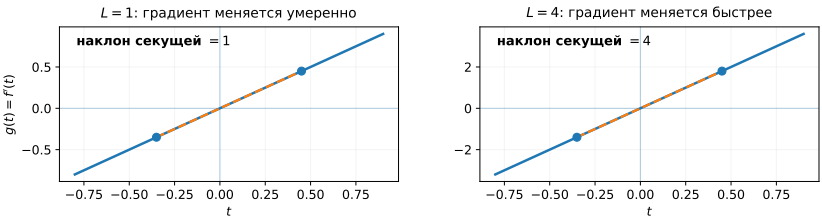
L ограничивает скорость изменения **градиента**, а не самой функции. Большое L означает, что направление и величина градиента могут быстро меняться даже на небольших расстояниях.

Как понимать параметр L в одном измерении?

Пусть $g(t) = f'(t)$. Липшицевость градиента означает, что для любых $t_1 \neq t_2$

$$\boxed{\frac{|g(t_2) - g(t_1)|}{|t_2 - t_1|} \leq L.}$$

То есть L ограничивает **наклон любой секущей** графика производной $g = f'$.



Если f'' непрерывна, локально это соответствует условию $|f''(t)| \leq L$: гладкость ограничивает величину кривизны.

Квадратичная функция как проверка определения

Пусть

$$f(x) = \frac{1}{2} x^\top A x - b^\top x, \qquad A = A^\top \succeq 0.$$

Тогда

$$\nabla f(x) - \nabla f(y) = A(x - y).$$

Следовательно,

$$\|\nabla f(x) - \nabla f(y)\| \leq \|A\|_2 \|x - y\|.$$

Для симметричной положительно полуопределённой A

$$\|A\|_2 = \lambda_{\max}(A).$$

Значит, квадратичная функция L-гладкая при

$$\boxed{L = \lambda_{\max}(A).}$$

Гладкость даёт квадратичную верхнюю модель

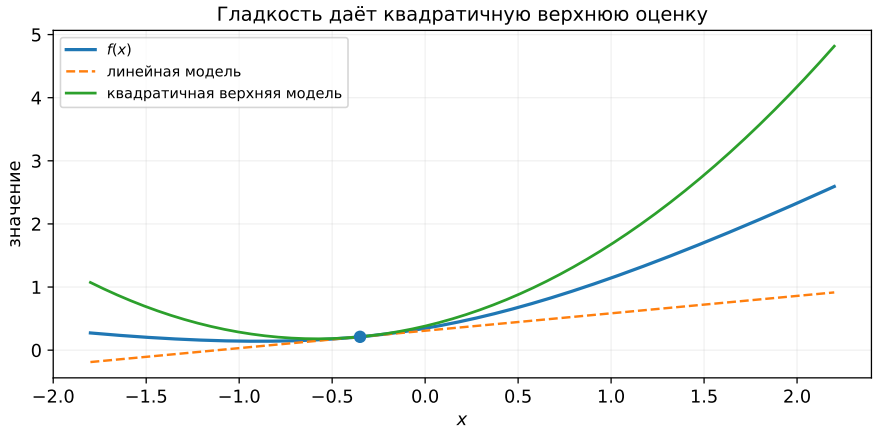
Лемма об убывании

Если f имеет L-липшицев градиент, то для любых x, h

$$\boxed{f(x+h) \le f(x) + \nabla f(x)^\top h + \frac{L}{2}\|h\|^2.}$$

Для квадратичной функции такая формула была точной. Для общей гладкой функции она становится **глобальной верхней оценкой**.

Геометрия леммы об убывании



Доказательство леммы: сводим всё к одной переменной

Рассмотрим путь

$$\varphi(t) = f(x + th), \qquad t \in [0, 1].$$

По основной теореме анализа

$$f(x + h) - f(x) = \int_0^1 \varphi'(t)\, dt.$$

По правилу цепочки

$$\varphi'(t) = \nabla f(x + th)^\top h.$$

Следовательно,

$$f(x + h) - f(x) = \int_0^1 \nabla f(x + th)^\top h\, dt.$$

Доказательство леммы: используем гладкость

Вычтем линейную часть:

$$f(x+h) - f(x) - \nabla f(x)^\top h$$
$$= \int_0^1 [\nabla f(x+th) - \nabla f(x)]^\top h \, dt.$$

По неравенству Коши–Буняковского и L-гладкости

$$[\nabla f(x+th) - \nabla f(x)]^\top h \leq Lt \|h\|^2.$$

Интегрируя,

$$\int_0^1 Lt \|h\|^2 \, dt = \frac{L}{2} \|h\|^2.$$

Получаем требуемую оценку. □

Подставляем градиентный шаг

Положим

$$h = -\alpha \nabla f(x).$$

Тогда из леммы

$$f(x - \alpha \nabla f(x)) \leq f(x) - \alpha \|\nabla f(x)\|^2 + \frac{L}{2}\alpha^2 \|\nabla f(x)\|^2 .$$

То есть

$$\boxed{f(x_{k+1}) \leq f(x_k) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x_k)\|^2 .}$$



Теорема об убывании градиентного спуска

Следствие

Если f L-гладкая и

$$0 < \alpha < \frac{2}{L},$$

то при $\nabla f(x_k) \neq 0$

$$f(x_{k+1}) < f(x_k).$$

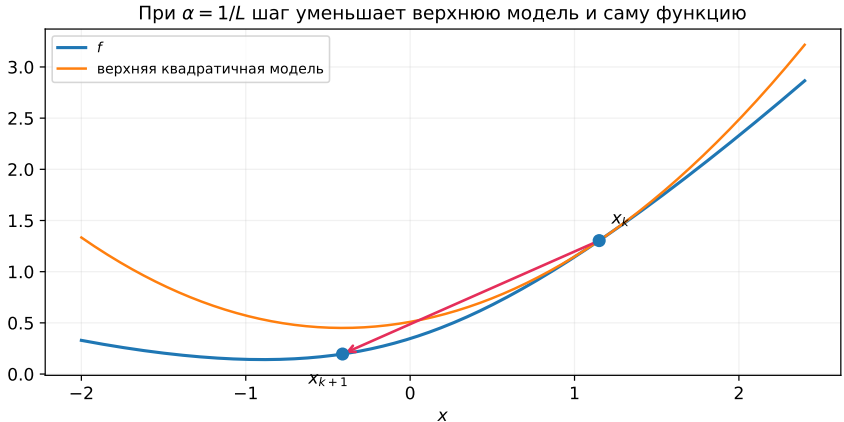
Особенно удобно взять

$$\alpha = \frac{1}{L}.$$

Тогда

$$\boxed{f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2.}$$

Как выглядит гарантированное убывание



Что мы доказали — и чего ещё не доказали

Из L-гладкости мы получили:

$$f(x_{k+1}) \leq f(x_k)$$

при подходящем шаге.
Но отсюда **не следует**, что

$$x_k \to x^*_{\text{global}}.$$

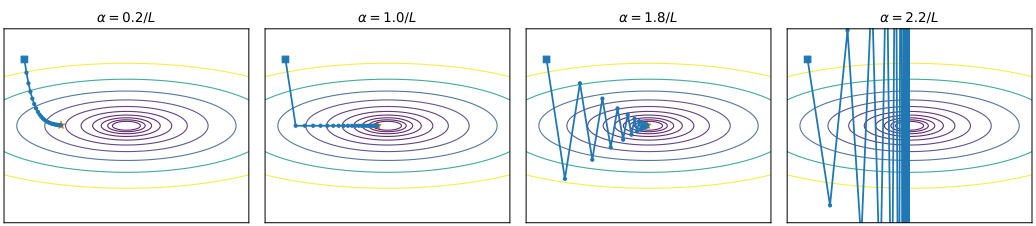
Почему?

Невыпуклая функция может иметь локальные минимумы и седловые точки. Убывание функции — это ещё не глобальная оптимальность.

Для более сильных выводов нам понадобятся дополнительные свойства функции.

Как влияет размер шага на траекторию?

Шаг управляет компромиссом: скорость, колебания и устойчивость



Можно ли выбрать шаг лучше, чем $1/L$?

Для квадратичной функции мы знаем точный коэффициент сокращения

$$q(\alpha) = \max_i |1 - \alpha\lambda_i|.$$

При спектре

$$\lambda_i \in [\mu, L]$$

достаточно контролировать концы интервала:

$$\boxed{q(\alpha) = \max\{|1 - \alpha\mu|,\ |1 - \alpha L|\}.}$$

Теперь можно оптимизировать уже сам выбор шага.

Оптимальный фиксированный шаг: идея

Чтобы минимизировать худший множитель, естественно уравнять ошибки на двух концах спектра:

$$1 - \alpha\mu = -(1 - \alpha L).$$

Отсюда

$$2 = \alpha(L + \mu),$$

поэтому

$$\boxed{\alpha^* = \frac{2}{L + \mu}.}$$

Коэффициент сокращения при оптимальном шаге

Подставим α^*:

$$q^* = 1 - \alpha^* \mu = 1 - \frac{2\mu}{L + \mu}.$$

Следовательно,

$$\boxed{q^* = \frac{L - \mu}{L + \mu}.}$$

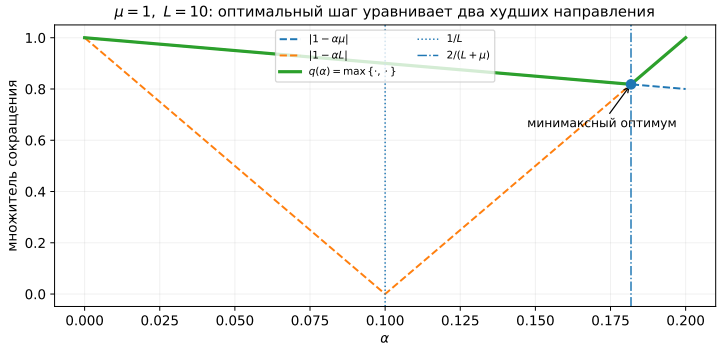
Через число обусловленности $\kappa = L/\mu$:

$$\boxed{q^* = \frac{\kappa - 1}{\kappa + 1}.}$$

Где находится оптимальный шаг?

Для спектра $\lambda \in [\mu, L]$ худший множитель равен

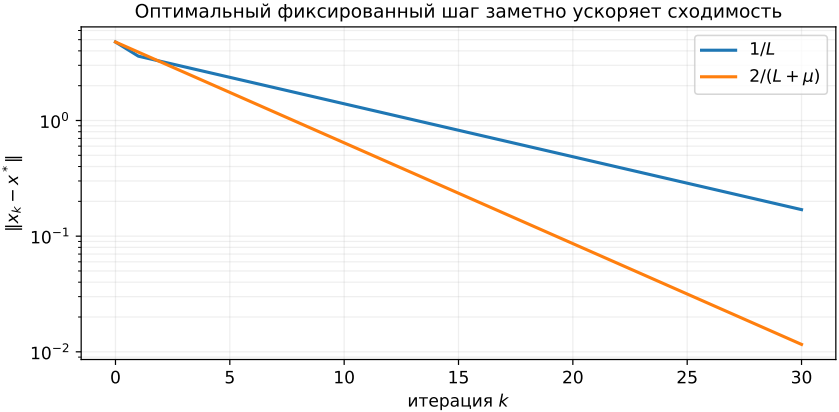
$$q(\alpha) = \max\{|1 - \alpha\mu|,\ |1 - \alpha L|\}.$$



Минимум достигается там, где два крайних направления одинаково плохи:

$$1 - \alpha\mu = -(1 - \alpha L) \quad \Longrightarrow \quad \alpha^* = \frac{2}{L + \mu}.$$

Сравним $1/L$ и оптимальный фиксированный шаг



Карта лекции

$$\boxed{\kappa = \frac{L}{\mu}} \quad \Longrightarrow \quad \begin{array}{l}\text{вытянутость линий уровня} \\ \text{чувствительность решения}\end{array}$$

$$\Downarrow$$

$$e_{k+1} = (I - \alpha A)e_k \quad \Longrightarrow \quad z_{k+1,i} = (1 - \alpha\lambda_i)z_{k,i}$$

$$\Downarrow$$

$$0 < \alpha < \frac{2}{L}, \qquad \|e_k\| \leq q^k \|e_0\|$$

$$\Downarrow$$

L-гладкость $\quad \Longrightarrow \quad f(x+h) \leq f(x) + \nabla f(x)^\top h + \frac{L}{2}\|h\|^2 .$

Что стоит уметь после лекции

1. Объяснять геометрический и численный смысл $\kappa(A)$.
2. Доказывать оценку чувствительности линейной системы через $\kappa(A)$.
3. Выводить рекурсию
$$e_{k+1} = (I - \alpha A)e_k$$
и условие
$$0 < \alpha < 2/L.$$
4. Формулировать определение L-гладкости.
5. Доказывать лемму об убывании и применять её к градиентному шагу.

Куда движемся дальше?

Сегодня мы показали, что при гладкости подходящий градиентный шаг **уменьшает функцию**.
Но остаётся вопрос:

когда локальное уменьшение приводит к глобальному минимуму?

Для этого нам понадобится геометрическое свойство функции — **выпуклость**.

Следующая лекция: **выпуклые функции и условия оптимальности**.