

Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 5. Выпуклость и условия оптимальности

Никита Лукьяненко

Что мы уже умеем

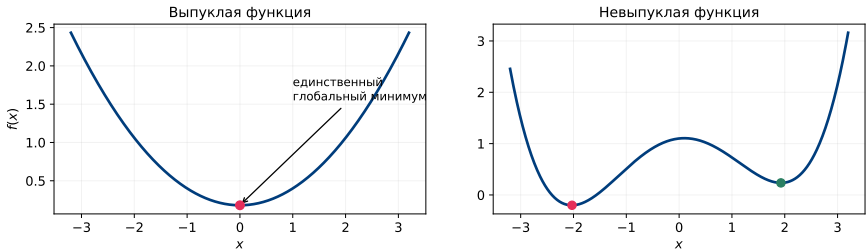
На прошлой лекции мы научились доказывать, что при подходящем шаге градиентный спуск уменьшает функцию:

$$f(x_{k+1}) < f(x_k).$$

Но остаётся более фундаментальный вопрос:

К какому минимуму мы вообще можем прийти?

Убывание функции само по себе не говорит, в какой минимум мы придём



Проблема локального минимума

Для невыпуклой функции возможны разные стационарные точки:

- локальные минимумы разного качества;
- локальные максимумы;
- седловые точки.

Главный вопрос

Можно ли выделить класс функций, для которых **любой локальный минимум автоматически глобален**?

Ответ этой лекции: да. Такой класс задаёт **выпуклость**.

Почему выпуклость так полезна

выпуклость $\Longrightarrow$ простая геометрия $\Longrightarrow$ простые условия оптимальности $\Longrightarrow$ глобальные гарантии

Сегодня мы свяжем три уже знакомых объекта:

геометрию функции $\quad \nabla f(x) \quad \nabla^2 f(x).$

И увидим, как они позволяют распознавать глобальный минимум.

Отрезок между двумя точками

Пусть $x, y \in \mathbb{R}^d$. Точки отрезка между ними имеют вид

$$z(t) = (1 - t)x + ty, \qquad t \in [0, 1].$$

При $t = 0$ получаем x, при $t = 1 - y$.

Идея

Выпуклое множество устроено так, что вместе с любыми двумя своими точками содержит и весь соединяющий их отрезок.



Определение выпуклого множества

Определение

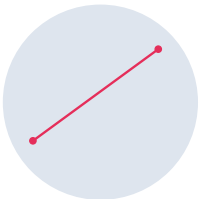
Множество $X \subseteq \mathbb{R}^d$ называется **выпуклым**, если для любых $x, y \in X$ и любого $t \in [0, 1]$

$$\boxed{(1-t)x + ty \in X.}$$

Это определение требует проверки **для любой пары точек** множества.

Как выглядит выпуклость геометрически

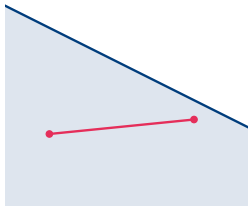
Шар — выпуклый



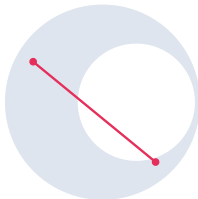
Прямоугольник — выпуклый



Полуплоскость — выпуклая



Невыпуклое множество



В невыпуклом множестве хотя бы один отрезок между двумя допустимыми точками выходит наружу.

Самопроверка: какие множества выпуклы?

Определите, какие из множеств выпуклы:

$$X_1 = \{x : \|x\|_2 \leq 1\},$$

$$X_2 = \{x \in \mathbb{R}^2 : x_1 + x_2 \leq 1\},$$

$$X_3 = \{x : \|x\|_2 = 1\},$$

$$X_4 = \{x \in \mathbb{R}^2 : x_1 x_2 \geq 1\}.$$

Совет

Чтобы показать невыпуклость, достаточно найти **одну** пару точек, для которой отрезок выходит из множества.

Выпуклая комбинация

Пусть $x_1, \ldots, x_m \in \mathbb{R}^d$, а коэффициенты удовлетворяют

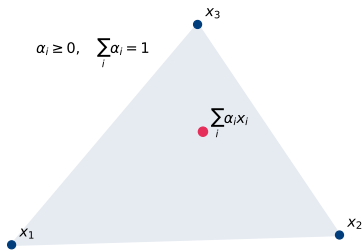
$$\alpha_i \geq 0, \qquad \sum_{i=1}^{m} \alpha_i = 1.$$

Тогда

$$\sum_{i=1}^{m} \alpha_i x_i$$

называется **выпуклой комбинацией** точек x_i.

Выпуклая комбинация остаётся внутри выпуклого множества



Выпуклое множество содержит выпуклые комбинации

Утверждение

Если X выпукло и $x_1, \ldots, x_m \in X$, то при

$$\alpha_i \geq 0, \qquad \sum_i \alpha_i = 1$$

имеем

$$\boxed{\sum_i \alpha_i x_i \in X.}$$

Для двух точек это ровно определение. Для трёх точек можно сначала объединить x_1, x_2, а затем полученную точку — с x_3.



Почему область определения тоже должна быть выпуклой

Дальше мы будем сравнивать значения функции в точках

$$(1 - t)x + ty.$$

Если эта точка выходит из области определения, само сравнение теряет смысл.

Поэтому

Говоря о выпуклой функции $f : X \to \mathbb{R}$, обычно предполагают, что её область X сама выпукла.

Геометрическая идея выпуклой функции

Хордовое определение: график выпуклой функции лежит не выше хорды

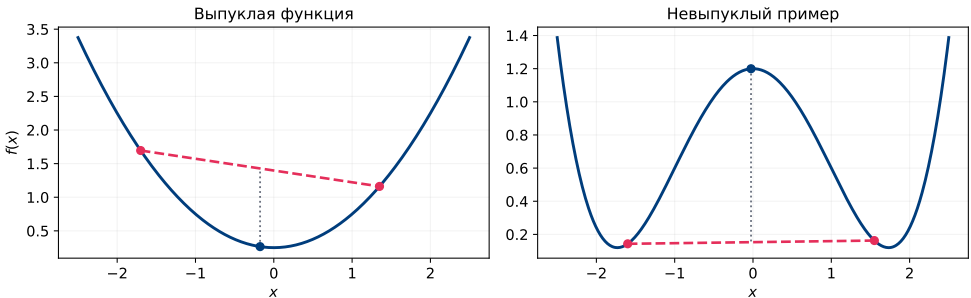


График выпуклой функции лежит **не выше** любой хорды, соединяющей две точки её графика.



Определение выпуклой функции

Определение

Функция $f : X \to \mathbb{R}$ на выпуклом множестве X называется **выпуклой**, если для любых $x, y \in X$ и $t \in [0, 1]$

$$\boxed{f((1-t)x + ty) \leq (1-t)f(x) + tf(y).}$$



Как читать определение буквально

Слева:

$$f\Big(\underbrace{(1-t)x+ty}_{\text{выпуклая комбинация аргументов}}\Big).$$

Справа:

$$\underbrace{(1-t)f(x)+tf(y)}_{\text{та же комбинация значений функции}}.$$

Смысл

Сначала усреднить аргументы и затем вычислить функцию — не хуже, чем сначала вычислить значения, а потом усреднить их.

Пример: $f(x) = x^2$ выпукла

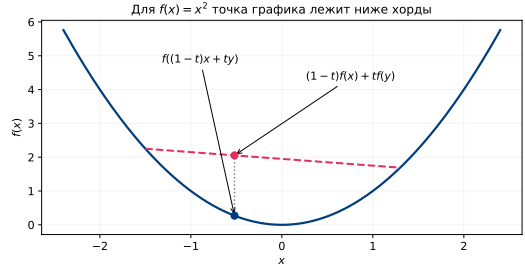
Нужно проверить

$$((1-t)x + ty)^2 \leq (1-t)x^2 + ty^2.$$

Рассмотрим разность правой и левой частей:

$$\begin{aligned}&(1-t)x^2 + ty^2 - ((1-t)x + ty)^2 \\ &= t(1-t)(x-y)^2 \geq 0.\end{aligned}$$

Следовательно, условие выпуклости выполняется.





Невыпуклый пример

Функция

$$f(x) = x^3$$

на всей $\mathbb{R}$ не является выпуклой.
Например, её кривизна меняет знак: слева от нуля

$$f''(x) = 6x < 0,$$

а справа

$$f''(x) > 0.$$

Позже мы увидим, что это уже достаточная причина невыпуклости на всей прямой.



Линейная функция — пограничный случай

Пусть

$$f(x) = a^\top x + b.$$

Тогда

$$\begin{aligned} f((1-t)x + ty) &= a^\top((1-t)x + ty) + b \\ &= (1-t)f(x) + tf(y). \end{aligned}$$

То есть в определении выпуклости всегда выполняется **равенство**.

Следствие

Линейная функция одновременно выпукла и вогнута.



Неравенство Йенсена

Для выпуклой функции и выпуклой комбинации

$$\alpha_i \geq 0, \qquad \sum_i \alpha_i = 1$$

справедливо

$$\boxed{f\left(\sum_i \alpha_i x_i\right) \leq \sum_i \alpha_i f(x_i).}$$

Это называется **неравенством Йенсена**.



Йенсен — это обобщение определения

При $m = 2$

$$\alpha_1 = 1 - t, \qquad \alpha_2 = t,$$

и неравенство Йенсена превращается в

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

Для большего числа точек результат получается последовательным применением определения.

Мини-задача на Йенсена

Функция $f(x) = e^x$ выпукла. Примените Йенсена к двум точкам с одинаковыми весами:

$$\alpha_1 = \alpha_2 = \frac{1}{2}.$$

Получаем

$$\boxed{e^{(x+y)/2} \leq \frac{e^x + e^y}{2}.}$$

Это простейший пример того, как выпуклость автоматически порождает полезные неравенства.



Но определение неудобно проверять напрямую

Чтобы проверить выпуклость по определению, формально нужно убедиться в неравенстве

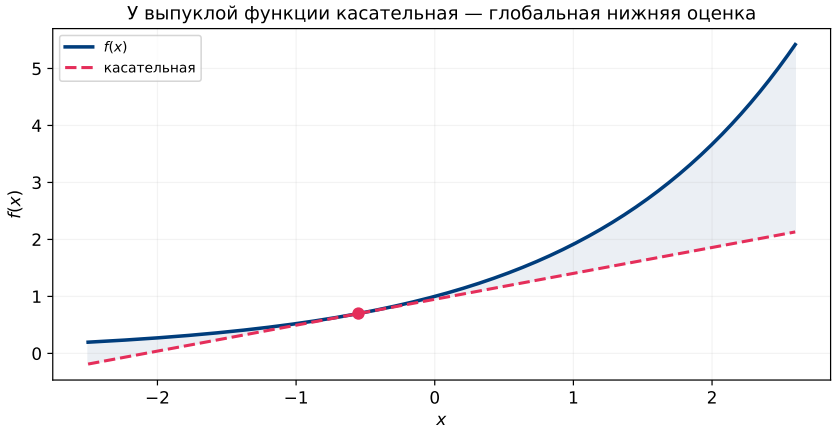
$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y)$$

для **всех** x, y и **всех** $t \in [0, 1]$.

Нужны локальные критерии

Если функция дифференцируема, можно описать выпуклость через градиент. Если дважды дифференцируема — через гессиан.

Касательная к выпуклой функции



В отличие от обычной локальной аппроксимации, у выпуклой функции касательная оказывается **глобальной нижней оценкой**.



Критерий первого порядка

Теорема

Пусть f дифференцируема на выпуклом множестве X. Тогда

$$\boxed{f \text{ выпукла } \iff f(y) \geq f(x) + \nabla f(x)^\top (y - x)}$$

для любых $x, y \in X$.

Правая часть — касательная гиперплоскость к графику в точке x.

Связь с локальной моделью из лекции 2

Раньше мы писали

$$f(x+h) \approx f(x) + \nabla f(x)^\top h.$$

Это была **локальная** линейная модель.
Для выпуклой функции при $h = y - x$ получаем уже точное глобальное утверждение:

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x).}$$

Главная мысль

Линейная модель выпуклой функции никогда не переоценивает саму функцию.

Доказательство критерия: направление $\Rightarrow$

Предположим, что f выпукла. Зафиксируем x, y и определим функцию одной переменной

$$\varphi(t) = f(x + t(y - x)), \qquad t \in [0, 1].$$

По выпуклости

$$\varphi(t) \leq (1 - t)\varphi(0) + t\varphi(1).$$

Переносим $\varphi(0)$ и делим на $t > 0$:

$$\frac{\varphi(t) - \varphi(0)}{t} \leq \varphi(1) - \varphi(0).$$



Доказательство критерия: предел при $t \to 0+$

Переходим к пределу:

$$\varphi'(0) \leq f(y) - f(x).$$

Но по правилу цепочки

$$\varphi'(0) = \nabla f(x)^\top (y - x).$$

Следовательно,

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x).}$$



Обратное направление критерия

Теперь предположим, что для любых u, v

$$f(v) \geq f(u) + \nabla f(u)^\top (v - u).$$

Положим

$$z = (1 - t)x + ty.$$

Применим условие в точке z отдельно к x и y:

$$f(x) \geq f(z) + \nabla f(z)^\top (x - z),$$
$$f(y) \geq f(z) + \nabla f(z)^\top (y - z).$$

Завершение обратного направления

Умножим первое неравенство на $1 - t$, второе на t и сложим:

$$(1-t)f(x) + tf(y) \geq f(z) + \nabla f(z)^\top \big((1-t)(x-z) + t(y-z)\big).$$

Но

$$(1-t)(x-z) + t(y-z) = 0.$$

Поэтому

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

Это и есть выпуклость.



Что стоит запомнить из критерия первого порядка

Не обязательно начинать с формулы. Геометрически утверждение звучит так:

касательная к выпуклой функции — глобальная нижняя оценка.

Это позволяет превращать локальную информацию $\nabla f(x)$ в утверждение о функции во всём пространстве.

Для коллоквиума

Важно уметь и сформулировать критерий, и восстановить доказательство через функцию $\varphi(t) = f(x + t(y - x))$.

Самопроверка: квадратичная функция

Пусть

$$f(x) = \frac{1}{2} x^\top A x, \qquad A = A^\top.$$

Критерий первого порядка требует

$$\frac{1}{2} y^\top A y \geq \frac{1}{2} x^\top A x + x^\top A (y - x).$$

После упрощения:

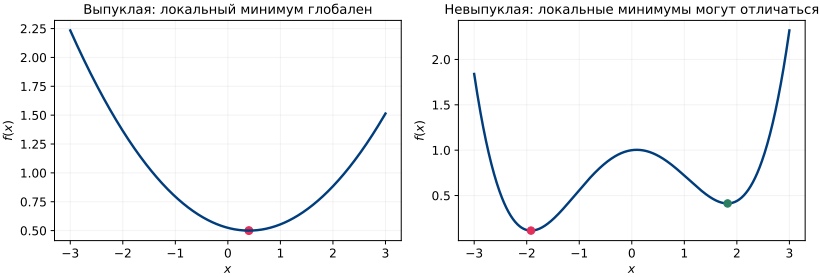
$$\boxed{\frac{1}{2} (y - x)^\top A (y - x) \geq 0.}$$

Какое условие на A обеспечивает это для любых x, y?

Локальный минимум выпуклой функции — глобальный

Теорема

Пусть f выпукла на выпуклом множестве X. Тогда любой локальный минимум $x^\star$ функции f является глобальным.





Доказательство: предположим обратное

Пусть $x^\star$ — локальный минимум, но существует $y \in X$ такое, что

$$f(y) < f(x^\star).$$

Рассмотрим точки

$$x_t = (1-t)x^\star + ty, \qquad t \in (0,1).$$

При малом $t > 0$ точка x_t находится сколь угодно близко к $x^\star$.



Доказательство: противоречие с локальностью

По выпуклости

$$\begin{aligned} f(x_t) &\leq (1-t)f(x^\star) + tf(y) \\ &< (1-t)f(x^\star) + tf(x^\star) \\ &= f(x^\star). \end{aligned}$$

Но x_t можно выбрать сколь угодно близко к $x^\star$. Это противоречит тому, что $x^\star$ — локальный минимум.



Условие оптимальности для дифференцируемой выпуклой функции

Теорема

Если f дифференцируема и выпукла на $\mathbb{R}^d$, то

$$\boxed{\nabla f(x^\star) = 0 \iff x^\star - \text{глобальный минимум } f.}$$

Левая часть — локальное условие. Выпуклость превращает его в глобальный результат.

Почему $\nabla f(x^\star) = 0$ достаточно

Из критерия первого порядка для любого y:

$$f(y) \geq f(x^\star) + \nabla f(x^\star)^\top (y - x^\star).$$

Если

$$\nabla f(x^\star) = 0,$$

то

$$\boxed{f(y) \geq f(x^\star) \quad \forall y.}$$

Следовательно, $x^\star$ — глобальный минимум.

Почему это фундаментально

Для произвольной гладкой функции условие

$$\nabla f(x) = 0$$

может означать:

минимум, максимум, седловую точку.

Для дифференцируемой выпуклой функции:

$$\boxed{\nabla f(x) = 0 \Longrightarrow \text{глобальный минимум.}}$$

Это одна из главных причин, почему выпуклые задачи настолько удобны.

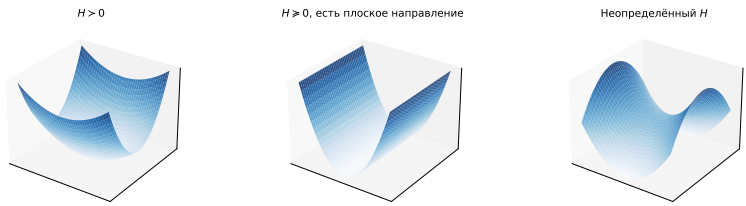
Можно ли распознать выпуклость через гессиан?

На лекции 2 мы получили формулу направленной кривизны:

$$\frac{d^2}{dt^2} f(x + tv)\Big|_{t=0} = v^\top \nabla^2 f(x) v.$$

Если функция выпукла, вдоль любой прямой она должна изгибаться **вверх**, а не вниз.

Знак направленной кривизны определяется гессианом





Критерий второго порядка

Теорема

Пусть f дважды непрерывно дифференцируема на выпуклом открытом множестве. Тогда

$$\boxed{f \text{ выпукла } \iff \nabla^2 f(x) \succeq 0 \quad \forall x.}$$

То есть выпуклость эквивалентна неотрицательной кривизне во всех направлениях и во всех точках.



Почему выпуклость даёт $\nabla^2 f \succeq 0$

Зафиксируем точку x и направление v. Рассмотрим одномерное сечение

$$\varphi(t) = f(x + tv).$$

Если f выпукла, то φ тоже выпукла как функция одной переменной. Поэтому

$$\varphi''(t) \geq 0.$$

Но

$$\varphi''(t) = v^\top \nabla^2 f(x + tv) v.$$

Значит, для любого v

$$v^\top \nabla^2 f(x) v \geq 0,$$

то есть $\nabla^2 f(x) \succeq 0$.

Обратное направление критерия второго порядка

Пусть теперь

$$\nabla^2 f(x) \succeq 0 \qquad \forall x.$$

Для любых x, y рассмотрим

$$\varphi(t) = f(x + t(y - x)).$$

Тогда

$$\varphi''(t) = (y - x)^\top \nabla^2 f(x + t(y - x))(y - x) \geq 0.$$

Следовательно, φ выпукла на $[0, 1]$, а значит

$$\varphi(t) \leq (1 - t)\varphi(0) + t\varphi(1).$$

Это ровно выпуклость f.

Квадратичная функция как частный случай

Для

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \qquad A = A^\top,$$

мы знаем

$$\nabla^2 f(x) = A.$$

Поэтому

$$\boxed{f \text{ выпукла } \iff A \succeq 0.}$$

Это полностью согласуется со спектральной геометрией лекции 3.

Практический алгоритм проверки выпуклости

Если функция дважды дифференцируема:

$$\boxed{f \longrightarrow H(x) = \nabla^2 f(x) \longrightarrow \text{проверить } H(x) \succeq 0 \text{ для всех } x.}$$

Но есть нюанс

Если гессиан зависит от x, проверка положительной полуопределённости **во всех точках** может быть сама по себе нетривиальной задачей.



Выпуклость не гарантирует единственность минимума

Рассмотрим

$$f(x, y) = x^2.$$

Функция выпукла, но

$$f(0, y) = 0$$

для любого y.
То есть глобальных минимумов бесконечно много:

$$\arg\min f = \{(0, y) : y \in \mathbb{R}\}.$$

Нужное усиление называется **строгой выпуклостью**.

Строгая выпуклость

Определение

Функция f называется **строго выпуклой**, если для любых $x \neq y$ и $t \in (0, 1)$

$$\boxed{f((1-t)x + ty) < (1-t)f(x) + tf(y).}$$

В отличие от обычной выпуклости, хорда теперь лежит **строго выше** графика между различными точками.

Строгая выпуклость даёт единственность

Теорема

Строго выпуклая функция имеет не более одного глобального минимума.

Предположим, что $x \neq y$ — два минимума и

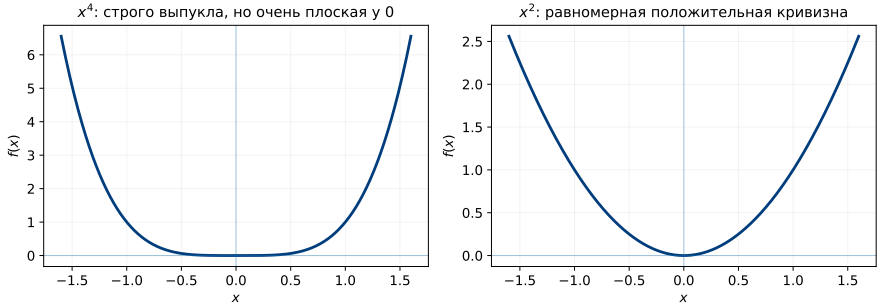
$$f(x) = f(y) = f^\star.$$

Тогда по строгой выпуклости

$$f\left(\frac{x+y}{2}\right) < \frac{1}{2}f(x) + \frac{1}{2}f(y) = f^\star,$$

противоречие.

Но строгая выпуклость не контролирует силу кривизны



Функция x^4 строго выпукла, но около нуля её вторая производная стремится к нулю. Значит, одной строгой выпуклости недостаточно для количественных оценок скорости.

Сильная выпуклость

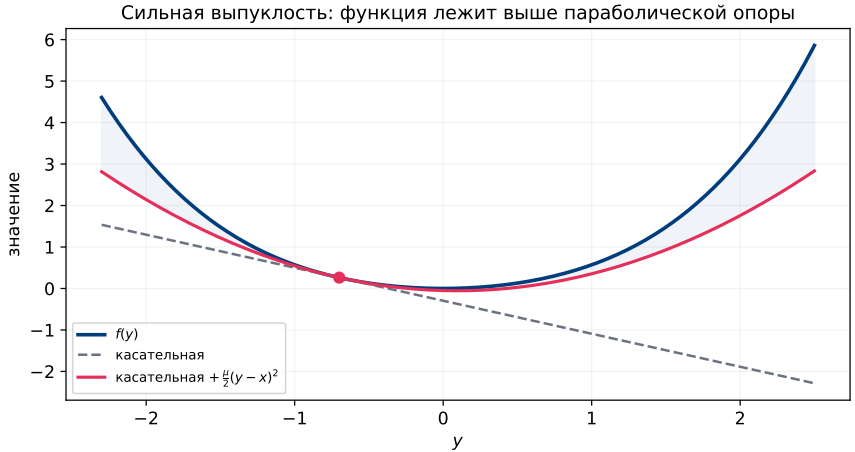
Определение

Дифференцируемая функция f называется μ-**сильно выпуклой**, если существует $\mu > 0$ такое, что для любых x, y

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2 .}$$

По сравнению с обычной выпуклостью появляется дополнительный положительный квадратичный запас.

Геометрия сильной выпуклости



Функция лежит выше не просто касательной, а **параболической опоры** с кривизной μ.

Критерий сильной выпуклости через гессиан

Для дважды дифференцируемой функции

$$\boxed{f\ \mu\text{-сильно выпукла} \iff \nabla^2 f(x) \succeq \mu I \quad \forall x.}$$

Удобный способ увидеть это: функция

$$g(x) = f(x) - \frac{\mu}{2}\|x\|^2$$

выпукла тогда и только тогда, когда

$$\nabla^2 g(x) = \nabla^2 f(x) - \mu I \succeq 0.$$

Связь с гладкостью и числом обусловленности

Если одновременно

$$\mu I \preceq \nabla^2 f(x) \preceq LI \qquad \forall x,$$

то кривизна функции во всех направлениях находится между μ и L.
Естественно определить

$$\boxed{\kappa = \frac{L}{\mu}.}$$

Связь с лекциями 3–4

Для квадратичной функции это ровно

$$\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

Пример из ML: метод наименьших квадратов

Рассмотрим уже знакомую задачу

$$f(w) = \frac{1}{2} \|Xw - y\|^2 .$$

Её гессиан

$$\nabla^2 f(w) = X^\top X.$$

Для любого z

$$z^\top X^\top X z = \|Xz\|^2 \geq 0.$$

Следовательно,

$$\boxed{X^\top X \succeq 0,}$$

и задача выпукла.



Когда минимум линейной регрессии единственный?

Если столбцы X линейно независимы, то

$$Xz \neq 0 \qquad \forall z \neq 0.$$

Поэтому

$$z^\top X^\top Xz = \|Xz\|^2 > 0,$$

то есть

$$X^\top X \succ 0.$$

Следовательно, функция строго и сильно выпукла, а минимум единственен.

Ridge добавляет кривизну

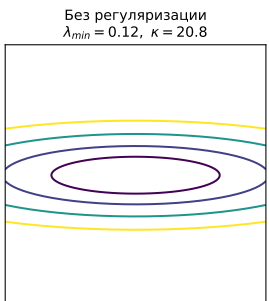
Для Ridge-регрессии

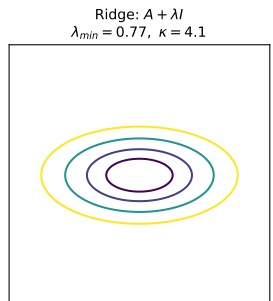
$$f(w) = \frac{1}{2}\|Xw - y\|^2 + \frac{\lambda}{2}\|w\|^2, \qquad \lambda > 0,$$

имеем

$$\nabla^2 f = X^\top X + \lambda I \succeq \lambda I.$$

Ridge добавляет кривизну во всех направлениях





Логистическая потеря тоже выпукла

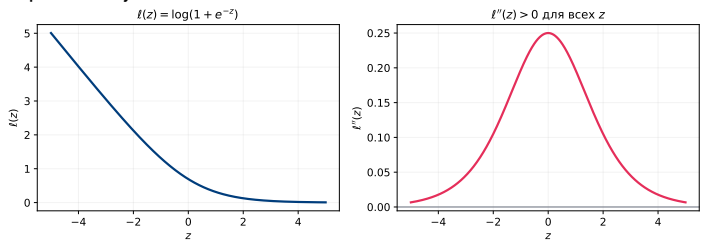
Для одного объекта удобно рассматривать

$$\ell(z) = \log(1 + e^{-z}).$$

Её вторая производная

$$\ell''(z) = \frac{e^z}{(1 + e^z)^2} > 0.$$

Следовательно, ℓ строго выпукла по z.



Сумма выпуклых функций остаётся выпуклой

Утверждение

Если f_i выпуклы и $\alpha_i \geq 0$, то

$$F(x) = \sum_i \alpha_i f_i(x)$$

выпукла.

Действительно,

$$\begin{aligned} F((1-t)x + ty) &= \sum_i \alpha_i f_i((1-t)x + ty) \\ &\leq \sum_i \alpha_i \big((1-t)f_i(x) + tf_i(y)\big) \\ &= (1-t)F(x) + tF(y). \end{aligned}$$

Отсюда средний эмпирический риск из выпуклых потерь тоже выпуклый.

Где эта теория перестаёт работать

Для параметров глубокой нейронной сети функция потерь обычно невыпукла.



Поэтому уже нельзя автоматически утверждать:

локальный минимум = глобальный,

$\nabla f(x) = 0 \Longrightarrow$ глобальный минимум.



Итоги и следующий вопрос

Сегодня мы получили цепочку

$$\boxed{\text{выпуклость} \implies f(y) \geq f(x) + \nabla f(x)^\top (y - x) \implies \nabla f(x^\star) = 0 \iff x^\star - \text{глобальный минимум}}$$

и критерий

$$f \text{ выпукла} \iff \nabla^2 f(x) \succeq 0.$$

Для сильно выпуклой и гладкой функции

$$\mu I \preceq \nabla^2 f(x) \preceq LI, \qquad \kappa = \frac{L}{\mu}.$$

Следующая лекция

Теперь мы знаем, **куда** должен прийти градиентный спуск. Следующий вопрос: **насколько быстро он туда приходит?**