

Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 6. Скорость сходимости градиентного спуска

Никита Лукьяненко

Что мы уже знаем про градиентный спуск

Для L-гладкой функции при шаге $\alpha = 1/L$:

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k)$$

и

$$\boxed{f(x_{k+1}) \leq f(x_k) - \frac{1}{2L}\|\nabla f(x_k)\|^2.}$$

Следовательно, значения функции не возрастают.

Но этого мало

Монотонное убывание ещё не говорит, **насколько быстро** мы приближаемся к оптимуму.



Из лекции 5: теперь мы знаем, куда хотим прийти

Для дифференцируемой выпуклой функции

$$\nabla f(x^*) = 0 \quad \Longrightarrow \quad x^* - \text{глобальный минимум.}$$

Для сильно выпуклой функции этот минимум единственен.

Сегодня вопрос уже не в существовании хорошего решения, а в сложности его поиска:

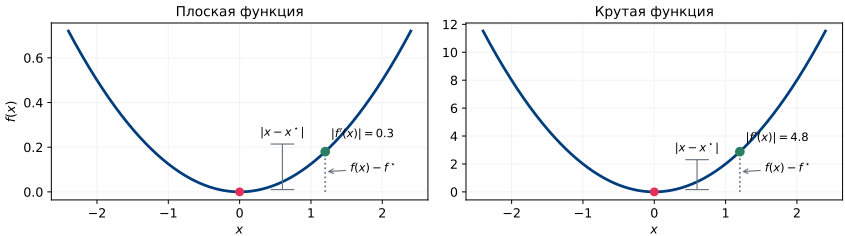
Сколько итераций нужно градиентному спуску?

Три разные меры ошибки

На итерации k можно измерять качество по-разному:

$$\boxed{f(x_k) - f^\star} \qquad \boxed{\|x_k - x^\star\|} \qquad \boxed{\|\nabla f(x_k)\|}.$$

Расстояние до минимума, ошибка по функции и градиент — разные величины



Они связаны, но не совпадают

Одинаковое расстояние до $x^\star$ может давать совершенно разную ошибку по функции — всё зависит от кривизны.
А маленький градиент сам по себе без дополнительных предположений не обязан означать маленькую ошибку по функции.

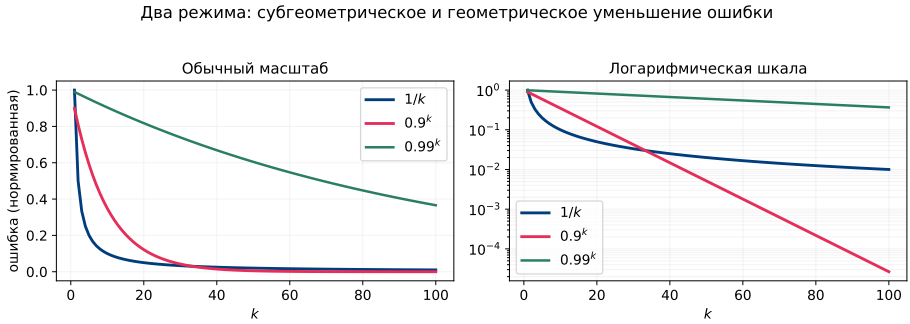
Основная мера сегодня

Будем оценивать

$$\boxed{f(x_k) - f^\star.}$$

Это непосредственно отвечает на вопрос, насколько хорошее значение целевой функции уже найдено.

Два режима, которые мы получим



Для выпуклой гладкой функции появится скорость порядка $1/k$, а сильная выпуклость даст геометрическое уменьшение ошибки.

Главные результаты лекции — пока без доказательства

Для выпуклой L-гладкой функции:

$$\boxed{f(x_k) - f^\star \leq \frac{L\,\|x_0 - x^\star\|^2}{2k}.}$$

Для μ-сильно выпуклой и L-гладкой:

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k \left(f(x_0) - f^\star\right).}$$

Наша задача — понять, откуда возникают обе формулы.

L-гладкость: ограничение на максимальную кривизну

Напомним определение:

$$\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|.$$

Если f дважды дифференцируема, то интуитивно

$$L \approx \text{максимальная кривизна функции.}$$

Для квадратичной функции

$$f(x) = \frac{1}{2} x^\top A x - b^\top x$$

имеем

$$L = \lambda_{\max}(A).$$

Главный инструмент из лекции 4

Из L-гладкости следует квадратичная верхняя оценка:

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2 .$$

При градиентном шаге $y = x - \frac{1}{L}\nabla f(x)$:

$$\boxed{f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 .}$$



Главный инструмент из лекции 5

Для выпуклой дифференцируемой функции

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

Это означает: касательная в x — глобальная нижняя оценка функции.

Нам понадобится одна специальная подстановка

Положим $y = x^\star$.

Выпуклость связывает градиент с ошибкой по функции

Подставляя $y = x^\star$, получаем

$$f^\star \geq f(x) + \nabla f(x)^\top (x^\star - x).$$

После переноса:

$$\boxed{f(x) - f^\star \leq \nabla f(x)^\top (x - x^\star).}$$

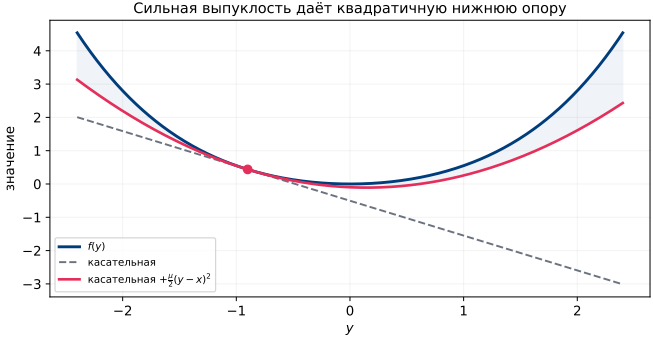
Справа появилась информация о направлении на оптимум.

Сильная выпуклость добавляет квадратичный запас

Если f μ-сильно выпукла, то

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2 .$$

Это более сильное утверждение, чем обычная выпуклость.



Карта доказательств

В первой части:

$$\boxed{L\text{-гладкость} + \text{выпуклость}} \Longrightarrow \boxed{f(x_k) - f^\star = O(1/k)}.$$

Во второй части добавим сильную выпуклость:

$$\boxed{L\text{-гладкость} + \mu\text{-сильная выпуклость}} \Longrightarrow \boxed{f(x_k) - f^\star \leq q^k C}.$$

И увидим, что

$$q = 1 - \frac{1}{\kappa}, \qquad \kappa = \frac{L}{\mu}.$$

Градиентный шаг даёт полезное равенство

Работаем с шагом

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k).$$

Переносим:

$$\frac{1}{L}\nabla f(x_k) = x_k - x_{k+1}.$$

Поэтому

$$\boxed{\nabla f(x_k) = L(x_k - x_{k+1}).}$$

Эта простая формула позволит заменить градиент геометрией последовательных точек.

Какой вид оценки нам хотелось бы получить?

Если удастся доказать неравенство вида

$$\boxed{f(x_{k+1}) - f^* \leq C\left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2\right),}$$

то при сложении по k большая часть членов сократится.

Именно это и произойдёт

Такие разности называются телескопическими: внутренние элементы исчезают при суммировании.

Шаг 1: применяем гладкость

К точкам x_k и x_{k+1}:

$$f(x_{k+1}) \leq f(x_k) + \nabla f(x_k)^\top (x_{k+1} - x_k) + \frac{L}{2} \|x_{k+1} - x_k\|^2 .$$

Вычитаем $f^\star$:

$$f(x_{k+1}) - f^\star \leq f(x_k) - f^\star + \nabla f(x_k)^\top (x_{k+1} - x_k) + \frac{L}{2} \|x_{k+1} - x_k\|^2 .$$

Шаг 2: используем выпуклость

Из слайда 11:

$$f(x_k) - f^\star \leq \nabla f(x_k)^\top (x_k - x^\star).$$

Подставляем:

$$\begin{aligned} f(x_{k+1}) - f^\star \leq & \nabla f(x_k)^\top (x_k - x^\star) \\ & + \nabla f(x_k)^\top (x_{k+1} - x_k) \\ & + \frac{L}{2} \|x_{k+1} - x_k\|^2 . \end{aligned}$$

Два скалярных произведения объединяются

Первые два члена имеют общий градиент:

$$\begin{aligned}&\nabla f(x_k)^\top (x_k - x^\star) + \nabla f(x_k)^\top (x_{k+1} - x_k)\\ &= \nabla f(x_k)^\top (x_{k+1} - x^\star).\end{aligned}$$

Поэтому

$$\boxed{f(x_{k+1}) - f^\star \leq \nabla f(x_k)^\top (x_{k+1} - x^\star) + \frac{L}{2} \|x_{k+1} - x_k\|^2 .}$$

Шаг 3: заменяем градиент через шаг

Используем

$$\nabla f(x_k) = L(x_k - x_{k+1}).$$

Получаем

$$f(x_{k+1}) - f^* \leq L(x_k - x_{k+1})^\top (x_{k+1} - x^*) + \frac{L}{2} \|x_k - x_{k+1}\|^2.$$

Осталось распознать чисто геометрическое тождество.



Трёхточечное тождество

Для любых a, b, c:

$$\boxed{2(a-b)^\top (b-c) = \|a-c\|^2 - \|a-b\|^2 - \|b-c\|^2 .}$$

В нашем случае:

$$a = x_k, \qquad b = x_{k+1}, \qquad c = x^\star .$$

Почему тождество верно

Заметим:

$$a - c = (a - b) + (b - c).$$

Тогда

$$\|a - c\|^2 = \|a - b\|^2 + \|b - c\|^2 + 2(a - b)^\top (b - c).$$

Перенос двух первых слагаемых даёт нужную формулу.

Никакой новой теории

Это просто раскрытие квадрата нормы суммы двух векторов.

Ключевое неравенство для выпуклого случая

Подставляя трёхточечное тождество, получаем

$$f(x_{k+1}) - f^\star \leq \frac{L}{2}\Big(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2 - \|x_k - x_{k+1}\|^2\Big) + \frac{L}{2}\|x_k - x_{k+1}\|^2 .$$

Последние два члена сокращаются:

$$\boxed{f(x_{k+1}) - f^\star \leq \frac{L}{2}\left(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2\right).}$$



Теперь складываем неравенства

Для $k = 0, \ldots, N-1$:

$$\sum_{k=0}^{N-1} \left(f(x_{k+1}) - f^\star\right) \leq \frac{L}{2} \sum_{k=0}^{N-1} \left(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2 \right).$$

Справа возникает телескопическая сумма.

Телескопическая сумма

Телескопическая сумма: внутренние расстояния сокращаются

$$
\begin{aligned}
&R_0^2 - R_1^2 \quad + \\
&R_1^2 - R_2^2 \quad + \quad \cdots \quad + (R_{N-1}^2 - R_N^2) \\
&R_2^2 - R_3^2 \\
&\quad = R_0^2 - R_N^2 \leq R_0^2
\end{aligned}
$$

В результате остаются только начальное и конечное расстояния.



После суммирования

Получаем

$$\sum_{k=1}^{N}(f(x_k)-f^\star) \leq \frac{L}{2}\left(\|x_0-x^\star\|^2 - \|x_N-x^\star\|^2\right).$$

Поскольку норма неотрицательна,

$$\boxed{\sum_{k=1}^{N}(f(x_k)-f^\star) \leq \frac{L}{2}\|x_0-x^\star\|^2.}$$



Используем монотонность значений функции

По лемме об убывании

$$f(x_N) \leq f(x_{N-1}) \leq \cdots \leq f(x_1).$$

Значит каждое из первых N отклонений не меньше последнего:

$$f(x_k) - f^\star \geq f(x_N) - f^\star.$$

Поэтому

$$\boxed{N\big(f(x_N) - f^\star\big) \leq \sum_{k=1}^{N} \big(f(x_k) - f^\star\big).}$$

Теорема: скорость GD для выпуклой гладкой функции

Теорема

Пусть f выпукла и L-гладка, а

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k).$$

Тогда для любого $N \geq 1$

$$\boxed{f(x_N) - f^\star \leq \frac{L\|x_0 - x^\star\|^2}{2N}.}$$

Это и есть скорость порядка $O(1/N)$.

Доказательство теоремы — в трёх строках

Из ключевого неравенства:

$$\sum_{k=1}^{N} \left(f(x_k) - f^\star\right) \leq \frac{L}{2} \|x_0 - x^\star\|^2 .$$

Из монотонности:

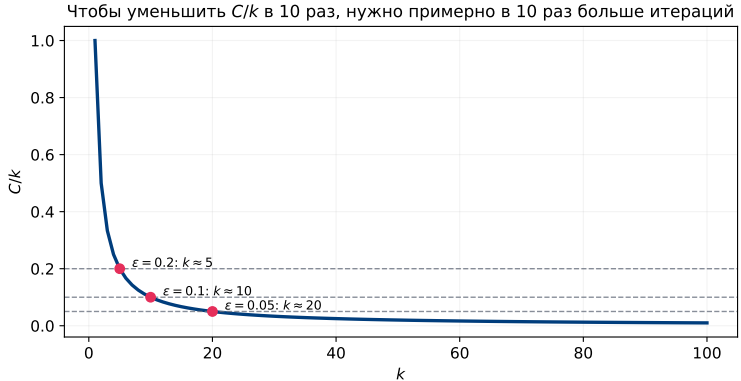
$$N\left(f(x_N) - f^\star\right) \leq \sum_{k=1}^{N} \left(f(x_k) - f^\star\right).$$

Следовательно,

$$N\left(f(x_N) - f^\star\right) \leq \frac{L}{2} \|x_0 - x^\star\|^2 ,$$

откуда делением на N получается утверждение.

Что означает $O(1/k)$?



При удвоении числа итераций гарантированная верхняя оценка примерно уменьшается вдвое.

Сколько итераций нужно для точности ε?

Хотим обеспечить

$$f(x_k) - f^\star \leq \varepsilon.$$

Из теоремы достаточно потребовать

$$\frac{L \|x_0 - x^\star\|^2}{2k} \leq \varepsilon.$$

Следовательно,

$$\boxed{k \geq \frac{L \|x_0 - x^\star\|^2}{2\varepsilon}.}$$

То есть сложность по точности — порядка $O(1/\varepsilon)$.



Почему такая скорость может быть медленной

Если хотим улучшить точность в десять раз,

$$\varepsilon \longrightarrow \frac{\varepsilon}{10},$$

то верхняя оценка числа итераций увеличивается примерно в десять раз.

Пример

Переход от ошибки 10^{-2} к 10^{-3} в худшей гарантии требует на порядок большего k.

Важно: это верхняя оценка, а не точный прогноз

Теорема утверждает

$$f(x_k) - f^\star \leq \frac{C}{k}.$$

Она **не** утверждает, что

$$f(x_k) - f^\star = \frac{C}{k}.$$

Как читать оценки сходимости

Они гарантируют: алгоритм работает **не хуже определённого сценария** на всём рассматриваемом классе функций. На конкретной задаче он может быть гораздо быстрее.



Теперь добавим сильную выпуклость

Пусть f одновременно

- L-гладкая;
- μ-сильно выпуклая.

Тогда

$$0 < \mu \leq L.$$

Сильная выпуклость даст связь между величиной градиента и ошибкой по функции — именно её не хватало раньше.



Что именно даёт сильная выпуклость

Для любого y:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2 .$$

Правая часть — квадратичная функция по y.

Идея

Если она является глобальной нижней оценкой f, можно минимизировать её и получить нижнюю оценку на само $f^\star$.

Минимизируем квадратичную нижнюю модель

Положим

$$h = y - x.$$

Нужно минимизировать по h

$$q(h) = \nabla f(x)^\top h + \frac{\mu}{2} \|h\|^2.$$

Условие стационарности:

$$\nabla_h q(h) = \nabla f(x) + \mu h = 0.$$

Следовательно,

$$\boxed{h^\star = -\frac{1}{\mu} \nabla f(x).}$$

Минимальное значение модели

Подставляем $h^\star = -\frac{1}{\mu}\nabla f(x)$:

$$q(h^\star) = -\frac{1}{\mu}\|\nabla f(x)\|^2 + \frac{\mu}{2}\frac{1}{\mu^2}\|\nabla f(x)\|^2$$
$$= -\frac{1}{2\mu}\|\nabla f(x)\|^2 .$$

Поэтому для любого y и, в частности, для минимума:

$$f^\star \geq f(x) - \frac{1}{2\mu}\|\nabla f(x)\|^2 .$$

Сильная выпуклость не позволяет градиенту быть слишком маленьким

Переносим члены:

$$f(x) - f^\star \leq \frac{1}{2\mu} \|\nabla f(x)\|^2 .$$

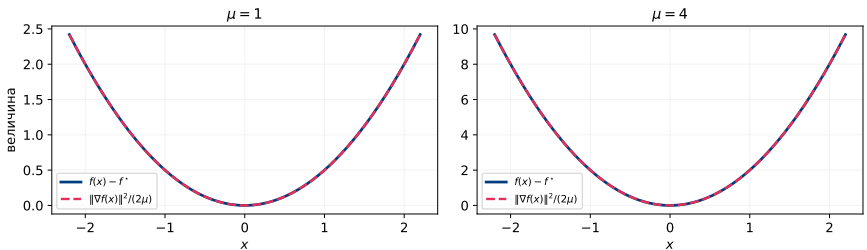
Или эквивалентно

$$\boxed{\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^\star).}$$

Это ключевой мост между леммой об убывании и ошибкой по функции.

Геометрический смысл предыдущего неравенства

Для квадратичной функции неравенство $\|\nabla f\|^2 \geq 2\mu(f - f^*)$ достигается с равенством



В сильно выпуклой задаче заметное отставание по функции обязано сопровождаться достаточно большим градиентом.



Снова используем лемму об убывании

При шаге $1/L$:

$$f(x_{k+1}) - f^\star \leq f(x_k) - f^\star - \frac{1}{2L} \|\nabla f(x_k)\|^2 .$$

Из сильной выпуклости:

$$\|\nabla f(x_k)\|^2 \geq 2\mu \big(f(x_k) - f^\star\big).$$

Подставляем нижнюю оценку на градиент в отрицательный член.



Получаем сокращение ошибки за один шаг

$$f(x_{k+1}) - f^\star \leq f(x_k) - f^\star - \frac{1}{2L} \cdot 2\mu \big(f(x_k) - f^\star\big)$$
$$= \left(1 - \frac{\mu}{L}\right) \big(f(x_k) - f^\star\big).$$

То есть

$$\boxed{f(x_{k+1}) - f^\star \leq \left(1 - \frac{\mu}{L}\right) \big(f(x_k) - f^\star\big).}$$

Каждая итерация сокращает верхнюю оценку на один и тот же множитель.



Повторяем неравенство k раз

Последовательно:

$$f(x_1) - f^\star \leq q\big(f(x_0) - f^\star\big),$$

$$f(x_2) - f^\star \leq q\big(f(x_1) - f^\star\big) \leq q^2\big(f(x_0) - f^\star\big),$$

где

$$q = 1 - \frac{\mu}{L}.$$

Поэтому

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k \big(f(x_0) - f^\star\big).}$$

Теорема о линейной сходимости

Теорема

Пусть f μ-сильно выпукла и L-гладка. Для GD с шагом $1/L$:

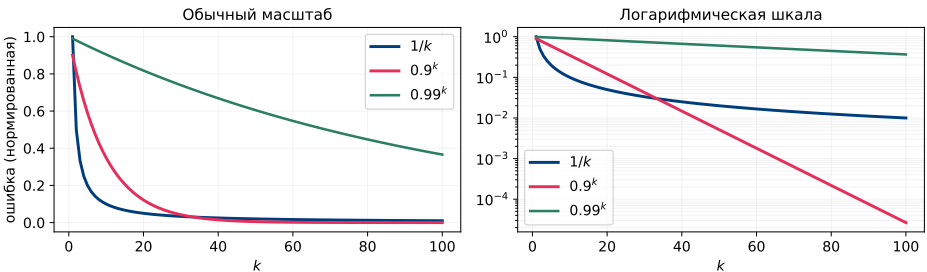
$$\boxed{f(x_k) - f^\star \le \left(1 - \frac{\mu}{L}\right)^k \left(f(x_0) - f^\star\right).}$$

Терминология

«Линейная сходимость» не означает движение по прямой. Это стандартное название геометрического закона $e_{k+1} \le q e_k$, где $q < 1$.

$1/k$ против геометрической скорости

Два режима: субгеометрическое и геометрическое уменьшение ошибки



Геометрическое уменьшение особенно хорошо видно на логарифмической шкале: оно становится почти прямой линией.

Число обусловленности снова появляется

Определим

$$\boxed{\kappa = \frac{L}{\mu}.}$$

Тогда множитель сокращения

$$q = 1 - \frac{\mu}{L} = 1 - \frac{1}{\kappa}.$$

Следовательно,

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{1}{\kappa}\right)^k \left(f(x_0) - f^\star\right).}$$



Хорошо обусловленная задача

Пусть

$$\kappa = 2.$$

Тогда

$$q = 1 - \frac{1}{2} = 0.5.$$

То есть гарантированная верхняя оценка ошибки делится примерно пополам на каждой итерации:

$$1,\ 0.5,\ 0.25,\ 0.125, \ldots$$

Плохо обусловленная задача

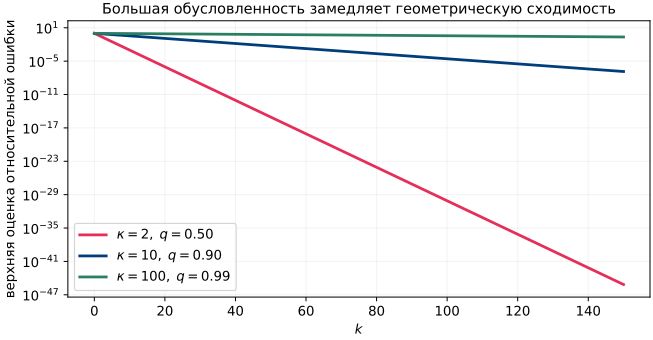
Пусть

$$\kappa = 100.$$

Тогда

$$q = 1 - \frac{1}{100} = 0.99.$$

За одну итерацию гарантированно исчезает лишь около 1% текущей ошибки.



Сколько итераций нужно в сильно выпуклом случае?

Хотим

$$\left(1 - \frac{1}{\kappa}\right)^k \leq \varepsilon.$$

Используем

$$1 - u \leq e^{-u}, \qquad u \geq 0.$$

Тогда

$$\left(1 - \frac{1}{\kappa}\right)^k \leq e^{-k/\kappa}.$$



Откуда возникает логарифм

Чтобы

$$e^{-k/\kappa} \le \varepsilon,$$

достаточно

$$-\frac{k}{\kappa} \le \log \varepsilon.$$

То есть

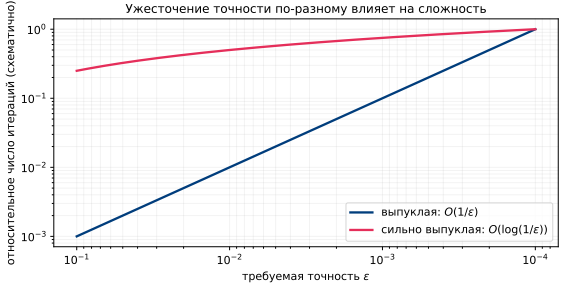
$$\boxed{k \ge \kappa \log \frac{1}{\varepsilon}.}$$

В обозначениях порядка:

$$\boxed{k = O\left(\kappa \log \frac{1}{\varepsilon}\right).}$$

Сравнение двух классов функций

	Выпуклая + гладкая	Сильно выпуклая + гладкая
Ошибка	$O(1/k)$	$O(q^k)$
До точности ε	$O(1/\varepsilon)$	$O(\log(1/\varepsilon))$
Минимум единственен	не обязательно	да
Роль κ	не обязательна	определяет скорость



Связь с квадратичными задачами

Для

$$f(x) = \frac{1}{2} x^\top A x - b^\top x, \qquad A \succ 0,$$

имеем

$$L = \lambda_{\max}(A), \qquad \mu = \lambda_{\min}(A).$$

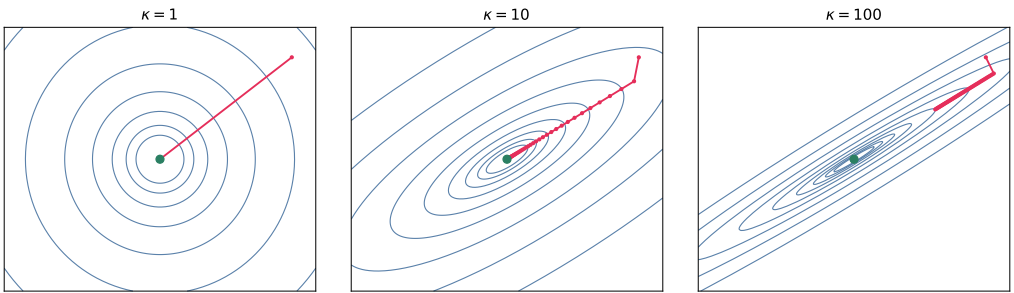
Поэтому

$$\boxed{\kappa = \frac{L}{\mu} = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.}$$

Это ровно то же число обусловленности, которое появилось на лекции 3.

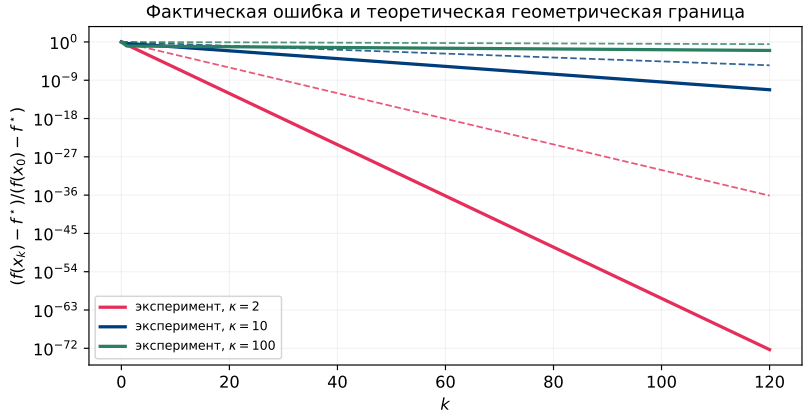
Один минимум, разные числа обусловленности

Один и тот же GD с шагом $1/L$: вытянутая геометрия приводит к медленному движению



Чем более вытянуты линии уровня, тем дольше градиентный спуск избавляется от медленной компоненты ошибки.

Фактическая ошибка и теоретическая граница



Пунктир — гарантированная скорость $(1 - 1/\kappa)^k$; сплошные линии — реальный эксперимент.

Зачем используют логарифмический масштаб

Если

$$e_k = Cq^k, \qquad 0 < q < 1,$$

то после логарифмирования

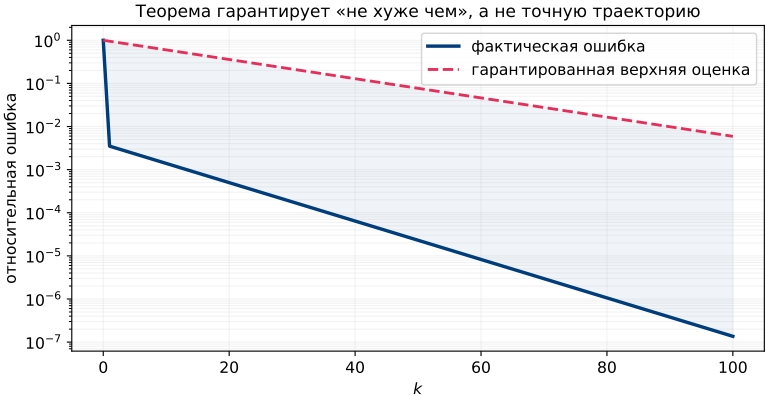
$$\log e_k = \log C + k \log q.$$

Это линейная функция от k.

Практический признак

Почти прямая линия ошибки на полулогарифмическом графике — характерный признак геометрической сходимости.

Теория против эксперимента



Теоретическая оценка строится для всего класса задач и потому часто консервативна. Она должна быть над фактической ошибкой, а не совпадать с ней.

Самопроверка

Пусть

$$L = 20, \qquad \mu = 2.$$

Ответьте:

1. Чему равно κ?
2. Чему равен множитель $q = 1 - 1/\kappa$?
3. Во сколько раз примерно уменьшится верхняя оценка ошибки после 20 шагов?

$$\boxed{\kappa = 10, \qquad q = 0.9, \qquad q^{20} \approx 0.12.}$$



Карта лекции

Для выпуклой L-гладкой функции:

$$\boxed{f(x_k) - f^\star \leq \frac{L \|x_0 - x^\star\|^2}{2k}.}$$

Добавляем μ-сильную выпуклость:

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k \left(f(x_0) - f^\star\right).}$$

Именно отношение

$$\boxed{\kappa = L/\mu}$$

управляет худшей гарантированной геометрической скоростью.

Следующий естественный вопрос

При плохой обусловленности

$$\kappa \gg 1$$

обычный градиентный спуск может быть медленным, даже если задача выпуклая и очень хорошо изучена.

Что можно сделать?

Можно ли изменить алгоритм так, чтобы быстрее проходить длинные узкие долины и меньше зависеть от κ?

Это приведёт нас к более продвинутым методам оптимизации.