



Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 6. Скорость сходимости градиентного спуска

Никита Лукьяненко



Что мы уже знаем про градиентный спуск

Для L -гладкой функции при шаге $\alpha = 1/L$:

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k)$$

и

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Следовательно, значения функции не возрастают.

Но этого мало

Монотонное убывание ещё не говорит, **насколько быстро** мы приближаемся к оптимуму.



Из лекции 5: теперь мы знаем, куда хотим прийти

Для дифференцируемой выпуклой функции

$$\nabla f(x^*) = 0 \implies x^* \text{ — глобальный минимум.}$$

Для сильно выпуклой функции этот минимум единственен.

Сегодня вопрос уже не в существовании хорошего решения, а в сложности его поиска:

Сколько итераций нужно градиентному спуску?



Три разные меры ошибки


На итерации k можно измерять качество по-разному:

$$f(x_k) - f^*$$

$$\|x_k - x^*\|$$

$$\|\nabla f(x_k)\|.$$

Расстояние до минимума, ошибка по функции и градиент — разные величины





Они связаны, но не совпадают

Одинаковое расстояние до x^* может давать совершенно разную ошибку по функции — всё зависит от кривизны.

А маленький градиент сам по себе без дополнительных предположений не обязан означать маленькую ошибку по функции.

Основная мера сегодня

Будем оценивать


$$f(x_k) - f^*.$$

Это непосредственно отвечает на вопрос, насколько хорошее значение целевой функции уже найдено.



Два режима, которые мы получим

Два режима: субгеометрическое и геометрическое уменьшение ошибки



Для выпуклой гладкой функции появится скорость порядка $1/k$, а сильная выпуклость даст геометрическое уменьшение ошибки.



Главные результаты лекции — пока без доказательства

Для выпуклой L -гладкой функции:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|^2}{2k}.$$

Для μ -сильно выпуклой и L -гладкой:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*).$$

Наша задача — понять, откуда возникают обе формулы.



L -гладкость: ограничение на максимальную кривизну

Напомним определение:

$$\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|.$$

Если f дважды дифференцируема, то интуитивно

$L \approx$ максимальная кривизна функции.

Для квадратичной функции

$$f(x) = \frac{1}{2} x^\top A x - b^\top x$$

имеем

$$L = \lambda_{\max}(A).$$



Главный инструмент из лекции 4

Из L -гладкости следует квадратичная верхняя оценка:

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2.$$

При градиентном шаге $y = x - \frac{1}{L} \nabla f(x)$:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2.$$



Главный инструмент из лекции 5

Для выпуклой дифференцируемой функции

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

Это означает: касательная в x — глобальная нижняя оценка функции.

Нам понадобится одна специальная подстановка

Положим $y = x^*$.



Выпуклость связывает градиент с ошибкой по функции

Подставляя $y = x^*$, получаем

$$f^* \geq f(x) + \nabla f(x)^\top (x^* - x).$$

После переноса:

$$f(x) - f^* \leq \nabla f(x)^\top (x - x^*).$$

Справа появилась информация о направлении на оптимум.




Сильная выпуклость добавляет квадратичный запас

Если f μ -сильно выпукла, то

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

Это более сильное утверждение, чем обычная выпуклость.

Сильная выпуклость даёт квадратичную нижнюю опору





Карта доказательств

В первой части:

$$\boxed{L\text{-гладкость} + \text{выпуклость}} \implies \boxed{f(x_k) - f^* = O(1/k)}.$$

Во второй части добавим сильную выпуклость:

$$\boxed{L\text{-гладкость} + \mu\text{-сильная выпуклость}} \implies \boxed{f(x_k) - f^* \leq q^k C}.$$

И увидим, что

$$q = 1 - \frac{1}{\kappa}, \quad \kappa = \frac{L}{\mu}.$$



Градиентный шаг даёт полезное равенство

Работаем с шагом

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k).$$

Переносим:

$$\frac{1}{L} \nabla f(x_k) = x_k - x_{k+1}.$$

Поэтому

$$\boxed{\nabla f(x_k) = L(x_k - x_{k+1}).}$$

Эта простая формула позволит заменить градиент геометрией последовательных точек.



Какой вид оценки нам хотелось бы получить?

Если удастся доказать неравенство вида

$$f(x_{k+1}) - f^* \leq C \left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right),$$

то при сложении по k большая часть членов сократится.

Именно это и произойдёт

Такие разности называются телескопическими: внутренние элементы исчезают при суммировании.



Шаг 1: применяем гладкость

К точкам x_k и x_{k+1} :

$$f(x_{k+1}) \leq f(x_k) + \nabla f(x_k)^\top (x_{k+1} - x_k) + \frac{L}{2} \|x_{k+1} - x_k\|^2.$$

Вычитаем f^* :

$$f(x_{k+1}) - f^* \leq f(x_k) - f^* + \nabla f(x_k)^\top (x_{k+1} - x_k) + \frac{L}{2} \|x_{k+1} - x_k\|^2.$$



Шаг 2: используем выпуклость

Из слайда 11:

$$f(x_k) - f^* \leq \nabla f(x_k)^\top (x_k - x^*).$$

Подставляем:

$$\begin{aligned} f(x_{k+1}) - f^* &\leq \nabla f(x_k)^\top (x_k - x^*) \\ &\quad + \nabla f(x_k)^\top (x_{k+1} - x_k) \\ &\quad + \frac{L}{2} \|x_{k+1} - x_k\|^2. \end{aligned}$$



Два скалярных произведения объединяются

Первые два члена имеют общий градиент:

$$\begin{aligned}\nabla f(x_k)^\top (x_k - x^*) + \nabla f(x_k)^\top (x_{k+1} - x_k) \\ = \nabla f(x_k)^\top (x_{k+1} - x^*).\end{aligned}$$

Поэтому

$$f(x_{k+1}) - f^* \leq \nabla f(x_k)^\top (x_{k+1} - x^*) + \frac{L}{2} \|x_{k+1} - x_k\|^2.$$



Шаг 3: заменяем градиент через шаг

Используем

$$\nabla f(x_k) = L(x_k - x_{k+1}).$$

Получаем

$$\begin{aligned} f(x_{k+1}) - f^* &\leq L(x_k - x_{k+1})^\top (x_{k+1} - x^*) \\ &\quad + \frac{L}{2} \|x_k - x_{k+1}\|^2. \end{aligned}$$

Осталось распознать чисто геометрическое тождество.



Трёхточечное тождество

Для любых a, b, c :

$$2(a - b)^\top (b - c) = \|a - c\|^2 - \|a - b\|^2 - \|b - c\|^2.$$

В нашем случае:

$$a = x_k, \quad b = x_{k+1}, \quad c = x^*.$$



Почему тождество верно

Заметим:

$$a - c = (a - b) + (b - c).$$

Тогда

$$\begin{aligned}\|a - c\|^2 &= \|a - b\|^2 + \|b - c\|^2 \\ &\quad + 2(a - b)^\top (b - c).\end{aligned}$$

Перенос двух первых слагаемых даёт нужную формулу.

Никакой новой теории

Это просто раскрытие квадрата нормы суммы двух векторов.



Ключевое неравенство для выпуклого случая

Подставляя трёхточечное тождество, получаем

$$f(x_{k+1}) - f^* \leq \frac{L}{2} \left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 - \|x_k - x_{k+1}\|^2 \right) + \frac{L}{2} \|x_k - x_{k+1}\|^2.$$

Последние два члена сокращаются:

$$f(x_{k+1}) - f^* \leq \frac{L}{2} \left(\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right).$$



Теперь складываем неравенства

Для $k = 0, \dots, N-1$:

$$\sum_{k=0}^{N-1} (f(x_{k+1}) - f^*) \leq \frac{L}{2} \sum_{k=0}^{N-1} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2).$$

Справа возникает телескопическая сумма.



Телескопическая сумма

Телескопическая сумма: внутренние расстояния сокращаются

$$\begin{aligned} R_0^2 - R_1^2 &+ \\ R_1^2 - R_2^2 &+ \dots + (R_{N-1}^2 - R_N^2) \\ R_2^2 - R_3^2 & \\ &= R_0^2 - R_N^2 \leq R_0^2 \end{aligned}$$

В результате остаются только начальное и конечное расстояния.



После суммирования

Получаем

$$\sum_{k=1}^N (f(x_k) - f^*) \leq \frac{L}{2} \left(\|x_0 - x^*\|^2 - \|x_N - x^*\|^2 \right).$$

Поскольку норма неотрицательна,

$$\sum_{k=1}^N (f(x_k) - f^*) \leq \frac{L}{2} \|x_0 - x^*\|^2.$$



Используем монотонность значений функции

По лемме об убывании

$$f(x_N) \leq f(x_{N-1}) \leq \dots \leq f(x_1).$$

Значит каждое из первых N отклонений не меньше последнего:

$$f(x_k) - f^* \geq f(x_N) - f^*.$$

Поэтому

$$N(f(x_N) - f^*) \leq \sum_{k=1}^N (f(x_k) - f^*).$$



Теорема: скорость GD для выпуклой гладкой функции

Теорема

Пусть f выпукла и L -гладка, а

$$x_{k+1} = x_k - \frac{1}{L} \nabla f(x_k).$$

Тогда для любого $N \geq 1$

$$f(x_N) - f^* \leq \frac{L \|x_0 - x^*\|^2}{2N}.$$

Это и есть скорость порядка $O(1/N)$.



Доказательство теоремы — в трёх строках

Из ключевого неравенства:

$$\sum_{k=1}^N (f(x_k) - f^*) \leq \frac{L}{2} \|x_0 - x^*\|^2.$$

Из монотонности:

$$N(f(x_N) - f^*) \leq \sum_{k=1}^N (f(x_k) - f^*).$$


Следовательно,

$$N(f(x_N) - f^*) \leq \frac{L}{2} \|x_0 - x^*\|^2,$$

откуда делением на N получается утверждение.



Что означает $O(1/k)$?



При удвоении числа итераций гарантированная верхняя оценка примерно уменьшается вдвое.



Сколько итераций нужно для точности ε ?

Хотим обеспечить

$$f(x_k) - f^* \leq \varepsilon.$$

Из теоремы достаточно потребовать

$$\frac{L \|x_0 - x^*\|^2}{2k} \leq \varepsilon.$$

Следовательно,

$$k \geq \frac{L \|x_0 - x^*\|^2}{2\varepsilon}.$$

То есть сложность по точности — порядка $O(1/\varepsilon)$.



Почему такая скорость может быть медленной

Если хотим улучшить точность в десять раз,

$$\varepsilon \longrightarrow \frac{\varepsilon}{10},$$

то верхняя оценка числа итераций увеличивается примерно в десять раз.

Пример

Переход от ошибки 10^{-2} к 10^{-3} в худшей гарантии требует на порядок большего k .



Важно: это верхняя оценка, а не точный прогноз

Теорема утверждает

$$f(x_k) - f^* \leq \frac{C}{k}.$$

Она **не** утверждает, что

$$f(x_k) - f^* = \frac{C}{k}.$$

Как читать оценки сходимости

Они гарантируют: алгоритм работает **не хуже определённого сценария** на всём рассматриваемом классе функций. На конкретной задаче он может быть гораздо быстрее.



Теперь добавим сильную выпуклость

Пусть f одновременно

- L -гладкая;
- μ -сильно выпуклая.

Тогда

$$0 < \mu \leq L.$$

Сильная выпуклость даст связь между величиной градиента и ошибкой по функции — именно её не хватало раньше.



Что именно даёт сильная выпуклость

Для любого y :

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|^2.$$

Правая часть — квадратичная функция по y .

Идея

Если она является глобальной нижней оценкой f , можно минимизировать её и получить нижнюю оценку на само f^* .



Минимизируем квадратичную нижнюю модель

Положим

$$h = y - x.$$

Нужно минимизировать по h

$$q(h) = \nabla f(x)^\top h + \frac{\mu}{2} \|h\|^2.$$

Условие стационарности:

$$\nabla_h q(h) = \nabla f(x) + \mu h = 0.$$

Следовательно,

$$h^* = -\frac{1}{\mu} \nabla f(x).$$



Минимальное значение модели

Подставляем $h^* = -\frac{1}{\mu} \nabla f(x)$:

$$\begin{aligned} q(h^*) &= -\frac{1}{\mu} \|\nabla f(x)\|^2 + \frac{\mu}{2} \frac{1}{\mu^2} \|\nabla f(x)\|^2 \\ &= -\frac{1}{2\mu} \|\nabla f(x)\|^2. \end{aligned}$$

Поэтому для любого u и, в частности, для минимума:

$$f^* \geq f(x) - \frac{1}{2\mu} \|\nabla f(x)\|^2.$$



Сильная выпуклость не позволяет градиенту быть слишком маленьким

Переносим члены:

$$f(x) - f^* \leq \frac{1}{2\mu} \|\nabla f(x)\|^2.$$

Или эквивалентно


$$\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^*).$$

Это ключевой мост между леммой об убывании и ошибкой по функции.



Геометрический смысл предыдущего неравенства

Для квадратичной функции неравенство $\|\nabla f\|^2 \geq 2\mu(f - f^*)$ достигается с равенством



В сильно выпуклой задаче заметное отставание по функции обязано сопровождаться достаточно большим градиентом.



Снова используем лемму об убывании

При шаге $1/L$:

$$f(x_{k+1}) - f^* \leq f(x_k) - f^* - \frac{1}{2L} \|\nabla f(x_k)\|^2.$$

Из сильной выпуклости:

$$\|\nabla f(x_k)\|^2 \geq 2\mu(f(x_k) - f^*).$$

Подставляем нижнюю оценку на градиент в отрицательный член.



Получаем сокращение ошибки за один шаг

$$\begin{aligned} f(x_{k+1}) - f^* &\leq f(x_k) - f^* - \frac{1}{2L} \cdot 2\mu(f(x_k) - f^*) \\ &= \left(1 - \frac{\mu}{L}\right) (f(x_k) - f^*). \end{aligned}$$

То есть

$$f(x_{k+1}) - f^* \leq \left(1 - \frac{\mu}{L}\right) (f(x_k) - f^*).$$

Каждая итерация сокращает верхнюю оценку на один и тот же множитель.



Повторяем неравенство k раз

Последовательно:

$$f(x_1) - f^* \leq q(f(x_0) - f^*),$$

$$f(x_2) - f^* \leq q(f(x_1) - f^*) \leq q^2(f(x_0) - f^*),$$

где

$$q = 1 - \frac{\mu}{L}.$$

Поэтому

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*).$$



Теорема о линейной сходимости

Теорема

Пусть f μ -сильно выпукла и L -гладка. Для GD с шагом $1/L$:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*).$$



Терминология

«Линейная сходимость» не означает движение по прямой. Это стандартное название геометрического закона $e_{k+1} \leq qe_k$, где $q < 1$.



$1/k$ против геометрической скорости

Два режима: субгеометрическое и геометрическое уменьшение ошибки



Геометрическое уменьшение особенно хорошо видно на логарифмической шкале: оно становится почти прямой линией.



Число обусловленности снова появляется

Определим

$$\kappa = \frac{L}{\mu}.$$

Тогда множитель сокращения

$$q = 1 - \frac{\mu}{L} = 1 - \frac{1}{\kappa}.$$

Следовательно,

$$f(x_k) - f^* \leq \left(1 - \frac{1}{\kappa}\right)^k (f(x_0) - f^*).$$



Хорошо обусловленная задача

Пусть

$$\kappa = 2.$$

Тогда

$$q = 1 - \frac{1}{2} = 0.5.$$

То есть гарантированная верхняя оценка ошибки делится примерно пополам на каждой итерации:

$$1, 0.5, 0.25, 0.125, \dots$$



Плохо обусловленная задача

Пусть


$$\kappa = 100.$$

Тогда

$$q = 1 - \frac{1}{100} = 0.99.$$

За одну итерацию гарантированно исчезает лишь около 1% текущей ошибки.

Большая обусловленность замедляет геометрическую сходимость





Сколько итераций нужно в сильно выпуклом случае?

Хотим

$$\left(1 - \frac{1}{\kappa}\right)^k \leq \varepsilon.$$

Используем

$$1 - u \leq e^{-u}, \quad u \geq 0.$$

Тогда

$$\left(1 - \frac{1}{\kappa}\right)^k \leq e^{-k/\kappa}.$$



Откуда возникает логарифм

Чтобы

$$e^{-k/\kappa} \leq \varepsilon,$$

достаточно

$$-\frac{k}{\kappa} \leq \log \varepsilon.$$

То есть

$$k \geq \kappa \log \frac{1}{\varepsilon}.$$


В обозначениях порядка:

$$k = O\left(\kappa \log \frac{1}{\varepsilon}\right).$$



Сравнение двух классов функций

	Выпуклая + гладкая	Сильно выпуклая + гладкая
Ошибка	$O(1/k)$	$O(q^k)$
До точности ε	$O(1/\varepsilon)$	$O(\log(1/\varepsilon))$
Минимум единственен	не обязательно	да
Роль κ	не обязательна	определяет скорость





Связь с квадратичными задачами

Для

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x, \quad A \succ 0,$$

имеем

$$L = \lambda_{\max}(A), \quad \mu = \lambda_{\min}(A).$$

Поэтому

$$\kappa = \frac{L}{\mu} = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$


Это ровно то же число обусловленности, которое появилось на лекции 3.




Один минимум, разные числа обусловленности

Один и тот же GD с шагом $1/L$: вытянутая геометрия приводит к медленному движению


$\kappa = 1$



$\kappa = 10$




$\kappa = 100$



Чем более вытянуты линии уровня, тем дольше градиентный спуск избавляется от медленной компоненты ошибки.



Фактическая ошибка и теоретическая граница



Пунктир — гарантированная скорость $(1 - 1/\kappa)^k$; сплошные линии — реальный эксперимент.



Зачем используют логарифмический масштаб

Если

$$e_k = Cq^k, \quad 0 < q < 1,$$

то после логарифмирования

$$\log e_k = \log C + k \log q.$$


Это линейная функция от k .

Практический признак

Почти прямая линия ошибки на полулогарифмическом графике — характерный признак геометрической сходимости.



Теория против эксперимента



Теоретическая оценка строится для всего класса задач и потому часто консервативна. Она должна быть над фактической ошибкой, а не совпадать с ней.



Самопроверка

Пусть

$$L = 20, \quad \mu = 2.$$

Ответьте:

1. Чему равно κ ?
2. Чему равен множитель $q = 1 - 1/\kappa$?
3. Во сколько раз примерно уменьшится верхняя оценка ошибки после 20 шагов?

$\kappa = 10, \quad q = 0.9, \quad q^{20} \approx 0.12.$
--



Для выпуклой L -гладкой функции:

$$f(x_k) - f^* \leq \frac{L \|x_0 - x^*\|^2}{2k}.$$

Добавляем μ -сильную выпуклость:

$$f(x_k) - f^* \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^*).$$

Именно отношение

$$\kappa = L/\mu$$

управляет худшей гарантированной геометрической скоростью.



Следующий естественный вопрос

При плохой обусловленности

$$\kappa \gg 1$$

обычный градиентный спуск может быть медленным, даже если задача выпуклая и очень хорошо изучена.

Что можно сделать?

Можно ли изменить алгоритм так, чтобы быстрее проходить длинные узкие долины и меньше зависеть от κ ?

Это приведёт нас к более продвинутым методам оптимизации.