

Совместная программа СМОЛ ГУ и
ФКН НИУ ВШЭ

2026/27 учебный год

Методы оптимизации в машинном обучении

Лекция 9. Метод Ньютона: от градиента к кривизне

Никита Лукьяненко

Где мы остановились

В предыдущих лекциях мы выбирали направление $-\nabla f(x)$ и отдельно подбирали длину шага α.

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Сегодняшний вопрос

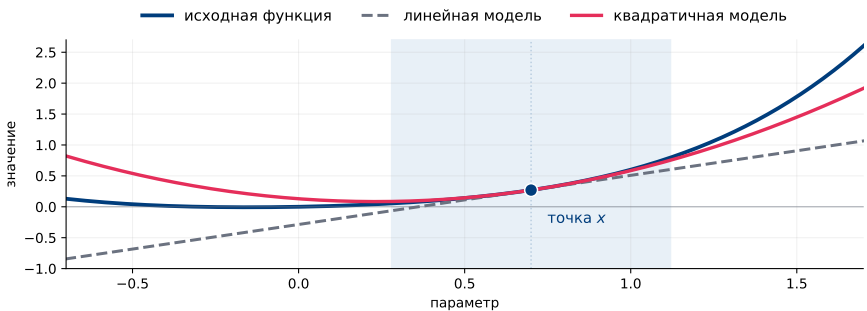
Можно ли использовать **кривизну** функции, чтобы сразу определить подходящее перемещение по каждой координате?

Линейная модель видит наклон, но не кривизну

Разложение первого порядка даёт

$$f(x+h) = f(x) + \nabla f(x)^{\top} h + o(\|h\|).$$

Его линейная часть не ограничена снизу по h, когда $\nabla f(x) \neq 0$.



Цели лекции

После лекции мы сможем:

1. вывести шаг Ньютона из квадратичной модели и линеаризации градиента;
2. доказать точное решение положительно определённой квадратичной задачи за один шаг;
3. понять, когда направление Ньютона убывает и когда полный шаг опасен;
4. доказать локальную квадратичную сходимость с явными предпосылками;
5. применить демпфирование и условие Армихо.

Градиент и гессиан: напоминание

Для дважды дифференцируемой $f : \mathbb{R}^n \to \mathbb{R}$:

$$g(x) = \nabla f(x), \qquad H(x) = \nabla^2 f(x).$$

Градиент задаёт изменение первого порядка, гессиан описывает изменение самого градиента.

$$g(x + h) = g(x) + H(x)h + o(\|h\|).$$

Важное различие

Гессиан может быть положительно определённым, неопределённым или вырожденным. От этого зависит смысл шага Ньютона.

Кривизна зависит от направления

Для единичного вектора v величина $v^\top H(x)v$ задаёт вторую производную вдоль прямой $x + tv$.

$$\frac{d^2}{dt^2} f(x + tv)\Big|_{t=0} = v^\top H(x)v.$$

Если $H(x) \succ 0$, кривизна положительна во всех ненулевых направлениях. Если $H(x)$ неопределён, локальная поверхность имеет направления разной кривизны.

Маршрут на 80 минут

Постановка и связь с градиентным спуском	7 мин
Квадратичная модель и вывод шага	14 мин
Квадратичная функция: один шаг	11 мин
Направление убывания и ограничения метода	10 мин
Локальная квадратичная сходимость	15 мин
Демпфирование и поиск Армихо	15 мин
Примеры, сравнение и выводы	8 мин



Когда у модели есть единственный минимум

Мы уже знаем из лекции 2 квадратичную модель функции в точке x:

$$m_x(h) = f(x) + g(x)^\top h + \tfrac{1}{2} h^\top H(x) h.$$

Здесь h — **перемещение** от текущей точки; $m_x(h)$ приближает значение $f(x+h)$. Если $H(x) \succ 0$, модель строго выпукла как функция перемещения h:

$$\nabla_h m_x(h) = g(x) + H(x)h, \qquad \nabla_h^2 m_x(h) = H(x) \succ 0.$$

Следующий вопрос: какое именно h минимизирует эту модель?

Стационарная точка модели — перемещение, а не значение

Назовём h_* **стационарной точкой модели**, если производная модели по перемещению равна нулю:

$$\nabla_h m_x(h_*) = g(x) + H(x)h_* = 0.$$

При $H(x) \succ 0$ это уравнение имеет ровно одно решение. Более того,

$$m_x(h) - m_x(h_*) = \tfrac{1}{2}(h - h_*)^\top H(x)(h - h_*) > 0 \quad \text{для } h \neq h_*.$$

Значит, **перемещение** h_* даёт наименьшее значение **квадратичной модели** среди всех h. Для исходной функции $f(x + h)$ такого вывода пока нет.



Вывод шага Ньютона из минимума модели

При $H(x) \succ 0$ решаем условие стационарности модели:

$$g(x) + H(x)h = 0.$$

Так как $H(x)$ обратима,

$$\boxed{p_N(x) = -H(x)^{-1}g(x).}$$

Вычислительно решают систему $H(x)p_N = -g(x)$, не формируя обратную матрицу.

$$\boxed{x_{k+1} = x_k + p_N(x_k)}$$

называется **полным шагом Ньютона**.



Тот же шаг из уравнения стационарности

Искомый минимум удовлетворяет $g(x^*) = 0$. Заменим градиент поблизости от x линейной моделью:

$$g(x + h) \approx g(x) + H(x)h.$$

Принудительно обнулим приближение:

$$g(x) + H(x)h = 0 \quad \Longrightarrow \quad h = p_N(x).$$

Два взгляда на формулу

При $H(x) \succ 0$ шаг минимизирует квадратичную модель. При просто обратимом $H(x)$ он остаётся шагом Ньютона для уравнения $g(x) = 0$, но может не вести к минимуму.



Итерация в нескольких строках

В точке x_k:

1. вычислить $g_k = \nabla f(x_k)$ и $H_k = \nabla^2 f(x_k)$;
2. решить линейную систему $H_k p_k = -g_k$;
3. положить $x_{k+1} = x_k + p_k$.

Условия нужны на каждом шаге

Обратимость H_k позволяет вычислить шаг. Положительная определённость дополнительно делает p_k направлением убывания при $g_k \neq 0$.



Одномерная формула

Для $f : \mathbb{R} \to \mathbb{R}$, если $f''(x) \neq 0$,

$$\boxed{x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}.}$$

Например, для $f(x) = \frac{1}{2}a(x - x^*)^2$, $a > 0$:

$$f'(x) = a(x - x^*), \qquad f''(x) = a,$$

поэтому $x_{k+1} = x^*$ независимо от начальной точки.



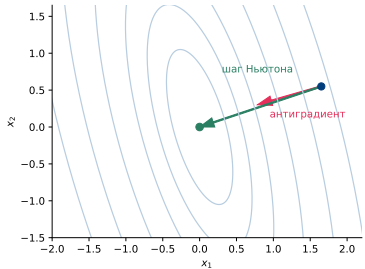
Как кривизна меняет длину шага

В одном измерении $p_N = -f'/f''$. При одинаковом наклоне большой $f'' > 0$ даёт короткий шаг, маленький $f'' > 0$ даёт длинный.

$$\underbrace{-\alpha f'(x)}_{\text{градиентный шаг}} \qquad \text{и} \qquad \underbrace{-\frac{f'(x)}{f''(x)}}_{\text{шаг Ньютона}}.$$

В нескольких измерениях H^{-1} корректирует разные направления по-разному.

Геометрия двух направлений



Из синей начальной точки красная стрелка идёт по антиградиенту: она перпендикулярна линии уровня и показывает самое быстрое локальное убывание при малой длине шага. Зелёная стрелка — перемещение Ньютона: оно учитывает вытянутость эллипсов и ведёт к их центру. Здесь функция квадратична, поэтому модель точна и зелёная стрелка попадает в минимум сразу.

Гессиан как локальный масштаб координат

Если $H = Q\Lambda Q^\top \succ 0$ и $g = \sum_i \gamma_i q_i$, то

$$p_N = -Q\Lambda^{-1}Q^\top g = -\sum_i \frac{\gamma_i}{\lambda_i} q_i.$$

Здесь q_i — собственное направление гессиана, $\lambda_i > 0$ — кривизна в нём, γ_i — компонента градиента. Метод делит эту компоненту на кривизну: в крутом направлении перемещение короче, в пологом — длиннее.

Если кривизна очень мала, полный шаг может оказаться слишком длинным за пределами локальной модели. Позже ограничим его длину поиском Армихо.

Что пока доказано, а что ещё нет

Мы вывели формулу $p_N = -H^{-1}g$ и условия, при которых она минимизирует **локальную модель**.

- Убывает ли истинная функция при полном шаге?
- Можно ли гарантировать сходимость из любой начальной точки?
- Какова скорость вблизи невырожденного минимума?

Ответы различаются. Начнём с класса задач, где модель точна всюду.

Положительно определённая квадратичная задача

Пусть

$$f(x) = \frac{1}{2} x^\top A x - b^\top x + c, \qquad A = A^\top \succ 0.$$

Тогда

$$g(x) = Ax - b, \qquad H(x) = A.$$

Гессиан постоянен, поэтому разложение Тейлора второго порядка совпадает с $f(x + h)$ **точно**, без остатка.



Единственный минимум квадратичной функции

Условие стационарности:

$$Ax^* - b = 0 \quad \Longrightarrow \quad \boxed{x^* = A^{-1}b.}$$

Поскольку $A \succ 0$, этот стационарный вектор является единственным глобальным минимумом.

$$f(x) - f(x^*) = \frac{1}{2}(x - x^*)^\top A(x - x^*) > 0 \quad \text{при } x \neq x^*.$$



Теорема: один шаг Ньютона

Утверждение

Для $f(x) = \frac{1}{2}x^\top Ax - b^\top x + c$, $A = A^\top \succ 0$, полный шаг Ньютона из любого x приводит в единственный минимум $x^* = A^{-1}b$.

Действительно, направление решает систему

$$Ap_N = -(Ax - b).$$

Значит,

$$p_N = A^{-1}b - x.$$

Доказательство одного шага: завершение

Подставляем полученное направление в полную итерацию:

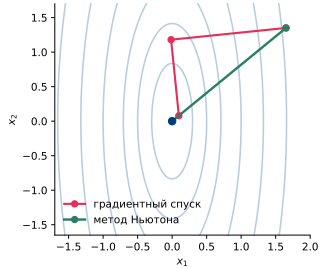
$$x_+ = x + p_N = x + (A^{-1}b - x) = A^{-1}b = x^*.$$

$$\boxed{x_+ = x^*.} \qquad \square$$

Область действия

Утверждение относится к точному решению линейной системы и постоянному положительно определённому гессиану. Численные ошибки и приближённое решение системы меняют буквальную точность одного шага.

Один шаг на карте линий уровня



Для квадратичной функции локальная модель совпадает с исходной задачей. Поэтому полный шаг Ньютона сразу попадает в центр эллипсов.

Численный пример в двух координатах

Возьмём

$$A = \begin{pmatrix} 4 & 0 \\ 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 4 \\ -2 \end{pmatrix}, \quad x_0 = \begin{pmatrix} 3 \\ 2 \end{pmatrix}.$$

Тогда $x^* = (1, -2)^\top$ и $g_0 = Ax_0 - b = (8, 4)^\top$.

$$p_0 = -A^{-1} g_0 = \begin{pmatrix} -2 \\ -4 \end{pmatrix}, \qquad x_1 = x_0 + p_0 = \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

Проверка: $g(x_1) = 0$.

Почему градиентному спуску нужен выбор шага

Для той же квадратичной функции градиентный шаг имеет вид

$$x_+ = x - \alpha(Ax - b).$$

Чтобы он попал в x^* за один шаг, необходимо одновременно выполнить $\alpha = 1/\lambda_i$ во всех активных собственных направлениях.

Вывод

При разных собственных значениях одно число α обычно не может устранить всю ошибку. Матрица A^{-1} корректирует каждую компоненту отдельно.

Зависимость результата от структуры задачи

Функция	Полный шаг Ньютона
$A \succ 0$ и $H(x) = A$ постоянно	точное решение за один шаг
Общая C^2 функция около минимума	квадратичная локальная сходимость при дополнительных условиях
Далеко от минимума	полный шаг может увеличить f

Далее разберём вторую и третью строки строго.

Когда направление Ньютона убывает

В лекции 8 направление p называлось направлением убывания, когда $g(x)^\top p < 0$: при малом положительном α функция $f(x + \alpha p)$ становится меньше.

Утверждение для метода Ньютона

Если $H(x) \succ 0$ и $g(x) \neq 0$, то $p_N = -H(x)^{-1} g(x)$ является строгим направлением убывания:

$$\boxed{g(x)^\top p_N < 0.}$$

Это утверждение касается **направления**. Полный шаг $\alpha = 1$ может увеличить функцию; такой пример увидим далее.

Доказательство направления убывания

Положительная определённость H влечёт $H^{-1} \succ 0$. Поэтому для $g \neq 0$

$$g^\top p_N = -g^\top H^{-1} g < 0.$$

Если $\varphi(\alpha) = f(x + \alpha p_N)$, то

$$\varphi'(0) = g^\top p_N < 0.$$

По определению производной найдётся $\bar{\alpha} > 0$ такое, что $f(x + \alpha p_N) < f(x)$ при $0 < \alpha \leq \bar{\alpha}$. $\square$



Что происходит при нулевом градиенте

Если $g(x) = 0$ и $H(x)$ обратима, то $p_N = 0$: метод уже находится в стационарной точке.

- При $H(x) \succ 0$ это строгий локальный минимум.
- При $H(x) \prec 0$ это строгий локальный максимум.
- При неопределённом $H(x)$ это седловая точка.

Формула шага сама по себе не классифицирует стационарную точку.

Неопределённый гессиан: шаг к седлу

Рассмотрим $f(x,y) = \frac{1}{2}(x^2 - y^2)$ в точке $(0,1)$.

$$g = (0,-1)^\top, \quad H = \operatorname{diag}(1,-1), \quad p_N = (0,-1)^\top.$$

Тогда $g^\top p_N = 1 > 0$, то есть это **направление роста**.

$$f(0,1) = -\frac{1}{2}, \qquad f(0,0) = 0.$$

Полный шаг приходит в седловую точку и увеличивает функцию.

Вырожденный гессиан: шаг не определён

Для $f(x) = x^3 - 3x$ в точке $x = 0$:

$$f'(0) = -3, \qquad f''(0) = 0.$$

Уравнение Ньютона $f''(0)p = -f'(0)$ превращается в $0 \cdot p = 3$ и не имеет решения.

Практическое следствие

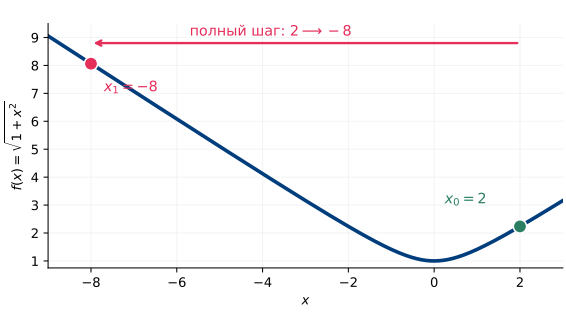
Перед вычислением направления проверяют возможность решения системы и свойства гессиана. При проблемах используют модификацию гессиана или другое направление.

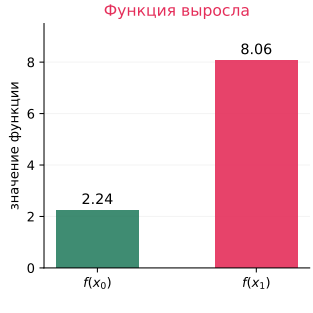
Полный шаг может провалиться даже при $H > 0$

Пусть $f(x) = \sqrt{1 + x^2}$. Здесь

$$f'(x) = \frac{x}{\sqrt{1 + x^2}}, \qquad f''(x) = \frac{1}{(1 + x^2)^{3/2}} > 0.$$

Шаг Ньютона даёт $x_+ = -x^3$. Из $x_0 = 2$ получаем $x_1 = -8$ и $f(x_1) = \sqrt{65} > \sqrt{5} = f(x_0)$.





Почему локальное направление не гарантирует полный шаг

Если $g^\top p_N < 0$, производная $\varphi'(0)$ отрицательна. Это гарантирует убывание только при **достаточно малой** длине шага.

$$\varphi(\alpha) = f(x + \alpha p_N), \qquad \varphi'(0) < 0.$$

При $\alpha = 1$ мы можем выйти за область, где квадратичная модель описывает f достаточно точно. Нужен механизм выбора α.

Теорема о локальной квадратичной сходимости

Теорема

Пусть $f \in C^2$ в окрестности x^*, $\nabla f(x^*) = 0$, а $H^* = \nabla^2 f(x^*) \succ 0$. Предположим, что в некотором шаре $B_r(x^*)$ гессиан липшицев и ограничен снизу:

$$H(x) \succeq mI \quad (m > 0), \qquad \|H(x) - H(y)\|_2 \leq L_H \|x - y\|_2 .$$

Тогда для достаточно близкого x_0 полный метод Ньютона корректен, остаётся в этом шаре и

$$\boxed{\|x_{k+1} - x^*\|_2 \leq \frac{L_H}{2m} \|x_k - x^*\|_2^2 .}$$

Если $L_H = 0$, гессиан постоянен в шаре и следующий шаг сразу даёт x^*.

Доказательство: почему гессиан обратим поблизости

Доказательство, шаг 1 из 5

Предпосылка $H^* \succ 0$ означает $\lambda_{\min}(H^*) > 0$. Поскольку $H(x)$ непрерывен, можно уменьшить шар около x^* так, чтобы

$$\|H(x) - H^*\|_2 \leq \tfrac{1}{2}\lambda_{\min}(H^*)$$

и, следовательно,

$$H(x) \succeq \tfrac{1}{2}\lambda_{\min}(H^*)I.$$

Липшицевость гессиана нужна отдельно для **квадратичной оценки ошибки**; одной непрерывности для этой оценки недостаточно.

Доказательство: точная формула для градиента

Шаг 2 из 5. Обозначим $e = x - x^*$. По основной теореме анализа вдоль отрезка:

$$g(x) - g(x^*) = \int_0^1 H(x^* + te)e\,dt.$$

Так как $g(x^*) = 0$,

$$\boxed{g(x) = \int_0^1 H(x^* + te)e\,dt.}$$

Эта формула точна. Именно она позволяет контролировать ошибку после шага без неформального символа $\approx$.

Доказательство: ошибка после шага

Шаг 3 из 5. Из $x_+ = x - H(x)^{-1} g(x)$ и $e = x - x^*$ получаем

$$e_+ = e - H(x)^{-1} g(x) = H(x)^{-1} \big(H(x) e - g(x) \big).$$

Подставляя интегральную формулу:

$$\boxed{e_+ = H(x)^{-1} \int_0^1 \big[H(x) - H(x^* + te) \big] e \, dt.}$$

Для квадратичной функции H постоянно, интеграл равен нулю.

Доказательство: почему ошибка возводится в квадрат

Шаг 4 из 5. Из $H(x) \succeq mI$ следует $\left\|H(x)^{-1}\right\|_2 \leq 1/m$. Липшицевость даёт

$$\|H(x) - H(x^* + te)\|_2 \leq L_H \|x - (x^* + te)\|_2 = L_H(1-t)\|e\|_2 .$$

Поэтому

$$\|e_+\|_2 \leq \frac{1}{m}\int_0^1 L_H(1-t)\|e\|_2^2 \, dt$$

$$= \boxed{\frac{L_H}{2m}\|e\|_2^2 .}$$

Это центральная оценка теоремы. Осталось проверить, что итерации остаются в выбранной окрестности.

Доказательство: итерации остаются рядом

Шаг 5 из 5. Пусть $L_H > 0$ и выберем

$$0 < \rho < r, \qquad \rho \le m/L_H.$$

Если $\|e_0\|_2 \le \rho$, то из оценки следует

$$\|e_{k+1}\|_2 \le \frac{L_H}{2m}\rho \|e_k\|_2 \le \tfrac{1}{2}\|e_k\|_2 .$$

Индукция показывает, что все точки остаются в шаре $B_\rho(x^*)$ и сходятся к x^*. Внутри него действует более сильная квадратичная оценка. □

Что означает квадратичная сходимость

Если $e_k = \|x_k - x^*\|$, то рядом с решением

$$e_{k+1} \le C e_k^2, \qquad C = \frac{L_H}{2m}.$$

Пример: $f(x) = e^x - x - 1$, минимум $x^* = 0$. Ньютон даёт $x_{k+1} = x_k - 1 + e^{-x_k}$ при $x_0 = 0{,}5$.

k	$e_k = \|x_k\|$	e_{k+1}/e_k^2
0	0,5	0,426
1	0,106531	0,483
2	0,005478	0,499
3	$1{,}50 \cdot 10^{-5}$	0,500
4	$1{,}12 \cdot 10^{-10}$	—

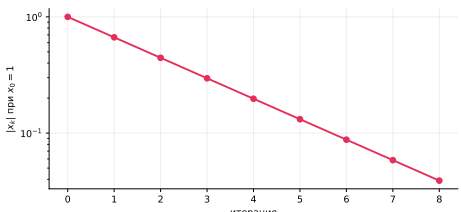
Отношение стремится к $1/2$: новая ошибка примерно равна половине квадрата предыдущей.

Невырожденность важна: пример x^4

Для $f(x) = x^4$ минимум находится в $x^* = 0$, но $f''(0) = 0$. При $x \neq 0$:

$$p_N = -\frac{4x^3}{12x^2} = -\frac{x}{3}, \qquad x_+ = \frac{2}{3}x.$$

Следовательно, $|x_k| = (2/3)^k |x_0|$: сходимость **линейная**, а не квадратичная.



Границы локальной теоремы

Теорема не утверждает глобальной сходимости из произвольной точки. Она требует:

- стационарный x^* с $H(x^*) \succ 0$;
- липшицев гессиан рядом с x^*;
- достаточно близкое начало для полного шага.

Вне этой окрестности полезно выбирать длину шага по фактическому значению f.



Демпфированный метод Ньютона

Демпфированный означает «с уменьшенной длиной шага». Направление Ньютона сохраняется, но его умножают на коэффициент $0 < \alpha_k \leq 1$:

$$\boxed{x_{k+1} = x_k + \alpha_k p_k, \qquad H_k p_k = -g_k.}$$

При $\alpha_k = 1$ получаем полный шаг, при $\alpha_k < 1$ — демпфированный. Если $H_k \succ 0$ и $g_k \neq 0$, направление убывает. Теперь выбираем длину по фактическому уменьшению функции.



Условие Армихо

Фиксируем $c \in (0, 1)$ и $\beta \in (0, 1)$. Пробуем $\alpha = 1, \beta, \beta^2, \ldots$, пока

$$\boxed{f(x + \alpha p) \leq f(x) + c\alpha g^\top p.}$$

Поскольку $g^\top p < 0$, правая часть меньше $f(x)$. Условие требует измеримого убывания, пропорционального предсказанному наклону.

Почему поиск Армихо завершается

Пусть $g^\top p < 0$, а градиент имеет константу Липшица L вдоль пробуемого отрезка. Лемма о спуске даёт

$$f(x + \alpha p) \le f(x) + \alpha g^\top p + \frac{L\alpha^2}{2} \|p\|^2 .$$

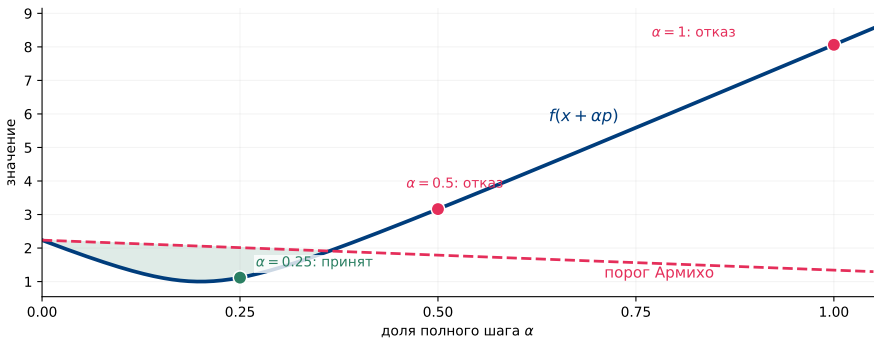
Условие Армихо выполнено, если

$$0 < \alpha \le \frac{2(1-c)(-g^\top p)}{L \|p\|^2}.$$

Геометрическая последовательность $1, \beta, \beta^2, \ldots$ в конце концов станет меньше этой положительной границы. □

Армихо исправляет слишком длинный шаг

Для $f(x) = \sqrt{1 + x^2}$ в точке $x = 2$ направление Ньютона равно $p = -10$. При $c = 0.1$, $\beta = 1/2$ шаги 1 и $1/2$ отклоняются, $\alpha = 1/4$ принимается: $x_+ = -1/2$.





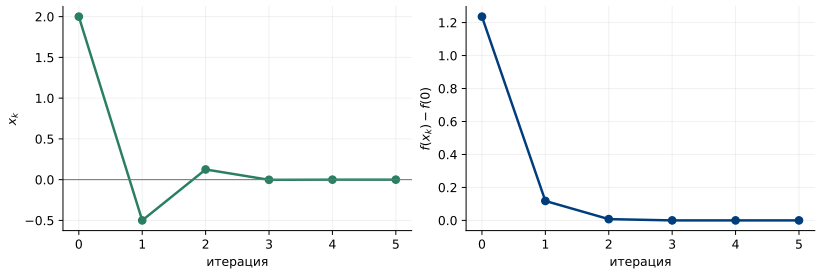
Алгоритм демпфированного Ньютона

На каждой итерации

1. Вычислить g_k и H_k. Если $\|g_k\|$ мала, остановиться.
2. Получить направление p_k из $H_k p_k = -g_k$. Проверить $g_k^\top p_k < 0$.
3. Начать с $\alpha = 1$. Пока не выполнено условие Армихо, заменить $\alpha \leftarrow \beta\alpha$.
4. Обновить $x_{k+1} = x_k + \alpha p_k$.

Если H_k не положительно определён, перед поиском шага нужно получить другое направление убывания, например из положительно определённой модификации H_k.

Пример траектории с демпфированием



В примере $f(x) = \sqrt{1 + x^2}$ поиск Армихо удерживает итерации от резкого прыжка $2 \mapsto -8$ и приводит к минимуму $x^* = 0$.



Почему вблизи минимума принимается $\alpha = 1$

Пусть $H(x) \succeq mI$, а гессиан липшицев с константой L_H на отрезке от x до $x + p$. Тогда остаток формулы Тейлора можно **оценить явно**:

$$f(x+p) = f(x) + g^\top p + \tfrac{1}{2} p^\top H(x) p + R, \qquad |R| \le \tfrac{L_H}{6} \|p\|^3 .$$

Для шага Ньютона $g = -Hp$, поэтому $g^\top p = -p^\top Hp$. Условие Армихо при $\alpha = 1$ выполнится, если

$$R \le (\tfrac{1}{2} - c) p^\top Hp.$$

При $c < 1/2$ правая часть не меньше $(\frac{1}{2} - c) m \|p\|^2$, а $|R|$ имеет порядок $\|p\|^3$. Поэтому достаточно малый полный шаг принимается.

Демпфирование сохраняет быстрый локальный режим

Если выполнены предпосылки локальной теоремы и $c \in (0, 1/2)$, то в достаточно малой окрестности x^* поиск Армихо принимает $\alpha = 1$. После этого метод совпадает с полным методом Ньютона:

$$\|x_{k+1} - x^*\| \leq \frac{L_H}{2m} \|x_k - x^*\|^2 .$$

Демпфирование контролирует шаг вдали от решения, а локальная квадратичная скорость возвращается рядом с ним.

Цена одной итерации

На каждом шаге нужны градиент, гессиан и решение линейной системы. Для плотной матрицы размерности n факторизация обычно требует порядка n^3 операций, хранение гессиана — порядка n^2 чисел.

Мост к следующей лекции

Можно ли сохранить коррекцию разных масштабов задачи, но заменить дорогой гессиан более простой положительно определённой матрицей? Так мы придём к **предобусловливанию** градиентного спуска.

Пример из ML: регуляризованная логистическая регрессия

В лекции 7 мы уже находили градиент логистической потери. Теперь посмотрим, какую дополнительную информацию даёт гессиан. Для $y_i \in \{-1, 1\}$ и $a_i \in \mathbb{R}^n$:

$$f(w) = \sum_{i=1}^{N} \log(1 + e^{-y_i a_i^\top w}) + \frac{\lambda}{2} \|w\|^2, \qquad \lambda > 0.$$

Положив $s_i = (1 + e^{y_i a_i^\top w})^{-1}$, получаем

$$H(w) = \sum_{i=1}^{N} s_i(1 - s_i) a_i a_i^\top + \lambda I \succ 0,$$

поскольку $s_i(1 - s_i) > 0$ и $\lambda I \succ 0$. Поэтому $H(w)p = -g(w)$ даёт направление убывания при $g(w) \neq 0$; Армихо подбирает длину. Полное численное решение системы может быть дорого при большом числе признаков.

Пример из ML: метод наименьших квадратов

Эту задачу мы изучали в лекции 3. Для $f(w) = \frac{1}{2}\|Xw - y\|_2^2$:

$$g(w) = X^\top(Xw - y), \qquad H = X^\top X.$$

Если столбцы X линейно независимы, $H \succ 0$ постоянно. Направление удовлетворяет

$$X^\top Xp = -X^\top(Xw - y) \quad \Longrightarrow \quad X^\top X(w + p) = X^\top y.$$

Значит, один **полный** шаг даёт точный минимум в точной арифметике.

Численная оговорка

На практике МНК часто решают через QR или SVD, не формируя $X^\top X$: так устойчивее при плохо обусловленной матрице X.



Как выбирать действие по состоянию гессиана

Состояние	Действие
$H \succ 0$, точка далеко от минимума	направление Ньютона и поиск Армихо
$H \succ 0$, точка близко к минимуму	полный шаг; ожидаем квадратичную скорость
H неопределён или вырожден	модифицировать гессиан либо выбрать другое направление убывания

Критерий близости здесь теоретический; на практике его заменяет успешное принятие полного шага.



Короткая проверка понимания

1. Почему полный метод решает положительно определённую квадратичную задачу за один шаг?
2. Какое свойство $H(x)$ делает p_N направлением убывания?
3. Почему $f \in C^2$ и $H(x^*) \succ 0$ сами по себе не дают выписанную квадратичную оценку?
4. При каком условии на c Армихо в конце концов принимает полный шаг рядом с x^*?

Итоги

$$\boxed{H_k p_k = -g_k, \qquad x_{k+1} = x_k + \alpha_k p_k.}$$

- При $H \succ 0$ направление Ньютона убывает; квадратичную функцию оно решает за один полный шаг.
- При липшицевом гессиане и невырожденном минимуме полный метод сходится локально квадратично.
- Поиск Армихо контролирует длину шага и рядом с минимумом допускает $\alpha = 1$ при $c < 1/2$.

Основной источник оформления: лекции 2–5 курса «Методы оптимизации в машинном обучении»; математический вывод выполнен в этой лекции.

Лекция 10. Предобусловливание и геометрия методов оптимизации

Почему эта тема следующая

В лекциях 2–4 мы увидели, как форма линий уровня и спектр влияют на градиентный спуск; в лекции 6 оценили его скорость. Лекции 7–8 дали вычисление градиента и выбор шага. Сегодня метод Ньютона показал, как кривизна устраняет растяжение на квадратичной задаче, но точный гессиан может быть дорогим.

Идея: выбрать более простую матрицу $P \succ 0$, отражающую масштаб задачи, и изменить направление:

$$\boxed{x_{k+1} = x_k - \alpha_k P^{-1} \nabla f(x_k).}$$

При $P = I$ это обычный градиентный спуск; если на каждом шаге брать $P = H(x_k) \succ 0$ и $\alpha_k = 1$, получаем шаг Ньютона.

План лекции 10:

1. Замена координат и новая геометрия квадратичной функции.
2. Матрица предобусловливания и предобусловленный градиентный спуск.
3. Как спектр после замены координат меняет скорость сходимости.
4. Простые варианты P и сравнение с GD и методом Ньютона.