Семинар 5. Скорость сходимости градиентного спуска

Основные задачи рассчитаны примерно на 40 минут работы у доски. Дополнительные задачи предназначены для более быстрой группы и самостоятельной практики. Если не сказано обратное, используется евклидова норма $\|\cdot\|_2$.

Основные задачи

Задача 1. Как по журналу ошибок распознать тип сходимости

Для трёх запусков некоторого метода оптимизации наблюдались относительные ошибки

$$r_k = \frac{f(x_k) - f^\star}{f(x_0) - f^\star}.$$

k	1	2	4	8	16
A	0.82	0.67	0.45	0.20	0.042
B	0.50	0.33	0.20	0.11	0.059
C	0.95	0.90	0.81	0.66	0.44

a) Какие из последовательностей больше похожи на геометрическую сходимость $r_k \approx q^k$, а какая — на поведение порядка $1/k$?

b) Для геометрических последовательностей оцените q.

c) Предскажите, сколько примерно итераций понадобится, чтобы добиться $r_k \le 10^{-3}$.

d) Можно ли по этой таблице заключить, что теоретическая оценка скорости достигается с равенством? Объясните.

Задача 2. Какой шаг градиентного спуска лучше

Рассмотрим

$$f(x) = \frac{1}{2} x^\top \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix} x, \qquad x_0 = (1, 1)^\top.$$

Для постоянного шага α компоненты ошибки умножаются на

$$q_1 = 1 - \alpha, \qquad q_2 = 1 - 9\alpha.$$

Сравните четыре шага

$$\alpha \in \{0.05,\ 0.10,\ 0.18,\ 0.21\}.$$

a) Для каждого α вычислите q_1 и q_2.

b) Определите, сходится ли метод и возникают ли колебания хотя бы в одном собственном направлении.

c) Для каждого шага вычислите

$$\rho(\alpha) = \max\{|q_1|, |q_2|\}.$$

Какой из предложенных шагов лучше с точки зрения худшего направления?

d) Предложите шаг, который должен быть ещё лучше, чем лучший из четырёх предложенных. Обоснуйте ответ через $\rho(\alpha)$.

Задача 3. Почему одно и то же число обусловленности не задаёт скорость каждого запуска

Рассмотрим

$$f(x, y) = \frac{1}{2}(x^2 + 100y^2), \qquad \alpha = \frac{1}{100}.$$

Сравните два запуска:

$$x_0^{(A)} = (1, 0), \qquad x_0^{(B)} = (0, 1).$$

a) Выпишите явные формулы для $x_k^{(A)}$ и $x_k^{(B)}$.

b) Что происходит с каждой координатой после одного шага?

c) Какая из двух траекторий сходится быстрее и почему, хотя у задачи одно и то же $\kappa = 100$?

d) Сформулируйте своими словами, что именно означает оценка скорости через число обусловленности: точную скорость любого запуска или худшую гарантию по всем направлениям?

e) Что изменится для старта $x_0^{(C)} = (1, 1)$?

Задача 4. Сколько регуляризации нужно, чтобы ускорить оптимизацию

Для задачи наименьших квадратов крайние собственные значения гессиана равны

$$\mu = 0.2, \qquad L = 10.$$

После добавления Ridge-регуляризации $\frac{\lambda}{2}\|w\|^2$ получаем

$$\mu_\lambda = 0.2 + \lambda, \qquad L_\lambda = 10 + \lambda,$$

и

$$\kappa(\lambda) = \frac{10 + \lambda}{0.2 + \lambda}.$$

a) Найдите исходные $\kappa(0)$ и теоретический множитель $q = 1 - 1/\kappa$.

b) Найдите минимальное $\lambda \geq 0$, для которого $\kappa(\lambda) \leq 10$.

c) Как изменится при таком λ теоретический множитель q?

d) Найдите минимальное λ, при котором $q \leq 0.8$.

e) Объясните, почему ускорение оптимизации не означает, что с точки зрения статистической модели следует брать сколь угодно большое λ.

Задача 5. Может ли критерий остановки по градиенту вводить в заблуждение

Рассмотрим семейство одномерных функций

$$f_a(x) = \frac{a}{2}x^2, \qquad a > 0,$$

с минимумом $x^\star = 0$. Алгоритм останавливается, когда

$$|f_a'(x)| \leq 10^{-2}.$$

a) Выразите максимально возможное $|x - x^\star|$ в момент остановки через a.

b) Выразите максимально возможную ошибку по функции $f_a(x) - f_a(x^\star)$ через a.

c) Вычислите обе величины для

$$a = 10^{-3}, \qquad a = 1, \qquad a = 100.$$

d) Почему один и тот же порог на $\|\nabla f(x)\|$ может означать очень разную точность по аргументу?

e) Какая характеристика геометрии функции нужна, чтобы связать малый градиент с близостью к $x^\star$?

Дополнительные задачи

Задача 6. Масштабирование функции и траектория GD

Пусть $g(x) = Cf(x)$, где $C > 0$, а функция f является L-гладкой и μ-сильно выпуклой.

a) Найдите параметры гладкости и сильной выпуклости L_g и μ_g функции g.

b) Сравните $\kappa_g = L_g/\mu_g$ и $\kappa = L/\mu$.

c) Сравните итерации

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k)$$

и

$$y_{k+1} = y_k - \frac{1}{L_g}\nabla g(y_k), \qquad y_0 = x_0.$$

Докажите, что последовательности совпадают.

d) Почему само по себе большое значение L ещё не означает плохую обусловленность?

Задача 7. Поворот координат не меняет сложность квадратичной задачи

Пусть

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 20 \end{pmatrix}, \qquad B = QAQ^\top,$$

где Q — ортогональная матрица поворота.

a) Покажите, что A и B имеют одинаковые собственные значения.

b) Сравните их числа обусловленности.

c) Пусть $y_0 = Qx_0$. Покажите, что если обе задачи решаются GD с шагом $1/L$, то $y_k = Qx_k$ для всех k.

d) Объясните, почему ориентация эллиптических линий уровня сама по себе не делает задачу «труднее».

Задача 8. Постройте самый медленный старт

Пусть SPD-матрица A имеет собственные значения

$$1, \qquad 4, \qquad 10,$$

а GD работает с шагом

$$\alpha = 0.1.$$

Рассматриваются все начальные ошибки e_0 с $\|e_0\| = 1$.

a) Найдите множители $1 - \alpha\lambda_i$ для трёх собственных направлений.

b) В каком собственном направлении следует выбрать e_0, чтобы $\|e_k\|$ убывала медленнее всего?

c) Найдите $\|e_k\|$ для такого старта.

d) Как изменится ответ, если интересует не большой k, а только один шаг?

Задача 9. Что можно узнать по наблюдаемому множителю сходимости

В численном эксперименте на поздних итерациях наблюдается

$$\frac{f(x_{k+1}) - f^\star}{f(x_k) - f^\star} \approx 0.92.$$

Предположим для начала, что это число совпадает с теоретической границей

$$q = 1 - \frac{1}{\kappa}.$$

a) Оцените κ.

b) Если наблюдаемый множитель равен 0.98, как изменится оценка κ?

c) Можно ли по одному наблюдаемому запуску утверждать, что истинное спектральное число обусловленности равно найденному значению?

d) Приведите причину, по которой фактическая скорость может быть заметно лучше худшей теоретической.

Задача 10. Найдите ошибки в утверждениях

Для каждого утверждения решите, верно ли оно. Если неверно — приведите конкретный контрпример; если верно — коротко обоснуйте.

a) «Если константа гладкости L меньше, градиентный спуск всегда сходится быстрее».

b) «Если $\kappa = 100$, ошибка на каждой итерации обязательно умножается на 0.99».

c) «Если $\|\nabla f(x)\|$ мало, то x обязательно близко к $x^\star$».

d) «Поворот линий уровня может ухудшить число обусловленности квадратичной задачи».

e) «Добавление Ridge-регуляризации может улучшить обусловленность гессиана».