Семинар 6. Матричное и автоматическое дифференцирование

Материал лекции 7. Основные задачи рассчитаны на 40 минут; их вычислительные аналоги — ещё на 40 минут работы в Python/Colab. Дополнительные задачи предназначены для самостоятельной практики. Если не сказано иначе, градиенты записываются столбцами.

Основные задачи

Задача 1. Градиент составной матричной функции

Рассмотрим

$$F(w) = \frac{1}{2}\|C(Aw - b)\|_2^2 + \frac{\lambda}{2}\|w\|_2^2,$$

где

$$A = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad \lambda = 1.$$

a) Введите промежуточные переменные $r = Aw - b$, $z = Cr$. Найдите dr, dz и dF.

b) Получите формулу $\nabla F(w)$, не раскрывая матричные произведения покоординатно.

c) Вычислите $\nabla F(w)$ в точке $w = (0, 1)^\top$.

d) Проверьте размерности всех множителей в формуле градиента.

Задача 2. Разветвление в вычислительном графе

Рассмотрим

$$f(x, y) = (xy + x)(xy)^2.$$

Зададим граф с промежуточными переменными

$$a = xy, \qquad b = a + x, \qquad c = a^2, \qquad f = bc.$$

a) Нарисуйте вычислительный граф, отметив все стрелки зависимостей.

b) Вычислите значения узлов при $x = 1$, $y = 2$.

c) Выполните обратный проход и найдите $\partial f/\partial x$ и $\partial f/\partial y$ в этой точке. Явно покажите, где складываются производные из разных ветвей.

d) Проверьте ответ независимым аналитическим дифференцированием исходной формулы.

Задача 3. Прямой и обратный режимы: согласованность

Пусть

$$G(x_1, x_2, x_3) = \begin{pmatrix} x_1 x_2 + \sin x_3 \\ x_1^2 + x_2 x_3 \end{pmatrix}, \quad x = \begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}, \quad v = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad u = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

a) Найдите матрицу Якоби $J_G(x)$ и укажите её размерность.

b) Вычислите $J_G(x)v$ и $J_G(x)^\top u$. Объясните, что вычисляют эти два произведения.

c) Проверьте численно тождество

$$\boxed{u^\top J_G(x) v = v^\top J_G(x)^\top u.}$$

d) Обоснуйте это тождество для произвольной матрицы $J \in \mathbb{R}^{m \times d}$ и произвольных u, v подходящих размерностей.

Задача 4. Численная устойчивость конечной разности

Рассмотрим функцию $f(x) = \sqrt{1+x} - 1$ при $x > -1$ и приближение её производной в нуле:

$$D_h = \frac{f(h) - f(0)}{h} = \frac{\sqrt{1+h} - 1}{h}, \qquad h > 0.$$

a) Найдите точное значение $f'(0)$.

b) Избавьтесь от вычитания близких чисел в формуле D_h, домножив числитель и знаменатель на сопряжённое выражение.

c) Объясните, почему полученные две формулы математически равны, но при очень маленьком h могут давать разные результаты на компьютере.

d) Какой результат должен получиться при $h \to 0$? Почему брать h «как можно меньше» в исходной формуле опасно?

Задача 5. Обратный проход через матрицу и нелинейность

Пусть

$$F(w) = u^\top \varphi(Bw), \qquad \varphi(t) = t^2 \quad \text{(покомпонентно)},$$

$$B = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \qquad u = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \qquad w = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

a) Запишите цепочку $w \mapsto z = Bw \mapsto a = \varphi(z) \mapsto F = u^\top a$.

b) Вычислите $F(w)$ и все промежуточные значения в заданной точке.

c) Проведите обратный проход от F к w, выписывая производные по a, z, w.

d) Запишите общую формулу $\nabla_w F(w)$ для произвольных B, u, w.

Дополнительные задачи

Задача 6. Градиент после линейной замены переменных

Пусть

$$f(w_1, w_2) = (w_1 - 1)^2 + 4(w_2 + 2)^2, \qquad w = Dz, \quad D = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}.$$

a) Найдите $\nabla_w f(w)$ и $\nabla_z(f(Dz))$ двумя способами: подстановкой и правилом цепочки.

b) Проверьте формулу $\nabla_z(f(Dz)) = D^\top \nabla_w f(w)$ в точке $z = (1, -2)^\top$.

c) Объясните, почему градиенты по z и по w в общем случае различаются.

Задача 7. Какой режим дифференцирования выбирать?

Рассмотрим отображения

$$G_1 : \mathbb{R}^2 \to \mathbb{R}^{100}, \qquad G_2 : \mathbb{R}^{100} \to \mathbb{R}, \qquad G_3 : \mathbb{R}^{100} \to \mathbb{R}^{100}.$$

a) Сколько отдельных направленных проходов потребуется в общем случае для вычисления полной матрицы Якоби прямым режимом?

b) Сколько обратных проходов требуется для вычисления той же матрицы построчно?

c) Для каждого G_i выберите более подходящий режим по числу проходов. Почему результат сравнения не является строгой оценкой времени работы конкретной программы?

Задача 8. Что происходит в недифференцируемой точке?

Рассмотрим $f(x) = \max\{0, x\}$.

a) Вычислите $f'(x)$ при $x < 0$ и $x > 0$.

b) Существуют ли левая и правая производные в $x = 0$? Существует ли обычная производная?

c) Чему равна симметричная конечная разность

$$\frac{f(h) - f(-h)}{2h}, \qquad h > 0?$$

d) Почему результат последнего пункта нельзя называть значением $f'(0)$?

Задача 9. Затухающие и взрывающиеся градиенты

Рассмотрим цепочку из n операций

$$z_0 = x, \qquad z_{k+1} = a z_k \ (k = 0, \dots, n-1), \qquad F(x) = z_n.$$

a) Найдите $F(x)$ и $F'(x)$ как функции a, n.

b) Объясните результат через произведение локальных производных вычислительного графа.

c) Исследуйте поведение $|F'(x)|$ при $n \to \infty$ для $|a| < 1$, $|a| = 1$ и $|a| > 1$.

d) Почему трудности могут возникать, даже когда все локальные производные вычислены корректно?

Задача 10. Эмпирический риск логистической модели

Для наблюдений (x_i, y_i), $y_i \in \{-1, 1\}$, рассмотрим

$$R(w) = \frac{1}{n} \sum_{i=1}^{n} \log\left(1 + e^{-y_i w^\top x_i}\right) + \frac{\lambda}{2} \|w\|_2^2 .$$

a) Выведите $\nabla R(w)$, используя градиент одной потери и линейность дифференциала.

b) Пусть $n = 2$, $x_1 = (1, 0)^\top$, $y_1 = 1$, $x_2 = (1, 1)^\top$, $y_2 = -1$, $\lambda = 1$. Найдите $\nabla R(0)$.

c) Объясните, какие операции требуется выполнить при обратном проходе по вычислительному графу для одного объекта и для среднего по выборке.